1ª Parte – Estatística Descritiva

1.1 - Divisão da Estatística

Estatística Descritiva: descrição, resumo e organização das informações. Compreende o uso de tabelas, gráficos e medidas resumo.

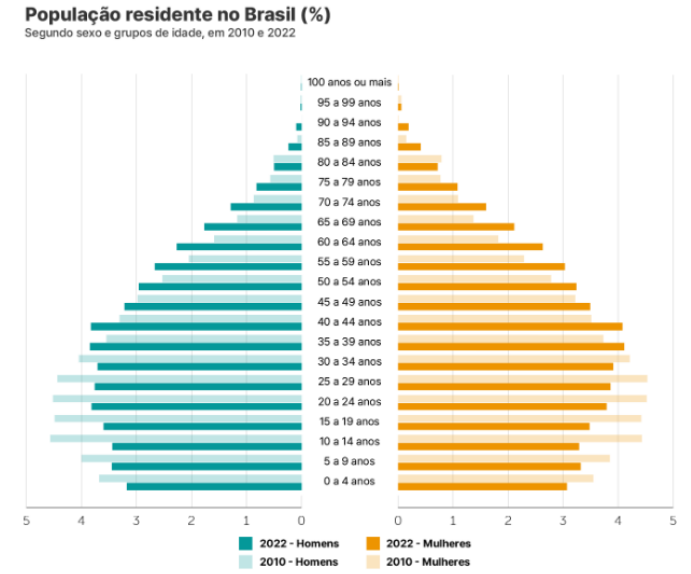

Fonte: Censo Demográfico Brasileiro - IBGE

Estatística Inferencial: através do particular (amostra) faz induções a respeito do todo (população), controlando a probabilidade de erro (por isso estudaremos a Teoria das Probabilidades).

Exemplo 1.1: projeção da percentagem de votos para um candidato numa eleição, projeção de safras.

Exemplo 1.2: expectativas de vida no Brasil, em anos, segundo projeções do IBGE.

1960: 52,5

2023: 76,4

2042: 79,7

1.2 - Estatística Descritiva

Definições

População: conjunto universo de elementos que possuem ao menos uma característica em comum. O tamanho da população é representado por N.

Exemplo 1.3: total de eleitores que compareceram ao último pleito.

Dimensão de uma população: finita ($N<\infty$)
infinita enumerável ($N=\infty$)
não enumerável ($N=\infty$)

Observação: um conjunto A é dito enumerável quando é finito ou quando há uma bijeção $f: A \to \mathbb{N}$. No segundo caso diremos que é infinito enumerável. O conjunto $\mathbb{N}$ é infinito enumerável, assim como o conjunto dos racionais. O conjunto dos reais é não enumerável.

Censo: é a investigação exaustiva de toda a população.

Exemplo 1.4: Série Censo Demográfico - IBGE

Ano	População	Variação %
1872	9930478	----------
1890	14333915	44,3426489641284
1900	17438434	21,6585559492993
1920	30635605	75,6786475207579
1940	41236315	34,602580885868
1950	51944397	25,9676016152268
1960	70191370	35,1278945446224
1970	93139037	32,6930034276294
1980	119002706	27,7688816988735
1991	146825475	23,3799465030652
2000	169799170	15,6469406960883
2010	190732695	12,3284024297645
2023	203062512	6,46444858339572

Amostra: é um subconjunto da população, isto é, uma parte da população retirada segundo alguns critérios. O tamanho da amostra é representado por n.

Exemplo 1.5: pesquisa pré-eleitorais, Pesquisa Nacional por Amostragem de Domicílios (PNAD).

Amostragem: é o processo de obtenção de uma amostra da população.

1.3 - Escalas de mensuração

Variáveis: são as características de interesse em uma população ou amostra.

Variáveis Qualitativas: Expressam qualidade e subdividem-se em:

Nominais: os níveis da variável são categorias de qualidade.

Exemplo 1.6: tipo de variedade de batata, cor, etc.

Ordinais: os níveis da variável são ordenados de acordo com a intensidade do fenômeno.

Exemplo 1.7: atribuir graus para uma característica não mensurável como aderência de uma tinta numa superfície metálica.

Z = "Grau de aderência da tinta"

A = "pouca" ; B = " regular" ; C = "boa" ; D = "ótima"

Note que nas escalas nominal e ordinal não podemos fazer operações aritméticas como numa escala numérica. No exemplo 1.7 não faz sentido fazer a soma $A+B+C+D$.

Variáveis Quantitativas: expressam uma quantidade numérica, subdividem-se em:

Discretas: podem assumir valores observados somente em pontos isolados em uma escala.

Exemplo 1.8: número de defeitos num lote de 100 peças, números de falhas diárias numa máquina, etc.

Contínuas: Podem assumir qualquer valor em um conjunto não enumerável.

Exemplo 1.9: comprimento, área, velocidade, temperatura.

1.4 - Arredondamentos de números

(1º)

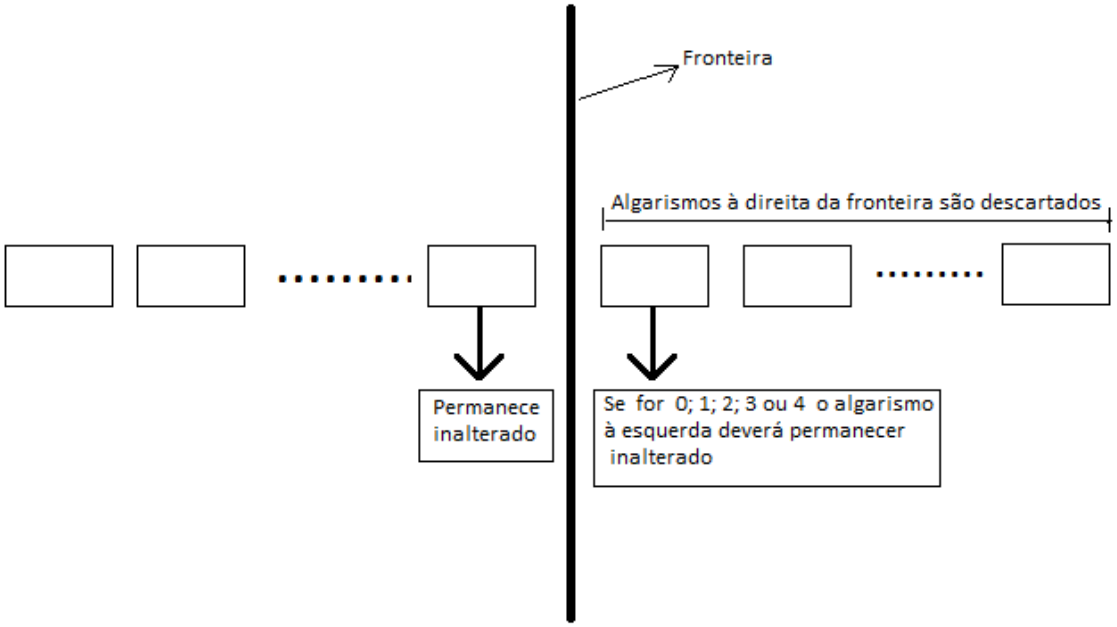

(2ª)

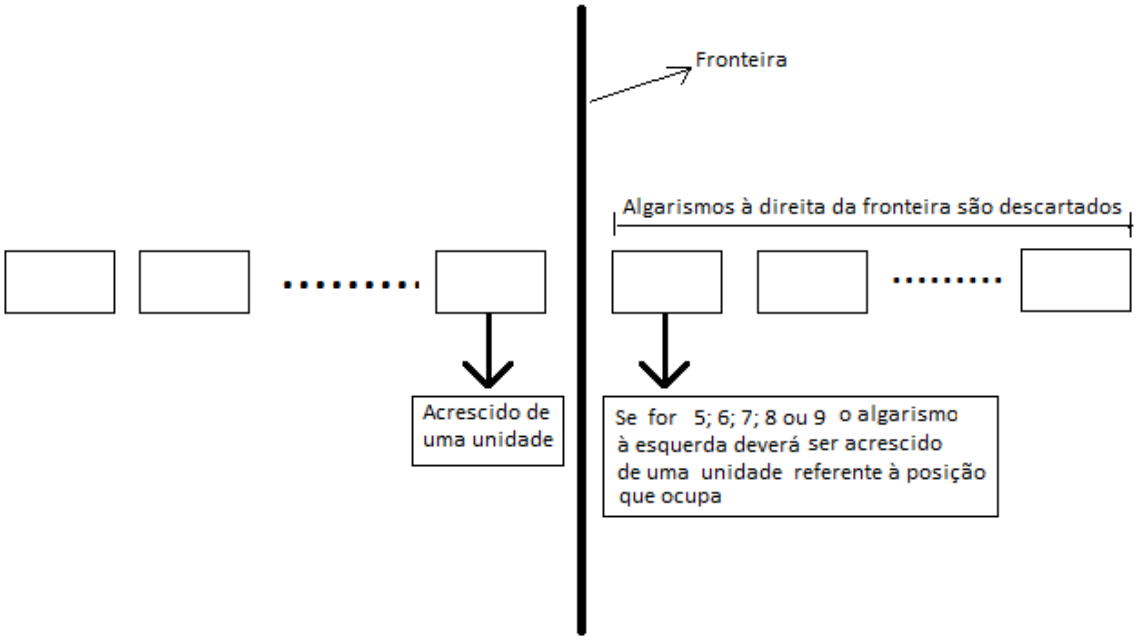

Exemplo 1.10: Arredonde para

(a) a unidade 72,8 : 73

(b) centésimos 72,8146: 72,81

(c) milésimos 72,8146: 72,815

(d) centésimos 72,465: 72,47

(e) centésimos 183,575: 183,58

(f) dezenas 737,2136 : 740

Observações:

(1ª) Recomenda-se não arredondar cálculos intermediários. Se for arredondar, apenas a resposta final. Para evitar erros nos cálculos, utilize as memórias (variáveis) da calculadora. Nas calculadoras científicas mais antigas havia apenas uma memória, mas nas mais recentes, há, pelo menos, seis para armazenar resultados.

(2ª) As calculadoras operam com sistema de ponto flutuante. Números racionais, como por exemplo $\frac{2}{3}$, e irracionais como $\sqrt{2}$, são aproximados por um número finito de dígitos.

(3ª) Pode acontecer erros em algumas operações, como no exemplo a seguir.

$$\frac{1}{\frac{a}{b}+\frac{c}{d}}=\frac{b\times d}{a\times d+b\times c}$$

$$\frac{1}{\frac{7}{3600}+\frac{8}{4600}}=\frac{16560}{61}=271{,}4754098$$

Arredondando $\frac{7}{3600}$ como 0,0019 e $\frac{8}{4600}$ como 0,0017,

$$\frac{1}{\frac{7}{3600}+\frac{8}{4600}}\approx\frac{1}{0{,}0019+0{,}0017}=\frac{2500}{9}=277{,}7777778$$

1.5 - Somatórios

$\sum$ é o símbolo reservado para representar uma soma

$$\sum_{i=k}^{n} x_i = x_k + x_{k+1} + \ldots + x_{K+n-1} + x_{k+n}$$

x representa a variável

i é dito o indexador (índice)

k é o valor inicial do indexador, sendo que o caso especial é quando $k = 1$

n é o valor final do indexador,

Observações:

(1ª) a notação "..." que aparece na definição do somatório significa que a operação de soma deve prosseguir, ou seja, todas as parcelas devem ser somadas.

(2ª) quando não há menção em contrário, o incremento do indexador é igual a 1

Exemplo 1.11: $\sum_{i=1}^{5} i^2 = 1^2 + 2^2 + 3^2 + 4^2 + 5^2 = 55$

Propriedades dos somatórios:

(1ª) $\sum_{i=1}^{n} c = n \times c$, c constante real

(2ª) $\sum_{i=1}^{n} c \times x_i = c \times \sum_{i=1}^{n} x_i$

(3ª) $\sum_{i=1}^{n} (x_i + c) = \sum_{i=1}^{n} x_i + n \times c$

(4ª) $\sum_{i=1}^{n} (x_i + y_i) = \sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i$

1.6 - Resumo de conjuntos de dados

Um conjunto de valores será representado por:

No caso de amostra: $\{x_1, x_2, \ldots, x_n\}$, n é o tamanho da amostra

No caso de população: $\{x_1, x_2, \ldots, x_N\}$ N é o tamanho da população

1.6.1 - Medidas de posição (tendência central)

Média: requer escala de mensuração quantitativa.

Média aritmética

Na amostra:

$$\overline{X} = \frac{x_1 + x_2 + \ldots + x_n}{n} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Na população:

$$\mu = \frac{x_1 + x_2 + \ldots + x_N}{N} = \frac{\sum_{i=1}^{N} x_i}{N}$$

Observação: em uma sequência aritmética (progressão aritmética) o termo central entre dois termos é obtido pela média aritmética. Por exemplo, na P.A $a_n = 5n + 2$, $a_2 = \frac{a_1 + a_3}{2} = \frac{7+17}{2} = 12$.

Exemplo 1.12: um trem de carga apresentou as seguintes velocidades registradas em instantes sucessivos: $\{10 \quad 20 \quad 30 \quad 40 \quad 50\}$. A velocidade do trem segue uma progressão aritmética, ou seja, $v = 10 \times n;\ n \in \{1;2;3;4;5\}$

média aritmética: $\frac{10+20+30+40+50}{5} = 30$

Exemplo 1.13: realizar a soma dos seguintes quocientes, truncando-os em duas casas decimais:

$$\frac{1}{9}+\frac{3}{9}+\frac{4}{9}+\frac{6}{9}+\frac{7}{9}+\frac{8}{9}+\frac{2}{9}+\frac{3}{9}+\frac{2}{9}\simeq$$
$$\simeq 0,11+0,33+0,44+0,66+0,77+0,88+0,22+0,33+0,22=3,96$$

Note que o truncamento em cada divisão resultou em uma resposta diferente daquela se fosse utilizada a fórmula da média aritmética, ou seja:

$$\frac{1+3+4+6+7+8+2+3+2}{9}=\frac{36}{9}=4$$

Além disso, é mais eficiente do ponto de vista computacional utilizar a fórmula da média aritmética.

Média Aritmética ponderada

$$\bar{X}=\frac{\sum_{i=1}^{n} m_i x_i}{\sum_{i=1}^{n} m_i}$$, sendo $m_i>0$ os "pesos"

Exemplo 1.14: Verifique a tabela a seguir, e com base nos dados nela contidos, calcule a média salarial mensal.

Quantidade de Funcionários	Salários / mês (em R$)
15	800,00
3	3.000,00
2	5.250,00
1	12.100,00

Média aritmética ponderada : $\frac{15\times 800+3\times 3000+2\times 5250+1\times 12100}{15+3+2+1}=2076,19$

Se os funcionários confrontassem seus salários e as médias mensais dos seus salários com os outros funcionários, certamente ninguém concordaria com tais valores, tanto os que ganham mais, quanto os que ganham menos. Isso ocorre com a média aritmética porque ela é influenciada por valores extremos. Neste exemplo, o salário de 12100,00 é um valor extremo com relação aos outros.

Exemplo 1.15: interpretação física da média aritmética

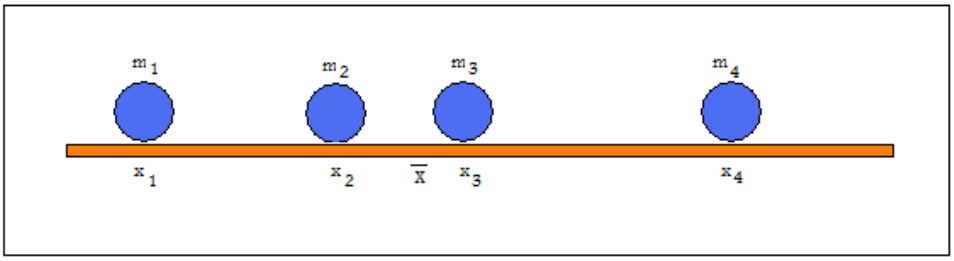

$m_i x_i$ é o momento de massa da i-ésima partícula

$\sum_{i=1}^{n} m_i$ é a massa total

$\sum_{i=1}^{n} m_i x_i$ é o momento de massa do sistema

$\bar{X} = \dfrac{\sum_{i=1}^{n} m_i x_i}{\sum_{i=1}^{n} m_i}$ é o centro de massa do sistema

Média geométrica

$m_g = \sqrt[n]{x_1 \times x_2 \times \ldots \times x_n}$, $x_i > 0$ para todo i

Observação: em uma sequência geométrica (progressão geométrica) o termo central entre dois termos é obtido pela média geométrica. Por exemplo, na PG $a_n = 6 \times 3^n$, $a_2 = \sqrt[2]{a_1 \times a_3} = \sqrt[2]{18 \times 162} = 54$

Exemplo 1.16: no exemplo 1.14 a média geométrica ponderada é

$\sqrt[21]{800^{15} \times 3000^3 \times 5250^2 \times 12100^1} = 1315{,}48$

Exemplo 1.17: um jato apresentou as seguintes velocidades registradas em instantes sucessivos: {30 60 120 240 480}. A velocidade segue uma progressão geométrica, ou seja, $v = 15 \times 2^n$; $n \in \{1;2;3;4;5\}$.

média geométrica = $\sqrt[5]{30 \times 60 \times 120 \times 240 \times 480} = 120$

Exemplo 1.18: a média geométrica é utilizada nas situações envolvendo aumentos sucessivos. Por exemplo, vamos considerar um aumento de salário sucessivo de 15% no primeiro mês, 12% no segundo mês e 21% no terceiro mês. Suponhamos que o salário reajustado seja de R$ 600,00.

$600 \times 1{,}15 = 690$

$600 \times 1{,}15 \times 1{,}12 = 772{,}80$

$600{,}00 \times 1{,}15 \times 1{,}12 \times 1{,}21 = 935{,}09 = 600 \times \left(\sqrt[3]{1{,}15 \times 1{,}12 \times 1{,}21}\right)^3 = 600 \times 1{,}1594^3$

sendo $m_g = \sqrt[3]{1{,}15 \times 1{,}12 \times 1{,}21} = 1{,}1594$

Média harmônica

$$m_h = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}} \qquad x_i > 0 \quad \text{para todo } i$$

Observação: em uma sequência harmônica o termo central entre dois termos é obtido pela média harmônica. Por exemplo: $a_n = \frac{1}{n}$, isto é, {1 1/2 1/3 .....}.

Então, $a_2 = \frac{2}{1+3} = \frac{1}{2}$

Exemplo 1.19

(a) Um navio de carga está se aproximando de um ancoradouro e vem desacelerando da seguinte maneira: { 30 15 10 7,5 6}. A velocidade segue uma sequência harmônica, ou seja, $v = \frac{30}{n}$; $n \in \{1;2;3;4;5\}$.

Média harmônica = $\dfrac{5}{\frac{1}{30}+\frac{1}{15}+\frac{1}{10}+\frac{1}{7,5}+\frac{1}{6}} = 10$

(b) Um veículo faz metade de uma distância d a 30 km/h e a outra a 50 km/h. Qual a velocidade média do veículo?

$$30 = \frac{\frac{d}{2}}{t_1} \Rightarrow t_1 = \frac{d}{2\times 30} \qquad 50 = \frac{\frac{d}{2}}{t_2} \Rightarrow t_2 = \frac{d}{2\times 50}$$

$$v_m = \frac{d}{t_1+t_2} = \frac{\frac{d}{2}+\frac{d}{2}}{\frac{d}{2\times 30}+\frac{d}{2\times 50}} = \frac{2}{\frac{1}{30}+\frac{1}{50}} = 37,5$$

Neste caso, como distância e tempo são inversamente proporcionais, a velocidade média coincide com a fórmula da média harmônica

(c) Um veículo trafega por 30 minutos a uma velocidade de 30 km/h, e por mais 30 minutos trafega a 50 km/h. Qual a velocidade média do veículo?

$d_1 = 0,5\times 30$; $d_2 = 0,5\times 50$

$$v_m = \frac{0,5\times 30 + 0,5\times 50}{0,5+0,5} = \frac{30+50}{2} = 40$$

Neste caso, uma vez que os instantes foram constantes, a velocidade média coincide com a fórmula da média aritmética.

Comparação entre os tipos de médias

(1º) As três médias mantém a seguinte relação entre elas, desde que os valores sejam positivos: $m_h \leq m_g \leq \bar{X}$

(2ª) A média mais conhecida e utilizada é a aritmética, pois sua fórmula é mais simples, além de não ficar restrita a valores positivos. Contudo, valores extremos tendem a superestimar.

A mediana: requer escala de medida ordinal ou quantitativa.

De maneira informal, a mediana de um conjunto **ordenado** de valores, denotada por *Md,* é o ponto que separa o conjunto em dois subconjuntos de mesmo tamanho. Por convenção, o conjunto deve estar ordenado em ordem crescente, sendo $\{x_{[.]}\}$ a amostra após a ordenação. A amostra original pode estar fora de ordem, com relação aos valores da variável, ou seja, pode acontecer que $x_i > x_j$ para algum $i < j$. Na amostra ordenada $x_i \leq x_j$ para quaisquer $i < j$.

Suponha que n seja ímpar:

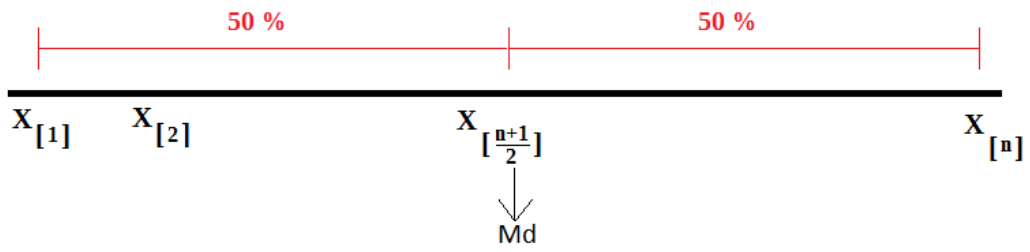

A mediana é única, e será o elemento "do meio" no conjunto.

Agora suponha que n seja par:

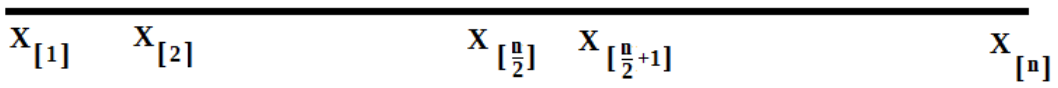

Autores propõem fazer uma interpolação entre $X_{\left[\frac{n}{2}\right]}$ e $X_{\left[\frac{n}{2}+1\right]}$, isto é, $Md = \dfrac{X_{\left[\frac{n}{2}\right]} + X_{\left[\frac{n}{2}+1\right]}}{2}$.

Resumindo,

$$Med = \begin{cases} X_{\left[\frac{n+1}{2}\right]}; & \text{se } n \text{ ímpar} \\ \dfrac{X_{\left[\frac{n}{2}\right]} + X_{\left[\frac{n}{2}+1\right]}}{2}; & \text{se } n \text{ par} \end{cases}$$

Exemplo 1.20:

(a) pesos em kg de cinco pessoas: {66; 62; 60; 70; 58}

Posição	1ª	2ª	3ª	4ª	5ª
Amostra ordenada	58	60	62	66	70

$$\text{Md} = x_{[3]} = 62$$

(b) dez usuários de uma operadora de celular foram inquiridos quanto ao número de chips que possuíam: { 1; 2; 1; 1; 1; 2; 3; 1; 2; 2}

Posição	**1a**	**2a**	**3a**	**4a**	**5a**	**6a**	**7a**	**8a**	**9a**	**10a**
Amostra ordenada	**1**	**1**	**1**	**1**	**1**	**2**	**2**	**2**	**2**	**3**

$$\textbf{Mediana} = \frac{x_{[5]} + x_{[6]}}{2} = \frac{1+2}{2} = 1{,}5$$

(c) alturas em cm de seis pessoas: {180; 165; 175; 182; 177; 160}

Posição	1ª	2ª	3ª	4ª	5ª	6ª
Amostra ordenada	160	165	175	177	180	182

$$\text{Md} = \frac{x_{[3]} + x_{[4]}}{2} = \frac{175+177}{2} = 176$$

A moda

A moda de um conjunto de valores, denotada por M_o, é definida como o valor mais frequente no conjunto. Convém lembrar que a moda pode não ser única, isto é, um conjunto pode ter duas ou mais modas. No caso em que todas as frequências forem iguais diremos que não há moda, embora alguns autores definem como multimodal.

Exemplo 1.21:

(a) dado o conjunto {1; 2; 2; 3; 3; 4; 4; 4; 7; 9; 15} a moda é Mo=4, pois este valor é o mais frequente.

(b) para o conjunto { 1; 1 ; 2 ; 2 ; 2 ; 3 ; 4 ; 4 ; 4} teremos duas modas:

$Mo^1=2$ e $Mo^2=4$

(c)

X	FREQ.
1	1
2	1
3	1
4	1

Não há moda

(d)

X	FREQ.
3	8

Mo=3

(e)

X	FREQ.
RH+	85%
RH-	15%

Mo = RH+

Observação: a mediana exige ordenação das categorias e, por sua vez, é indicada nas seguintes situações:

(1ª) quando se deseja obter o ponto que divide o conjunto em duas partes de mesmo tamanho.

(2ª) quando há resultados extremos que afetariam a Média de maneira acentuada.

Escalas de mensuração e medidas de tendência central

Nominal: moda

Ordinal: moda, mediana

Quantitativa discreta e contínua: moda, mediana e média

1.6.2 - Medidas de dispersão (variabilidade)

Observação: As medidas de dispersão requer escala quantitativa

Amplitude: a medida de dispersão mais simples, porém "rústica", é a amplitude, anotada por "h", e definida como a diferença entre os valores extremos do conjunto, isto é:

$$h = x_{max} - x_{min} \geq 0$$

Variância e o desvio padrão absolutos

As medidas mais utilizadas são a variância e o desvio padrão. Estas medidas têm como ponto de referência a média aritmética.

Variância absoluta:

$$S^2=\frac{(x_1-\bar{X})^2+(x_2-\bar{X})^2+\ldots+(x_n-\bar{X})^2}{n-1}=\frac{\sum_{i=1}^{n}(x_i-\bar{X})^2}{n-1}$$

A variância é a soma dos quadrados das distâncias em relação à $\bar{X}$

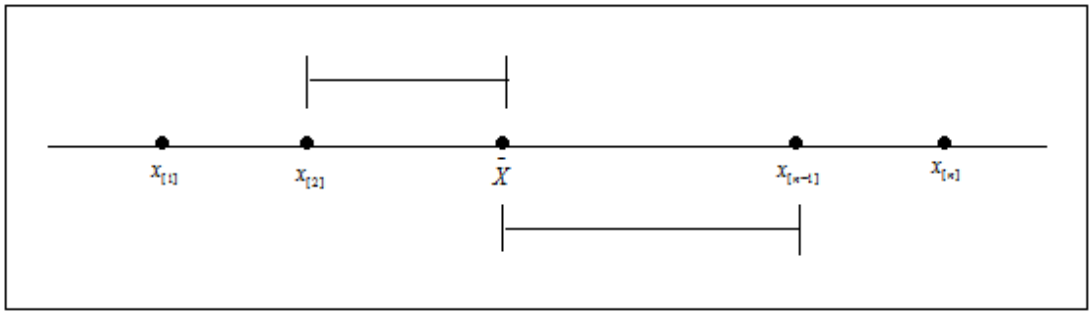

Comparação de três amostras com mesma média aritmética

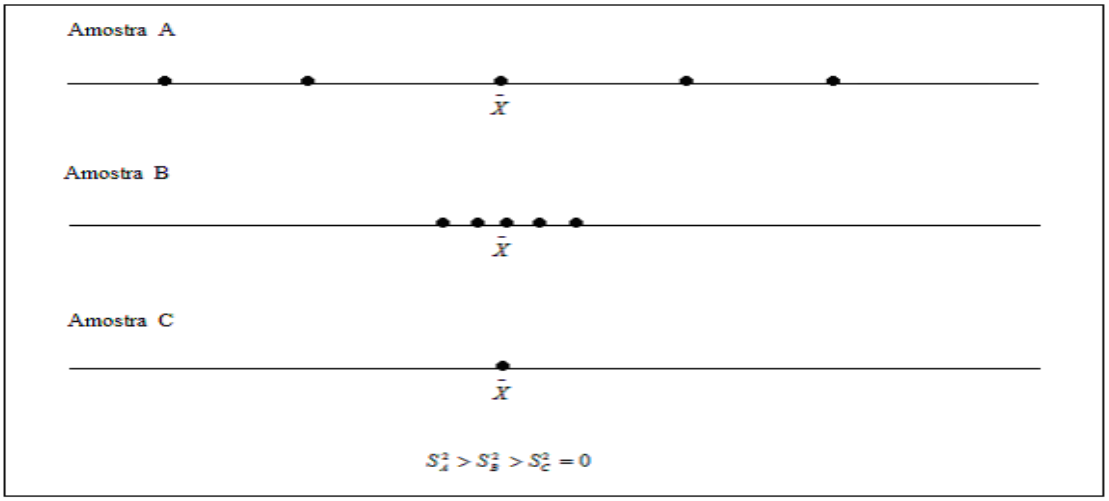

Pode-se mostrar que $\sum_{i=1}^{n}(X_i-\bar{X})^2=\left(\sum_{i=1}^{n}X_i^2\right)-n\times(\bar{X})^2$. Assim, há uma fórmula alternativa para a variância, ou seja, $S^2=\frac{\left(\sum_{i=1}^{n}X_i^2\right)-n\times(\bar{X})^2}{n-1}$.

A variância, por ser um quadrado, não permite comparações com a unidade que estamos trabalhando. Para ter uma medida de variabilidade com a mesma unidade da variável, utiliza-se a raiz quadrada da variância, denominada de **desvio padrão**.

Desvio padrão absoluto: $S=\sqrt{S^2}$

Observações:

(1ª) variância e desvio padrão são não negativos.

(2ª) a versão de variância $V^2=\frac{\sum_{i=1}^{n} x_i^2}{n}-(\bar{X})^2$ é uma medida enviesada, por isso, utiliza-se S^2, a qual é uma correção de V^2.

(3ª) $S^2=\frac{n}{n-1}\times V^2$, e para amostras suficientemente grandes $V^2\approx S^2$.

(4ª) o desvio padrão mede o grau de dispersão dos valores em torno da média, ou seja, é variabilidade média (em unidades de medida) em torno da média aritmética.

(5ª) para julgar se há "pouca" ou "muita" variação, o usuário tem que ter um conhecimento sobre a variável estudada.

Exemplo 1.22: {17 18 19 18 22 24 26 18 21} é uma amostra das idades dos ingressantes numa faculdade.

$$\sum x=183\,;\sum x^2=3799 \quad ; \quad \bar{X}=\frac{183}{9}=20,3333$$

$$S^2=\frac{\left[17^2+3\times 18^2+19^2+21^2+22^2+24^2+26^2\right]-9\times\left(\frac{183}{9}\right)^2}{8}=9,75 \qquad S=3,1225$$

Note que cada observação pode ser escrita em função da média e do desvio padrão, por exemplo:

$$26=20,3333+k\times 3,1225\Rightarrow k=1,81$$

$$17=20,3333+k\times 3,1225\Rightarrow k=-1,07$$

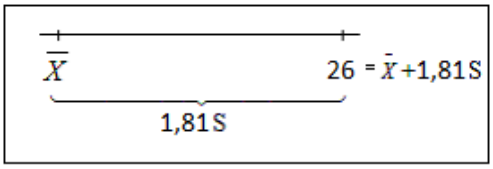

Coeficiente de variação

O coeficiente de variação, também chamado de desvio padrão relativo, é dado por:

$$CV = \frac{S}{|\bar{X}|} \times 100\% \quad , \quad \bar{X} \neq 0$$

Observação: o coeficiente de variação é interpretado como o grau de variabilidade relativa em torno da média.

Exemplo 1.23: em relação ao exemplo anterior,

$$CV = \frac{3,1225}{20,3333} \times 100\% = 15,3566\%$$

Observações:

(1ª) Após calcular a variância surge um problema: o que fazer com o valor obtido? A variância, por ter como unidade de medida o quadrado, pode não ter uma interpretação. Já o desvio padrão fica na mesma unidade de medida da variável. Mesmo assim, o que significa o valor do desvio padrão? Como julgar se há "pouca" ou "muita" variação? Não existe uma regra que permita responder! Dependerá mais da unidade de medida da variável. Por isso, o usuário tem que ter conhecimento sobre a variável analisada. No exemplo 1.22 o desvio padrão foi de 3,1225 anos. Este valor indica pouca ou muita variação? Difícil julgar!

(2ª) Alternativa é o coeficiente de variação, o qual é uma medida relativa. Mesmo assim, também não existe uma regra para julgar a variabilidade. No exemplo 1.23, CV=15,3566%. Esse valor é pequeno ou alto? Também dependerá da unidade de medida para fazer este julgamento! Há casos em que fica evidente, por exemplo, se CV=1%, maioria das pessoas diria que é pouca variação. Por outro lado, CV=120%, sem dúvida responderiam que é elevada variação em torno da média. Mas um CV=30% dividiria as opiniões.

Exemplo 1.24 (o problema do truncamento de números): os valores seguintes são espessuras em mm de chapas de alumínio: { 6,34 6,38 6,40 6,38 6,36 6,36 6,38 6,20 6,42 6,28}. Obtenha média, desvio padrão e coeficiente de variação.

Solução: $n = 10$ $\quad \sum x = 63,5$ $\quad \sum x^2 = 403,2628$

$$\bar{X} = 6,35 \;;\quad S^2 = 0,0042 \;;\quad S = 0,064807 \;;\quad CV = 1,020589\%$$

Se o valor do somatório dos quadrados for arredondado para décimos, então:

$S^2 = \frac{403,3 - 10 \times (6,35)^2}{9} = 0,008333$; $S = 0,09128709$ $\quad CV = 1,437592\%$, que é diferente do resultado sem fazer arredondamento. Se arredondar para $\bar{X} = 6,4$, então $S^2 = \frac{403,3 - 10 \times (6,4)^2}{9} = -0,7$, que é impossível (lembre que $S^2 \geq 0$).

Propriedades das Medidas

Seja $\{x_1, x_2, \ldots, x_n\}$ uma amostra, onde foi observada a variável X

(1ª) $x_i = c;\ c \in \mathbb{R}$, $\bar{X} = c$ e $S_X^2 = 0$

(2ª) $y_i = (x_i + c); c \in \mathbb{R}$, $\bar{Y} = \bar{X} + c$ e $S_Y^2 = S_X^2$

(3ª) $y_i = (c\, x_i); c \neq 0$, $\bar{Y} = c\, \bar{X}$ e $S_Y^2 = c^2 S_X^2$

(4ª) $y_i = (c\, x_i + b); c \neq 0; b \in \mathbb{R}$, $\bar{Y} = c\, \bar{X} + b$ e $S_Y^2 = c^2 S_X^2$

(5ª) $y_i = \dfrac{x_i - \bar{X}}{S}$ é dita padronização da variável, e é relativa, além de $\bar{Y} = 0\ ; S_Y^2 = 1$

(6ª) $min \leq m_h \leq m_g \leq \bar{X} \leq max$

$$0 \leq S^2 \leq \left(\frac{n}{n-1}\right) h^{2,}; h = max - min$$

(7ª) amostra A: $\{x_{1,} \ldots x_n\}$

amostra B: $\{x_{n+1}, \ldots, x_{n+m}\}$

média ponderada: $\bar{X}_p = \dfrac{n \times \bar{X}_A + m \times \bar{X}_B}{n+m}$

variância ponderada: $S_p^2 = \dfrac{(n-1) \times S_A^2 + (m-1) \times S_B^2}{n+m-2}$

1.7 - Distribuições de frequências

Para se trabalhar com grandes conjuntos de dados é necessário inicialmente agrupá-los. O agrupamento é feito em tabelas, denominadas de distribuições de frequências.

1.7.1 - Distribuições de frequências por ponto (ou valores)

Exemplo 1.25: peso de 27 embalagens de cereal em decigramas

31,5 32,5 32,5 32,5 32,5 32,5 33,5 33,5 33,5 33,5 33,5 33,5 33,5 33,5 33,5 33,5
33,5 34,5 34,5 34,5 34,5 34,5 34,5 34,5 34,5 35,5 35,5

Distribuição de frequências por ponto

x_i	frequência (f_i)	$x_i \times f_i$	$x_i^2 \times f_i$
31,5	1	31,5	992,25
32,5	5	162,5	5281,25
33,5	11	368,5	12344,75
34,5	8	276	9522
35,5	2	71	2520,5
Total	27	909,5	30660,75

Medidas de tendência central e dispersão: no caso de uma tabela de distribuição de frequência por ponto as fórmulas ficam:

$$\bar{X} = \frac{\sum_{i=1}^{k} x_i \times f_i}{\sum_{i=1}^{k} f_i} = \frac{\sum_{i=1}^{k} x_i \times f_i}{n} \qquad S^2 = \frac{\sum_{i=1}^{k} x_i^2 \times f_i - n\left(\bar{X}\right)^2}{n-1}$$

sendo f_i a frequência absoluta (ou simples), que é o número de vezes que ocorre o valor x_i, e k o número de valores distintos no conjunto.

Observação: as outras medidas: mediana, moda, desvio padrão e coeficiente de variação, têm as mesmas fórmulas.

Exemplo 1.26: em relação ao exemplo acima,

$\bar{X} = \frac{909,5}{27} = 33,6852$; Mo=33,5; Mediana=33,5

$S^2 = \frac{30660,75 - 27 \times (33,6852)^2}{26} = 0,9250$; $S = 0,9617$; CV=2,8566%.

1.7.2 - Distribuições de frequências por classes (ou intervalos)

Ao construirmos a distribuição de frequências por classes haverá perda de informação, mas haverá uma melhor organização na apresentação e compreensão, como ilustra o exemplo 1.27.

Algoritmo para a construção de uma tabela de distribuição frequências por intervalos

(1º) Determinar a amplitude dos dados: $h = x_{max} - x_{min}$.

(2º) Decidir sobre o número de classes k a ser utilizado. Recomenda-se um número de classes entre 5 e 15. Para que a decisão não seja totalmente arbitrária, pode-se usar a raiz quadrada do número de valores, ou seja, $k = \sqrt{n}$, ou $k = \ln(n)$. ou a fórmula de Sturgs $k = 1 + 3{,}322 \log(n)$.

(3º) Determinar a amplitude de cada classe. Sempre que possível manter todas as amplitudes iguais. Para tanto, deve-se dividir a amplitude dos dados "h" pelo número de classes "k", arredondando para mais, ou seja, $h_i \simeq \frac{h}{k}$.

(4º) Contar o número de valores pertencentes a cada classe. As classes devem ser disjuntas (sem intersecção). Em geral, utiliza-se a notação (|---), para indicar um intervalo fechado à esquerda e aberto à direita. Também poderia ser utilizado o intervalo aberto à esquerda e fechado à direita (---|), aberto de ambos os lados (---) ou ainda fechado de ambos os lados (|---|).

Elementos de uma tabela de distribuição de frequências por intervalos

Intervalos	x_i	f_i	F_i	fr_i	Fr_i	$x_i \times f_i$	$x_i^2 \times f_i$
l_1 |------- L_1	x_1	f_1	F_1	fr_1	Fr_1	$x_1 \times f_1$	$x_1^2 \times f_1$
l_2 |------- L_2	x_2	f_2	F_2	fr_2	Fr_2	$x_2 \times f_2$	$x_2^2 \times f_2$
l_k |------- L_k	x_k	f_k	n	fr_k	1	$x_k \times f_k$	$x_k^2 \times f_k$
Total	----	n	----	1	----	$\sum x_i \times f_i$	$\sum x_i^2 \times f_i$

k é o número de classes

l_i é o limite inferior de classe

L_i é o limite superior de classe

$x_i = \frac{l_i + L_i}{2}$ é o ponto médio de classe

$h_i = L_i - l_i$ é a amplitude de classe

f_i é a frequência absoluta de classe

F_i é a frequência acumulada de classe, ou seja,

$F_1 = f_1$, $F_i = f_i + F_{i-1}$, para $i \geq 2$

fr_i é a frequência relativa de classe, isto é, $fr_i = \frac{f_i}{n}$

Fr_i é a frequência relativa acumulada de classe, ou seja,

$Fr_1 = fr_1$; $Fr_2 = fr_1 + fr_2$; .....; $Fr_k = fr_1 + fr_2 + \cdots + fr_k = 1$

Exemplo 1.27: diâmetro de eixos de veículos agrícolas em cm.

x	1,00	1,02	1,04	1,05	1,06	1,07	1,08	1,09	1,10	1,11	1,12	1,13	1,14	1,15	1,16	1,17	1,18
f	1	1	1	14	8	8	6	6	5	9	8	9	5	6	6	6	5
x	1,19	1,20	1,21	1,22	1,23	1,24	1,25	1,26	1,27	1,28	1,29	1,30	1,31	1,32	1,33	1,34	1,35
f	3	2	6	6	4	4	3	3	3	5	2	2	2	1	1	1	1
x	1,36	1,37	1,39														
f	1	1	1														

Tabela de distribuição de frequências com 8 classes

Diâmetros	x_i	f_i	F_i	Percentual	$x_i \times f_i$	$x_i^2 \times f_i$
1,00 |— 1,05	1,025	3	3	1,92	3,075	3,151875
1,05 |— 1,10	1,075	42	45	26,92	45,15	48,53625
1,10 |— 1,15	1,125	36	81	23,08	40,5	45,5625
1,15 |— 1,20	1,175	26	107	16,67	30,55	35,89625
1,20 |— 1,25	1,225	22	129	14,10	26,95	33,01375
1,25 |— 1,30	1,275	16	145	10,26	20,4	26,01
1,30 |— 1,35	1,325	7	152	4,49	9,275	12,289375
1,35 |— 1,40	1,375	4	156	2,56	5,5	7,5625
Total	--------	156	--------	100	181,4	212,0225

O ponto médio de um intervalo é $x_i = \frac{l_i + L_i}{2}$, seja para intervalo aberto ou fechado.

Lembre que a notação |------- significa fechado à esquerda e aberto à direita. Para o 1º intervalo o ponto médio é $x_1 = \frac{1+1{,}05}{2} = 1{,}025$. O número de observações no intervalo 1|------ 1,05 é $f_1 = 3$. A coluna das frequências acumuladas inicia com $F_1 = f_1 = 3$. Depois $F_2 = F_1 + f_2 = 3 + 42 = 45$ e assim até que $F_8 = F_7 + f_8 = 152 + 4 = 156$

Observações:

(1ª) Deve-se evitar tabelas com frequências zero ou 1. Se isto ocorrer, aglutine com outro intervalo.

Intervalo	frequência
a ⊢— b	1
b ⊢— c	1
c ⊢— d	1
d ⊢— e	0

→

Intervalo	frequência
a ⊢— e	3

(2ª) Comumente encontramos tabelas com intervalos de mesma amplitude, pois assim facilita os cálculos. Também é comum intervalos fechados à esquerda e abertos à direita.

Medidas de tendência central e dispersão

No caso de uma tabela de distribuição de frequência por intervalos as fórmulas para média e variância ficam as mesmas do caso de distribuições por ponto, exceto que onde tiver x_i você deve utilizar o ponto médio de classe.

Na fórmula da média e variância para dados agrupados em intervalos utilizamos o ponto médio $x_i = \frac{l_i + L_i}{2}$. Fazendo isto, haverá uma aproximação para a média e variância, ou seja, as medidas serão diferentes daquelas feitas com os dados originais. No exemplo 30 será visto que as medidas para a distribuição por intervalo resultam diferentes daquelas feitas com os dados originais.

As fórmulas da mediana e moda também são aproximações feitas por interpolação.

Mediana: para localizar a classe mediana procuramos na coluna das frequências absolutas acumuladas a primeira F_i tal que $F_i \geq \frac{n}{2}$.

$$\text{Md} = l_m + h_m \times \left[\frac{\frac{n}{2} - F_{m-1}}{f_m} \right]$$

l_m o limite inferior da classe mediana

h_m a amplitude da classe mediana

f_m a frequência simples da classe mediana

F_{m-1} a frequência acumulada da classe anterior à mediana

Moda pelo processo de King: o primeiro passo é localizar a classe modal, aquela com maior frequência absoluta. Se houver mais de uma classe modal então a fórmula da moda é aplicada em cada classe modal.

$$\text{Moda} = l_m + h_m \times \left[\frac{f_{m+1}}{f_{m+1} + f_{m-1}} \right]$$

l_m é o limite inferior da classe modal

h_m é a amplitude da classe modal

f_{m+1} é a frequência simples da classe posterior à modal

f_{m-1} é a frequência simples da classe anterior à modal

Exemplo 1.28: com relação ao exemplo anterior, para a tabela com 8 classes:

$$\bar{X} = \frac{181,4}{156} = 1,1628$$

$$S^2 = \frac{212,0225 - 156 \times (1,1628)^2}{156 - 1} = 0,00712$$

$S = 0,0837$; $C.V = 7,2013\%$

Uma vez que $81 > \frac{n}{2} = 78$ então a classe mediana é 1,10|-------1,15.

Aplicando a fórmula: $Md = 1,10 + 0,05 \times \left(\frac{78 - 45}{36} \right) = 1,1458$

A classe modal é 1,05|-------1,10, pois tem maior frequência absoluta. Pelo processo de King,

$$Mo = 1,05 + 0,05 \times \left(\frac{36}{36 + 3} \right) = 1,096 \quad .$$

Conclusão: $Mo < Med < \bar{X}$ devido à forma assimétrica à direita da distribuição.

Medidas	Observações originais	8 classes	10 classes
Média	1,1561	1,1608	1,1600
Variância	0,00772	0,00737	0,006498
Desvio padrão	0,0855	0,0837	0,0806
CV	7,3998%	7,2013%	6,04918%
Mediana	1,14	1,1458	1,1471
Moda	1,05	1,096	1,1374

Histograma para a distribuição de frequências do exemplo 1.28

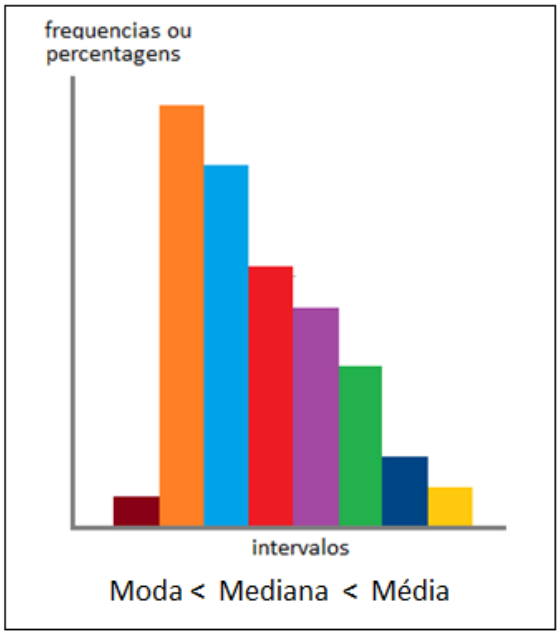

2ª Parte - Fundamentos da Probabilidade

2.1 - Objeto de estudo da Teoria da Probabilidade

A Teoria da Probabilidade tem como objeto de estudo os fenômenos aleatórios. No dicionário Michaelis da língua portuguesa "aleatório" tem o sentido de eventual, fortuito, incerto.

Fenômenos determinísticos: o resultado observado é determinado pelas condições sob as quais o fenômeno ocorreu.

Exemplo 2.1 (fenômeno determinístico): sempre que um corpo descreve uma trajetória circular, a força centrípeta é dada, a cada instante, pela resultante das forças que atuam no corpo, na direção do raio da trajetória. O globo da morte exemplifica a atuação da força centrípeta.

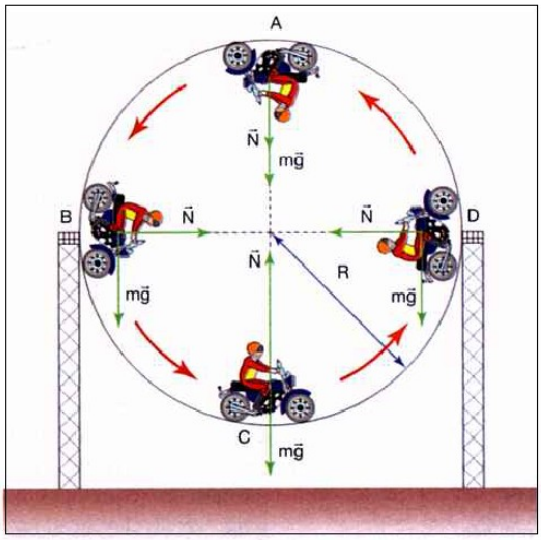

2.2 - Modelos Determinísticos:

$F = m \times v^2$, sendo F a força resultante, m a massa do corpo e v a velocidade

$E = m \times c^2$, sendo E energia, c a velocidade da luz

Fenômenos aleatórios: o resultado não é determinado pelas condições de realização do fenômeno.

Exemplo 2. 2: tempo de duração de uma lâmpada fluorescente

3.3 - Modelos Probabilísticos

Modelos probabilísticos são modelos matemáticos que descrevem fenômenos aleatórios. Experimentos aleatórios são fenômenos aleatórios executados por nós.

Exemplo 2.3 (Exemplos de Experimentos Aleatórios):

EX1: Jogue um dado e observe o nº da face de cima

EX2: Jogue uma moeda 3 vezes e observe o nº de caras

EX3: Jogue uma moeda 3 vezes e observe as sequências de faces

EX4: no. de peças defeituosas em um lote contendo N itens

EX5: tempo de duração de uma lâmpada até esta queimar

EX6: lance uma moeda até que ocorra a face cara pela primeira vez

Espaço Amostral: é o conjunto de todos os resultados possíveis de um experimento aleatório.

Notação: Ω , $\varpi \in \Omega$.

Exemplo 2.4 (Exemplos de espaços amostrais): com relação aos exemplos anteriores,

$\Omega_1 = \{1,2,3,4,5,6\}$

$\Omega_2 = \{0,1,2,3\}$

Ω_3 ={KKK, CCC, KKC, KCK, CKK, CCK, CKC, KCC}
C ≡"cara" K ≡"coroa"

$\Omega_4 = \{0,1,2,....,N\}$

$\Omega_5 = \{t \in \mathbb{R} : t \geq 0\}$

Ω_6 = { C, KC, KKC, KKKC, ...}

2.4 - Tipos de espaços amostrais

Finito: $\Omega_1; \Omega_2; \Omega_3; \Omega_4$
Infinito enumerável: Ω_6
Não enumerável: Ω_5

Evento: é um subconjunto do espaço amostral.

Notação: $A \subset \Omega, \quad B \subset \Omega, \quad C \subset \Omega,$

Observação: Ω é dito evento certo e $\varnothing$ evento impossível.

Tipos de eventos:

Simples: formado por um único elemento do espaço amostral.

Composto: é a combinação de dois ou mais elementos do espaço amostral.

Exemplo 2.5: considere um baralho padrão de 52 cartas, ou seja, 9 números e 4 figuras, cada um com 4 naipes.

Ás (vale 1 em alguns tipos de jogos)
2; 3; 4; 5; 6; 7; 8; 9; 10
J = 11; Q = 12 ; K =13

Naipes: copas paus espada ouro

Uma carta é retirada ao acaso e anota-se seu número e naipe. Escreva: os seguintes eventos:

A: "ocorre naipe de ouro"
B: "ocorre número ímpar"
C: "ocorre número par"
D: "ocorre 7 de ouro"

Solução:

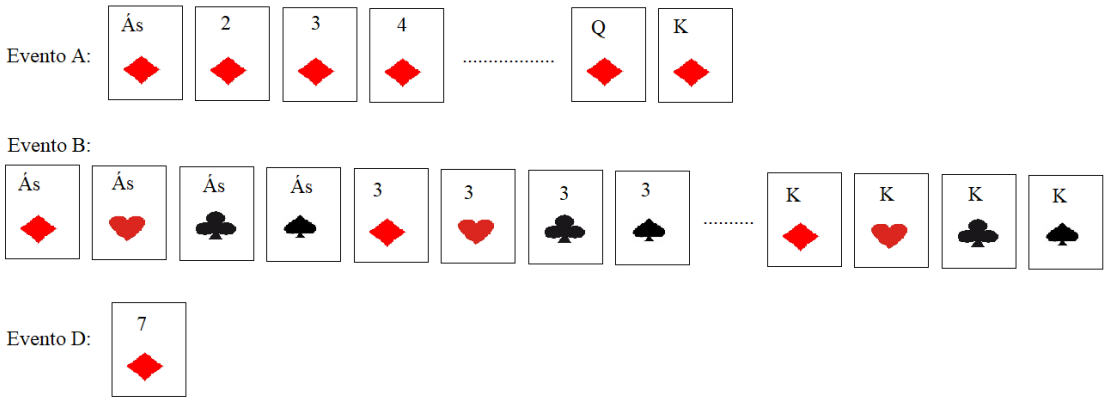

2.5 - Operações com eventos

Seja Ω um espaço amostral e A,B eventos. Então, as seguintes operações com eventos são definidas:

(1º) Evento união:

$A \cup B$: " ocorre somente A, ou ocorre somente B, ou ocorrem ambos"

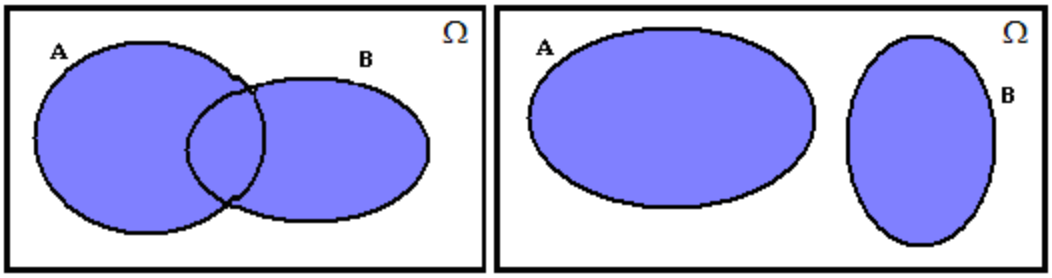

(2º) Evento intersecção:

$A \cap B$: "ocorre A e B simultaneamente"

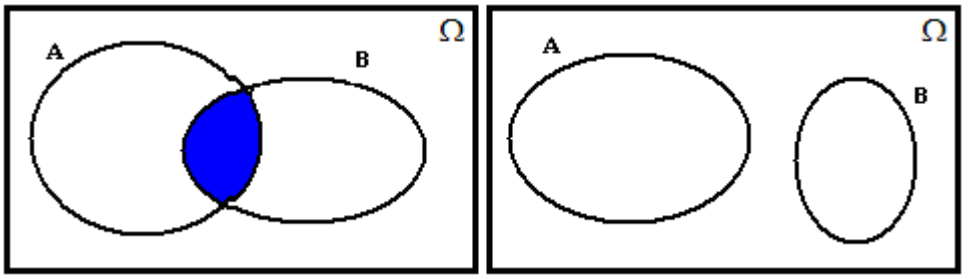

(3º) evento complementar: A^c : "não ocorre A"

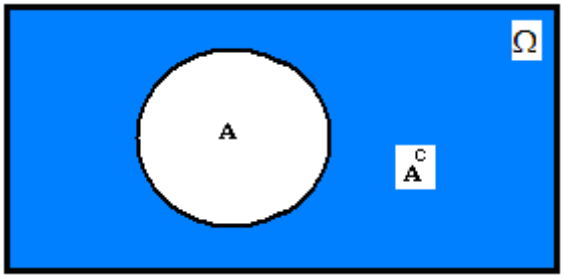

(4º) evento diferença: $A - B$: "ocorre A e não B"

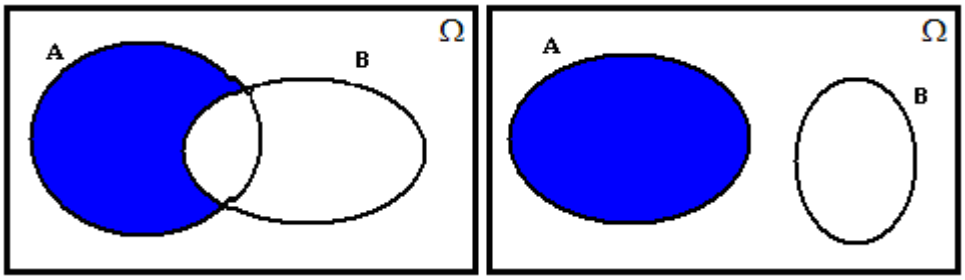

Observação: $A-B=B^c\cap A$; $A-B=A-A\cap B$; $A=(A\cap B)\cup(B^c\cap A)$

Alguns resultados sobre a teoria dos conjuntos

(1º) $A\cup A=A$, $A\cap A=A$

(2º) Propriedade distributiva: $A\cup(B\cap C)=(A\cup B)\cap(A\cup C)$, $A\cap(B\cup C)=(A\cap B)\cup(A\cap C)$

(3º) $\Omega\cup A=\Omega$, $\Omega\cap A=A$

$\emptyset\cup A=A$, $\emptyset\cap A=\emptyset$

(4º) $(A\cap B)^c=A^c\cup B^c$, $(A\cup B)^c=A^c\cap B^c$

Considere três eventos A,B,C

Sentença	Em notação de conjuntos
(1ª) Nenhum ocorre	$(A^c\cap B^c\cap C^c)=(A\cup B\cup C)^c$
(2ª) Somente um ocorre	$(A\cap B^c\cap C^c)\cup(A^c\cap B\cap C^c)\cup(A^c\cap B^c\cap C)$
(3ª) Somente dois ocorrem	$(A\cap B\cap C^c)\cup(A\cap B^c\cap C)\cup(A^c\cap B\cap C)$
(4ª) Todos ocorrem	$(A\cap B\cap C)$
(5ª) Pelo menos um ocorre	$(A\cup B\cup C)=(A^c\cap B^c\cap C^c)^c$
(6ª) Pelo menos dois ocorrem	união (3ª) com (4ª)
(7ª) Pelo menos três ocorrem	equivale a (4ª)
(8ª) No máximo um ocorre	união de (1ª) com (2ª)
(9ª) No máximo dois ocorrem	união de (1ª), (2ª) e (3ª)
(10ª) No máximo três ocorrem	união de (1ª), (2ª), (3ª) e (4ª)

Eventos exclusivos: *A, B* são mutuamente exclusivos se $A\cap B=\emptyset$.

Eventos não exclusivos: se $A\cap B\neq\emptyset$.

Definição: Seja uma sequência de eventos $A_1, A_2,....\subset\Omega$. Os eventos $\{A_1, A_2,....\}$ são mutuamente exclusivos (disjuntos), dois a dois, se e somente se $A_i\cap A_j=\emptyset$, para $i\neq j$.

Definição: uma união de eventos *A, B* tais que $A\cap B=\emptyset$ é dita união disjunta.

Exemplo 2.6: lance dois dados e observe as faces. Enumere:

Ω

A: "face do 1º dado é menor ou igual que a do 2º "

B: "a soma das faces é menor ou igual a 6"

C: "a face do 1º dado é ímpar"

D: "a face do 2º dado é igual ao dobro da face do 1º "

$A \cap B$; $A \cup B$; D^c

Solução:

Cada elemento do espaço amostral é da forma: (_____ _____)
1º dado 2º dado

O experimento de lançar 2 vezes o mesmo dado também tem o mesmo espaço amostral , sendo que cada elemento é da forma : (_____ _____)
1º lanç 2º lanç

$$\Omega = \left\{ \begin{matrix} (1,1);(1,2);(1,3);(1,4);(1,5);(1,6) \\ (2,1);(2,2);(2,3);(2,4);(2,5);(2,6) \\ (3,1);(3,2);(3,3);(3,4);(3,5);(3,6) \\ (4,1);(4,2);(4,3);(4,4);(4,5);(4,6) \\ (5,1);(5,2);(5,3);(5,4);(5,5);(5,6) \\ (6,1);(6,2);(6,3);(6,4);(6,5);(6,6) \end{matrix} \right\}$$

$$A = \left\{ \begin{matrix} (1,1);(1,2);(1,3);(1,4);(1,5);(1,6);(2,2) \\ (2,3);(2,4);(2,5);(2,6);(3.3);(3,4);(3,5) \\ (3,6);(4,4);(4,5);(4,6)(5,5);(5,6);(6,6) \end{matrix} \right\} = \{(x, y) \mid x \leq y\}$$

$$B = \left\{ \begin{matrix} (1,1);(1,2);(1,3);(1,4);(1,5) \\ (2,1);(2,2);(2,3);(2,4);(3,1) \\ (3,2);(3,3);(4,1);(4,2);(5,1) \end{matrix} \right\} = \{(x, y) \mid x + y \leq 6\}$$

$$C = \left\{ \begin{matrix} (1,1)(1,2)(1,3)(1,4)(1,5)(1,6) \\ (3,1)(3,2)(3,3)(3,4)(3,5)(3,6) \\ (5,1)(5,2)(5,3)(5,4)(5,5)(5,6) \end{matrix} \right\}$$

$$D = \{(1,2);(2,4);(3,6)\} = \{(x, y) \mid y = 2x\} \; ; \quad D^c = \Omega - \{(1,2);(2,4);(3,6)\}$$

$$A \cap B = \{(1,1);(1,2);(1,3);(1,4);(1,5);(2,2);(2,3);(2,4);(3.3)\}$$

$$A \cup B = \left\{ \begin{matrix} (1,1);(1,2);(1,3);(1,4);(1,5);(1,6);(2,1);(2,2);(2,3) \\ (2,4);(2,5);(2,6);(3,1);(3,2)(3.3);(3,4);(3,5);(3,6) \\ (4,1);(4,2);(4,4);(4,5);(4,6);(5,1);(5,5);(5,6);(6,6) \end{matrix} \right\}$$

$$A - B = \{(1,6);(2,5);(2,6);(3,4);(3,5);(3,6);(4,4)(4,5);(4,6);(5,5);(5,6);(6,6)\}$$

2.6 - Concepções de Probabilidade

Observações:

(1ª) P(A) lemos como a "probabilidade do evento A".

(2ª) Uma probabilidade não tem unidade de medida. É um grau entre 0 e 1 (ou 0% e 100%).

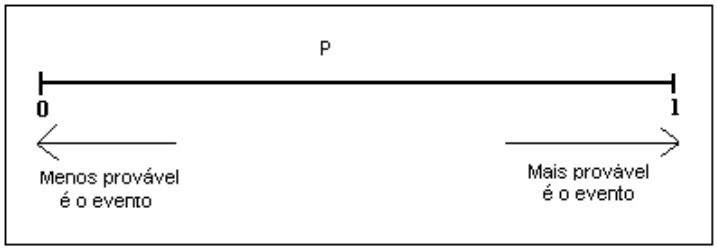

A concepção clássica de probabilidade: todos resultados possíveis do experimento

são igualmente prováveis.

$P(\varpi) = \frac{1}{N}$, $\varpi \in \Omega$ e N sendo o número de elementos de Ω

$P(A) = \frac{a}{N}$, sendo a o número de elementos do evento A

Observação: concepção clássica de probabilidade é válida somente para espaços amostrais finitos.

Exemplo 2.7: com relação ao exemplo 2.6,

$$P(1) = P(2) = ... = P(6) = \frac{1}{6}$$

$$P(A) = \frac{21}{36}; P(B) = \frac{15}{36}; P(C) = \frac{18}{36}; P(D) = \frac{3}{36}$$

$$P(A \cap B) = \frac{9}{36}; P(A \cup B) = \frac{27}{36}; P(A - B) = \frac{12}{36}$$

A concepção frequencista de probabilidade: a probabilidade de um evento é medida observando-se a frequência relativa do mesmo em uma sucessão de realizações do experimento. A frequência relativa é definida como: $f_r^{(n)}(A) = \frac{r^{(n)}(A)}{n}$,

$r^{(n)}(A)$ é o número de ocorrências do evento A até n realizações do experimento. A frequência relativa é um número entre zero e 1. A probabilidade do evento A será $P(A)=\lim_{n\to\infty} f_r^{(n)}(A)$, se o limite existir, ou seja, se a sequência $\{f_r^{(n)}(A): n\geq 1\}$ convergir.

Exemplo 2.8 : Resultados de lançamentos de uma moeda equilibrada. O evento A é ocorreu a face cara.

n	Resultado	$r^{(n)}(A)$	$f_r^{(n)}(A)$
1	C	1	1
2	C	2	1
3	K	2	2/3
4	C	3	3/4
5	C	4	4/5
6	K	4	4/6
7	K	4	4/7
8	C	5	5/8
9	K	5	5/9
10	K	5	5/10
11	C	6	6/11

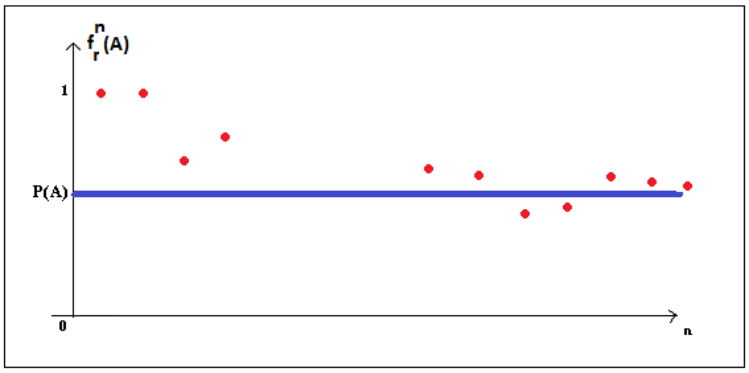

A concepção axiomática de probabilidade: construção de uma teoria matemática para as probabilidades, com base em "axiomas".

Exemplo 2.9: axiomática de Kolmogorov

Axiomas da Teoria das Probabilidades (Kolmogorov)

Uma medida é dita probabilidade se e somente se:

(1) $P(A)\geq 0$ para todo $A\subset\Omega$

(2) $P(\Omega)=1$

(3) $P(A_1\cup A_2\cup\ldots)=P(A_1)+P(A_2)+\ldots$, se $A_1, A_2\ldots$.estiverem contidos em Ω e forem disjuntos dois a dois.

2.7 - Propriedades das Probabilidades

As propriedades a seguir decorrem imediatamente dos axiomas:

(1ª) $P(A^c)=1-P(A)$

prova: $\Omega = A\,U\,A^c \Rightarrow P(\Omega)=P(A)+P(A^c) \Rightarrow 1=P(A)+P(A^c) \Rightarrow P(A^c)=1-P(A)$

(2ª) $P(\emptyset)=0$

prova: $P(\emptyset)=P(\Omega^c)=1-P(\Omega)=1-1=0$

(3ª) Se $A \subseteq B$ então $P(A) \leq P(B)$ e $P(B-A)=P(B)-P(A)$

Como $(A \cap B) \subset A, (A \cap B) \subset B$, $P(A-(A \cap B))=P(A)-P(A \cap B)$ e
$P(B-(A \cap B))=P(B)-P(A \cap B)$

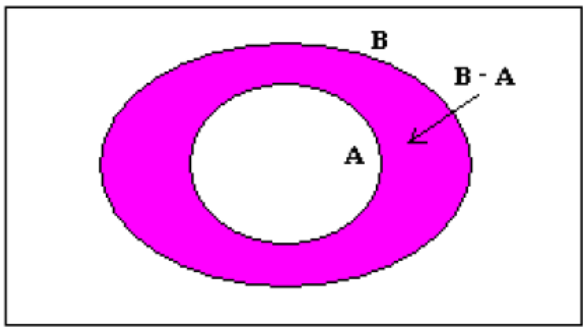

(4ª) $P(A) \leq 1$

prova: $A \subseteq \Omega$. Pela (3ª) propriedade, $P(A) \leq P(\Omega)=1$

(5ª) Para *A, B* eventos quaisquer $P(A \cup B)=P(A)+P(B)-P(A \cap B)$

(6ª) Para *A, B, C* eventos quaisquer

$$P(A \cup B \cup C)=P(A)+P(B)+P(C)-P(A \cap B)-P(A \cap C)-P(B \cap C)+P(A \cap B \cap C)$$

Exemplo 2.10: uma peça produzida pode apresentar defeito tipo A com probabilidade p, tipo B com probabilidade q e ambos defeitos com probabilidade r. Qual a probabilidade ?

(a) Apresentar pelo menos um defeito (b) Não apresentar nenhum dos defeitos

(c) Apresentar apenas um dos defeitos

Solução: $0<p,q<1$ e $0<r<p,q$

(a) $P(A\cup B)=P(A)+P(B)-P(A\cap B)=p+q-r$

(b) $P\left((A\cup B)^c\right)=1-P(A\cup B)=1-p-q+r$

(c) $P((A\cap B^c)\cup(A^c\cap B))=(P(A)-P(A\cap B))+(P(B)-P(A\cap B))=$
$=p-r+q-r=p+q-2r$

2.8 - Métodos de enumeração

Princípio da multiplicação: tarefas realizadas sequencialmente, isto é, o número das possíveis maneiras é $n_1\times n_2\times\cdots\times n_k$

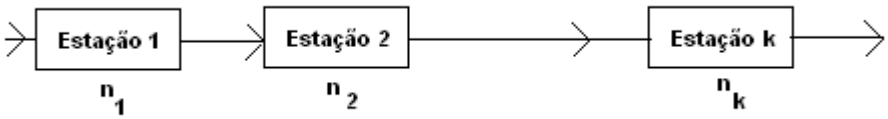

Princípio da adição: tarefas realizadas de forma mutuamente exclusivas, isto é, isto é, o número das possíveis maneiras é $n_1+n_2+\cdots+n_k$

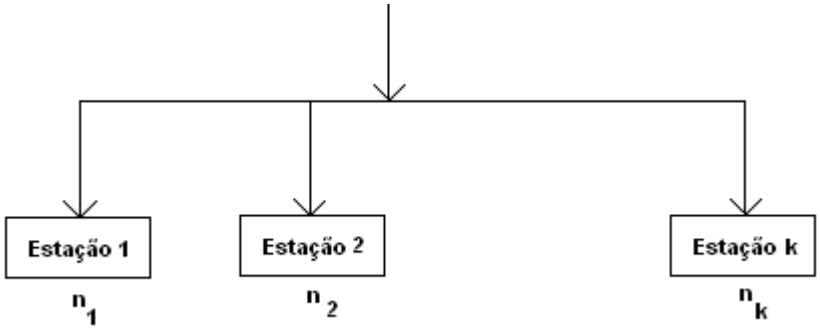

Seja uma população finita constituída de N elementos. Considere uma amostra de tamanho n. Então:

(1º) O número de amostras com reposição, considerando a ordenação, é N^n Amostras diferem pela ordenação.

N^n é dito arranjos com reposição

(2º) O número de amostras sem reposição, considerando a ordenação é

$$A_N^n=\frac{N!}{(N-n)!}\quad,\ n\leq N$$

A_N^n é dito arranjos sem reposição

(3º) o número de amostras sem reposição, desconsiderando a ordenação é $C_N^n = \frac{A_N^n}{n!}$.

Também vale que $C_N^n = \frac{N!}{(N-n)! \times n!}$.

Nota: $\binom{N}{n} = C_N^n$ é dito coeficiente binomial

(4º) a extensão de permutações é chamada de permutações com elementos repetidos.

$$Pr(n_1, n_2, \ldots, n_r) = \frac{n!}{n_1! \times n_2! \times \ldots \times n_r!} \quad , \quad n = n_1 + n_2 + \ldots + n_r$$

Se $r = 2$ temos o coeficiente binomial.

Por exemplo, quantos anagramas têm a palavra MATEMÁTICA?

M ocorre 2 vezes
A ocorre 3 vezes
T ocorre 2 vezes
E ocorre 1 vez
I ocorre 1 vez
C ocorre 1 vez

$$Pr(2,3,2,1,1,1) = \frac{10!}{2! \times 3! \times 2! \times 1! \times 1! \times 1!} = 151200$$

Exemplo 2.11: seja um conjunto $\Omega = \{\varpi_1, \varpi_2, \varpi_3\}$ e considere uma amostra de tamanho dois. Então: N=3 e n=2.

No processo com reposição é considerada a ordenação, assim, as amostras possíveis são:

(ϖ_1, ϖ_1) (ϖ_1, ϖ_2) (ϖ_1, ϖ_3) (ϖ_2, ϖ_1) (ϖ_2, ϖ_2) (ϖ_2, ϖ_3) (ϖ_3, ϖ_1) (ϖ_3, ϖ_2) (ϖ_3, ϖ_3) , portanto: $P[(\varpi_i, \varpi_j)] = \frac{1}{3^2}$.

No processo sem reposição, considerando ordenação, teremos:

(ϖ_1, ϖ_2) (ϖ_1, ϖ_3) (ϖ_2, ϖ_1) (ϖ_2, ϖ_3) (ϖ_3, ϖ_1) (ϖ_3, ϖ_2) , e

portanto: $P[(\varpi_i, \varpi_j)] = \frac{1}{6}$.

No processo sem reposição, desconsiderando ordem, teremos:

$$(\varpi_1,\varpi_2) \quad (\varpi_1,\varpi_3) \quad (\varpi_2,\varpi_3) \ .$$

Note que no caso em que a ordem é desconsiderada, algumas pessoas respondem que $P\left[(\varpi_i,\varpi_j)\right]=\frac{1}{6}$, que está errado, pois a soma de todas as probabilidades não será 1.

Quando a ordem não é considerada, $P\left[(\varpi_i,\varpi_j)\right]$ é multiplicada por $n!$, que é o número de réplicas da amostra, isto é:

$$P\left[(\varpi_i,\varpi_j)\right]=2\times\frac{1}{6}=\frac{1}{3}$$

Isto acontece porque as réplicas, que eram do caso com ordenação, serão consideradas iguais, como mostra a figura abaixo:

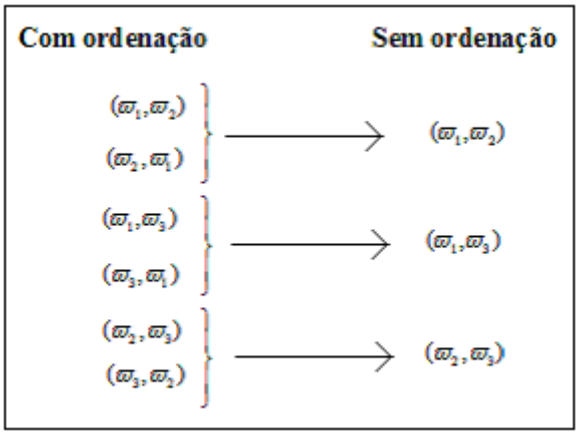

Exemplo 2.12: considere um congresso onde compareceram 35 engenheiros, 25 matemáticos e 15 físicos. Se for formada, ao acaso, uma comissão de 10 membros, qual a probabilidade de que esta seja constituída de:

(a) 5 engenheiros, 3 matemáticos e 2 físicos em qualquer sequência ?

(b) Exclusivamente de engenheiros, ou de matemáticos, ou de físicos ?

(c) Mesma composição de (a), mas os cientistas de mesma área querem ficar juntos, contudo matemáticos não querem ficar ao lado de físicos.

Solução:

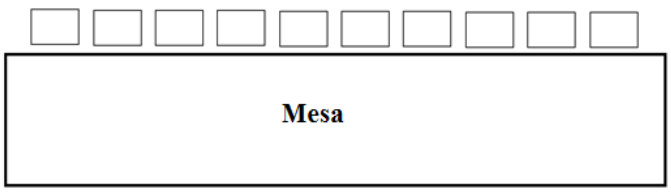

(a) pelo princípio da multiplicação, e uma vez que a ordem em que sentam não tem importância,

$$\frac{C_{35}^{5}\times C_{25}^{3}\times C_{15}^{2}}{C_{75}^{10}}=0,094577978$$

(b) pelo princípio da adição,

$$\frac{C_{35}^{10}}{C_{75}^{10}}+\frac{C_{25}^{10}}{C_{75}^{10}}+\frac{C_{15}^{10}}{C_{75}^{10}}=\frac{A_{35}^{10}}{A_{75}^{10}}+\frac{A_{25}^{10}}{A_{75}^{10}}+\frac{A_{15}^{10}}{A_{75}^{10}}=0,0002254$$

Note que há somente uma sequência EEEEEEEEEE, por isso, $\frac{C_{35}^{10}}{C_{75}^{10}}=\frac{A_{35}^{10}}{A_{75}^{10}}$.

(c) MEF ou FEM

$$\frac{A_{25}^{3}\times A_{35}^{5}\times A_{15}^{2}}{A_{75}^{10}}+\frac{A_{15}^{2}\times A_{35}^{5}\times A_{25}^{3}}{A_{75}^{10}}=0,0000751$$

Note que agora se utilizou arranjos, pois a disposição na mesa tem uma ordenação.

2.9 - Probabilidade condicional

Definição: seja Ω um espaço amostral e $A,B\subset\Omega$ eventos. Definimos a probabilidade condicional de A , dado que ocorreu B, por :

$$P(A|B)=\begin{cases}\frac{P(A\cap B)}{P(B)};P(B)>0\\ 0;P(B)=0\end{cases}$$

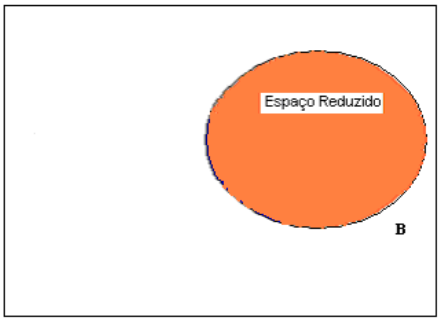

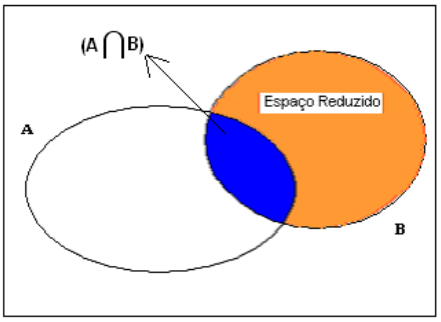

Observações:

(1ª) A notação P(A | B) é entendida como a probabilidade de A ocorrer, sabendo-se que B já ocorreu. Algumas pessoas entendem que é para dividir A por B, mas isto não faz sentido, pois a barra "|" que aparece entre "A" e "B" é para informar que "B" já ocorreu.

(2ª) A interpretação de P(A | B) é que uma vez conhecido o fato de que o evento B ocorreu, então não é mais necessário pensar em todo o espaço amostral. Na verdade, agora B passa a ser o "espaço amostral reduzido ".

Exemplo 2.13: extrair sem reposição, considerando a ordem das cores, duas bolas de uma urna com 5 azuis e 3 brancas. Para facilitar, faremos distinção apenas nas cores das bolinhas. Assim,

$$\Omega=\{(b,b);(b,a);(a,b);(a,a)\}$$

Sejam B = "1ª bola é branca" e A = "2ª bola é azul".

(a) Calcule $P(B\cap A)$

(b) Calcule a probabilidade de ocorrer uma branca e uma azul em qualquer ordem

Solução:

(a) $B=\{(b,b);(b,a)\}$ $B^c=\{(a,b);(a,a)\}$

$A=\{(b,a);(a,a)\}$ $A^c=\{(b,b);(a,b)\}$

$(B\cap A)=\{(b,a)\}$ $B^c\cap A=\{(a,a)\}$

$P(B\cap A)=\dfrac{A_3^1\times A_5^1}{A_8^2}=\dfrac{15}{56}$. Note que não vale $P(B\cap A)=\dfrac{\#(B\cap A)}{\#\Omega}=\dfrac{1}{4}$. Somente valeria se

houvesse mesmo número de bolas para as cores e se as extrações fossem com reposição. Outra maneira de obter $P(B\cap A)$ é através da probabilidade condicional, isto é,
$P(B\cap A)=P(B)\times P(A|B)=\dfrac{3}{8}\times\dfrac{5}{7}=\dfrac{15}{56}$.

(b) $P((b,a)\cup(a,b))=\dfrac{3}{8}\times\dfrac{5}{7}+\dfrac{5}{8}\times\dfrac{3}{7}=2\times\dfrac{3}{8}\times\dfrac{5}{7}=\dfrac{30}{56}=\dfrac{C_3^1\times C_5^1}{C_8^2}$

Propriedades das probabilidades condicionais

(1ª) $0\leq P(A|B)\leq 1$

(2ª) $P(A\cap B)=P(A)\times P(B|A)$; $P(B\cap A)=P(B)\times P(A|B)$

$P(A\cap B\cap C)=P(A)\times P(B|A)\times P(C|(A\cap B))$

(3ª) $P(A\cup B|C)=P(A|C)+P(B|C)$ se $A\cap B=\emptyset$

Exemplo 2.14: outra maneira de resolver o Exemplo 2.12 (a). Note que algumas pessoas responderiam que a solução é

$$\left(\frac{35}{75}\times\frac{34}{74}\times\frac{33}{73}\times\frac{32}{72}\times\frac{31}{71}\right)\times\left(\frac{25}{70}\times\frac{24}{69}\times\frac{23}{68}\right)\times\left(\frac{15}{67}\times\frac{14}{66}\right) \quad ,$$

que está errada, pois a ordem em que os membros são formados não está fixada, ou seja, é preciso levar em conta todas as posições dos membros dentro da comissão! A resposta correta é:

$$\frac{C_{35}^{5}\times C_{25}^{3}\times C_{15}^{2}}{C_{75}^{10}}=\frac{10!}{5!\times 3!\times 2!}\times\left(\frac{35}{75}\times\frac{34}{74}\times\frac{33}{73}\times\frac{32}{72}\times\frac{31}{71}\right)\times\left(\frac{25}{70}\times\frac{24}{69}\times\frac{23}{68}\right)\times\left(\frac{15}{67}\times\frac{14}{66}\right)$$

Note que $\frac{10!}{5!\times 3!\times 2!}$ é dito coeficiente trinomial.

Exemplo 2.15: considere uma urna contendo 5 bolas brancas, 4 verdes e 3 pretas. Uma pessoa retira, sem reposição, 3 bolas. Qual a probabilidade:

(a) ocorrer a seguinte sequência de cores: verde, preta e branca?
(b) saírem três cores diferentes?
(c) ocorrer pelo menos uma branca?
(d) sabendo-se que na 1ª extração saiu uma verde, qual a probabilidade de saírem mais duas verdes?
(e) todas as cores iguais

Solução: se fizermos distinção entre bolas de mesma cor, então a cardinalidade do espaço amostral será $A_{12}^{3}=1320$. Logo, será um trabalho árduo escrever todo Ω. Fazendo distinção apenas das cores, , $\Omega=\{bbb, bbv, bvb, vbb, \ldots, ppp\}$, $\#\Omega=3^3=27$

(a) $P(v\,p\,b)=P(v\cap p\cap b)=P(v)\times P(p|v)\times P(b|(vp))=\frac{4}{12}\times\frac{3}{11}\times\frac{5}{10}$

(b) Defina A o evento "ocorrem três cores diferentes". Note que algumas pessoas responderiam que $P(A)=\frac{\#A}{\#\Omega}=\frac{6}{27}=\frac{2}{9}$, que está errado! Este raciocínio somente valeria se houvesse mesmo número de bolas para as três cores e, além disso, se o processo fosse com reposição! O correto é

$$P(\text{vpb})+P(vbp)+P(bpv)+P(bvp)+P(pvb)+P(pbv)=6\times\frac{5}{12}\times\frac{4}{11}\times\frac{3}{10}=\frac{C_5^1\times C_4^1\times C_3^1}{C_{12}^3}$$

Note que a sequência de cores não foi fixada, então há $\frac{3!}{1!\times 1!\times 1!}=3!=6$ possíveis maneiras.

(c) Neste caso é mais fácil operar com dois tipos, cor branca e cores não brancas.

k = cor diferente da branca

$$P(kkb)+P(kbk)+P(bkk)+P(bbk)+P(bkb)+P(kbb)+P(bbb)=$$
$$3\times\frac{5}{12}\times\frac{7}{11}\times\frac{6}{10}+3\times\frac{5}{12}\times\frac{4}{11}\times\frac{7}{10}+\frac{5}{12}\times\frac{4}{11}\times\frac{3}{10}=$$
$$=\frac{C_5^1\times C_7^2}{C_{12}^3}+\frac{C_5^2\times C_7^1}{C_{12}^3}+\frac{C_5^3}{C_{12}^3}=\frac{37}{44}$$

Outra maneira, pelo evento complementar: $1-P(kkk)=1-\frac{7}{12}\times\frac{6}{11}\times\frac{5}{10}=\frac{37}{44}$.

(d) $P(vv|v)=\frac{P(vvv)}{P(v)}=\frac{3}{11}\times\frac{2}{10}$

(e) $P(bbb)+P(vvv)+P(ppp)=$
$\frac{5}{12}\times\frac{4}{11}\times\frac{3}{10}+\frac{4}{12}\times\frac{3}{11}\times\frac{2}{10}+\frac{3}{12}\times\frac{2}{11}\times\frac{1}{10}=\frac{90}{1320}=0,068$

2.10 - Teorema de Bayes

Definição: Seja Ω um espaço amostral. Um conjunto de eventos $\{B_1,B_2,...,B_k\}\subset\Omega$ forma uma partição de Ω se e somente se:

(1º) $B_i\cap B_j=\emptyset$, $i\neq j$

(2º) $\cup_{i=1}^{k}B_i=\Omega$

(3º) $B_i\neq\emptyset$

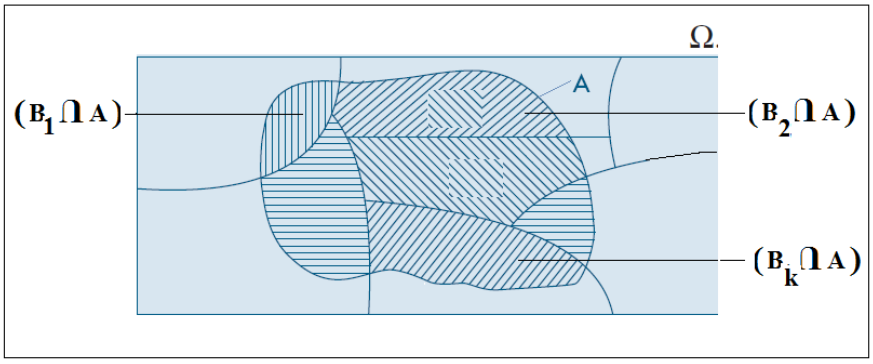

Teorema da Probabilidade Total: Seja Ω espaço amostral e $\{B_1,B_2,...,B_k\}\subset\Omega$ uma partição. Para $A\subset\Omega$ evento qualquer:

$$P(A)=\sum_{i=1}^{k}P(B_i)\times P(A|B_i)$$

Teorema de Bayes: Seja Ω espaço amostral e $\{B_1, B_2, ..., B_k\} \subset \Omega$ uma partição. Para $A \subset \Omega$ evento qualquer:

$$P(B_j|A) = \frac{P(A|B_j) \times P(B_j)}{\sum_{i=1}^{k} P(A|B_i) \times P(B_i)} \quad , \quad j = 1,2,.....,k \, .$$

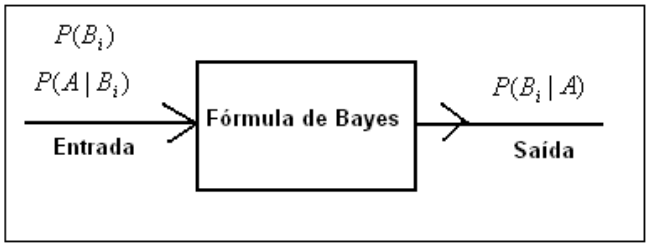

Observações:

(1ª) só há um caso em que $P(B_j|A) = P(A|B_j)$, ou seja, quando $P(B_j) = \frac{1}{k}$ e $P(A|B_j) = \frac{1}{k}$ para todo j.

(2ª) $P(B_i) > 0$ e $\sum_{i=1}^{k} P(B_i) = 1$, mas $\sum_{i=1}^{k} P(A|B_i)$ necessariamente não soma 1.

(3ª) $\sum_{i=1}^{k} P(B_i|A) = 1$.

Exemplo 2.16: Numa fábrica de parafusos, as máquinas A,B,C produzem 0,25, 0,35 e 0,40 do total produzido, respectivamente. Da produção de cada máquina, 0,05, 0,04 e 0,02, respectivamente, são defeituosos. Escolhe-se ao acaso um parafuso e verifica-se que ele é defeituoso. Qual a probabilidade de que o parafuso seja oriundo das máquinas:

(a) A ? (b) B ? (c) C ?

Solução:
Representação das proporções de produção das 3 máquinas

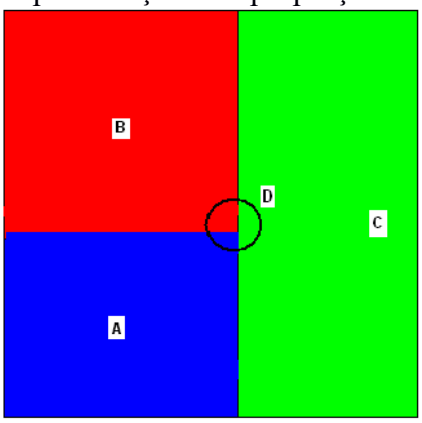

As informações de "entrada" são:

$$P(A)=0,25 \qquad P(B)=0,35 \qquad P(C)=0,40$$
$$P(D|A)=0,05 \qquad P(D|B)=0,04 \qquad P(D|C)=0,02$$

Pelo Teorema da Probabilidade Total:

$$P(D)=P(A)\times P(D|A)+P(B)\times P(D|B)+P(C)\times P(D|C)=$$
$$=0,25\times 0,05+0,35\times 0,04+0,40\times 0,02=0,0345$$

Pela fórmula de Bayes:

$$P(A|D)=\frac{P(A)P(D|A)}{P(D)}=\frac{0,25\times 0,05}{0,0345}=0,3623$$

$$P(B|D)=\frac{P(B)P(D|B)}{P(D)}=\frac{0,35\times 0,04}{0,0345}=0,4058$$

$$P(C|D)=\frac{P(C)P(D|C)}{P(D)}=\frac{0,40\times 0,02}{0,0345}=0,2319$$

$$P(A|D)+P(B|D)+P(C|D)=1$$

2.11 - Independência Probabilística

Definição: dois eventos são probabilisticamente independentes se e somente se $P(A\cap B)=P(A)\times P(B)$

Observação: da definição acima segue que $P(A|B)=P(A)$ e $P(B|A)=P(B)$, ou seja, a ocorrência de um deles não altera a probabilidade de ocorrência do outro.

Definição: três eventos *A, B, C* são ditos mutuamente independentes se e somente se:

(1º) são independentes dois a dois

(2º) $P(A\cap B\cap C)=P(A)\times P(B)\times P(C)$

Observação: eventos mutuamente disjuntos não têm nenhuma relação com eventos mutuamente independentes.

Exemplo 2.17: suponha que no exemplo 2.13 houvesse 3000 bolas brancas e 5000 azuis. Então:

$$P(B\cap A)=P(B)\times P(A|B)=\frac{3000}{8000}\times\frac{5000}{7999}=0,234404$$

Se as extrações fossem com reposição,

$$P(B \cap A) = P(B) \times P(A|B) = \frac{3000}{8000} \times \frac{5000}{8000} = 0{,}234375$$

Para populações suficientemente grandes as duas formas de extração ficam próximas.

Exemplo 2.18: A finalidade deste exemplo é mostrar que extração de amostras com reposição possui a propriedade de independência probabilística, mas se o processo for sem reposição não haverá independência. Suponha uma urna contendo 7 bolas vermelhas e 5 bolas pretas. Considere o experimento aleatório de extrair 4 bolas ao acaso. Descreva o espaço amostral com as respectivas probabilidades, nos casos com e sem reposição. Na extração sem reposição considere a ordenação interna da amostra.

Solução:

(1ª) com reposição: se fizermos distinção entre bolas de mesma cor então a cardinalidade do espaço amostral será $\#\Omega = 12^4 = 20736$. Logo, será um trabalho árduo escrever todo Ω. Se não fizermos distinção entre bolas de mesma cor então $\Omega = \{vvvv, vvvp, vvpv, ..., pppp\}$, ou seja, $\#\Omega = 2^4 = 16$.

$$P(vvvv) = P(v) \times P(v|v) \times P(v|vv) \times P(v|vvv) = \frac{7}{12} \times \frac{7}{12} \times \frac{7}{12} \times \frac{7}{12} = \left(\frac{7}{12}\right)^4 =$$
$$= P(v) \times P(v) \times P(v) \times P(v)$$

$$P(vvvp) = P(v) \times P(v|v) \times P(v|vv) \times P(p|vvv) = \frac{7}{12} \times \frac{7}{12} \times \frac{7}{12} \times \frac{5}{12} = \left(\frac{7}{12}\right)^3 \times \left(\frac{5}{12}\right) =$$
$$= P(v) \times P(v) \times P(v) \times P(p)$$

$$P(vvpv) = P(vpvv) = P(pvvv) = P(vvvp) = \left(\frac{7}{12}\right)^3 \times \left(\frac{5}{12}\right)$$

$$P(vvpp) = P(vpvp) = P(pvpv) = P(pvvp) = P(vppv) = P(ppvv) = \left(\frac{7}{12}\right)^2 \times \left(\frac{5}{12}\right)^2$$

$$P(vppp) = P(pvpp) = P(ppvp) = P(pppv) = \left(\frac{7}{12}\right) \times \left(\frac{5}{12}\right)^3$$

$$P(pppp) = P(p) \times P(p|p) \times P(p|pp) \times P(p|ppp) = \frac{5}{12} \times \frac{5}{12} \times \frac{5}{12} \times \frac{5}{12} = \left(\frac{5}{12}\right)^4 =$$
$$= P(p) \times P(p) \times P(p) \times P(p)$$

Concluímos que os eventos são independentes.

(2ª) sem reposição: agora neste tipo de extração a mesma bola não pode aparecer mais que uma vez.

$$P(vvvv) = P(v) \times P(v \mid v) \times P(v \mid vv) \times P(v \mid vvv) = \frac{7}{12} \times \frac{6}{11} \times \frac{5}{10} \times \frac{4}{9} = \frac{A_7^4}{A_{12}^4}$$

$$P(v) \times P(v) \times P(v) \times P(v) = \left(\frac{7}{12}\right)^4$$

Como $P(vvvv) \neq P(v) \times P(v) \times P(v) \times P(v)$, não há independência probabilística.

Observação: o experimento de lançar diversas vezes um dado ou uma moeda, equivale a um processo de extração com reposição de bolas de uma urna. Especificamente, considere uma urna com mesma quantidade de bolas brancas e pretas. Fazendo extrações com reposição, equivale a lançar uma moeda honesta.

2.12 - Espaços amostrais não enumeráveis

Há situações em que o número de elementos do espaço amostral é não enumerável, por exemplo um intervalo limitado da reta real. Para espaços amostrais não enumeráveis, a definição clássica de probabilidade tem que ser estendida para o conceito de ***probabilidade geométrica***, ou seja, para A subconjunto não enumerável de um espaço amostral não enumerável, a probabilidade será:

$$P(A) = \frac{\text{medida do conjunto } A}{\text{medida de } \Omega}$$

Entenda-se como "medida" comprimento, área ou o volume.

Exemplo 2.19: se X e Y são pontos de uma linha de extremos A e B, a probabilidade de que um ponto da linha AB pertença à linha XY é proporcional ao comprimento de XY, e não depende da posição dos pontos X e Y sobre AB. Portanto, selecionado um ponto de AB, a probabilidade de que ele pertença a XY é:

$$p = \frac{\text{comprimento de XY}}{\text{comprimento de AB}} = \frac{Y - X}{B - A}$$

Exemplo 2.20: se tivermos uma região B do plano, contida em uma região A, a probabilidade de um ponto de A também pertencer a B é proporcional à área de B, e não depende da posição que B ocupa em A. Portanto, selecionado ao acaso um ponto de A, a probabilidade de que ele pertença a B é:

$$p = \frac{\text{área de B}}{\text{área de A}}$$

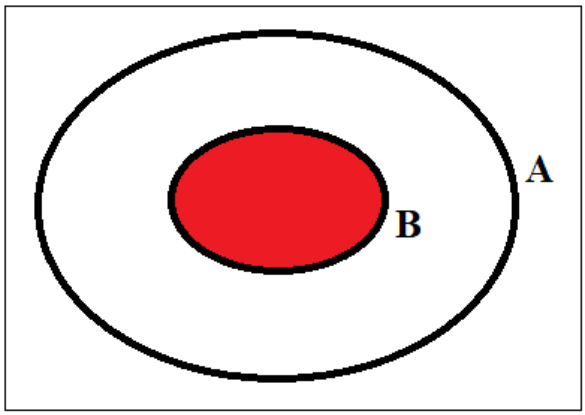

3ª Parte - Variáveis Aleatórias Discretas

3.1 - Definições

Definição: seja ε um experimento aleatório e Ω o espaço amostral associado a esse experimento. Uma função X, que associe a cada elemento $\omega \in \Omega$ um número real $X(\omega)$, é denominada de variável aleatória (v.a).

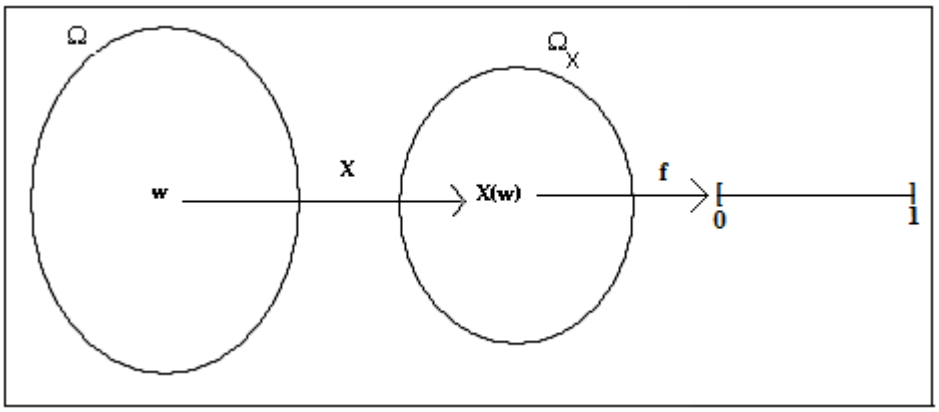

Observação: em algumas situações o resultado ω do espaço amostral já constitui uma característica numérica que desejamos registrar. Assim, tomamos $X(\omega)=\omega$.

Exemplo 3.1: lançamento de duas moedas. Considere a v.a. X sendo o número de faces CARA.

$\Omega=\{CC, KK, CK, KC\}$

C = "CARA" K = "COROA"

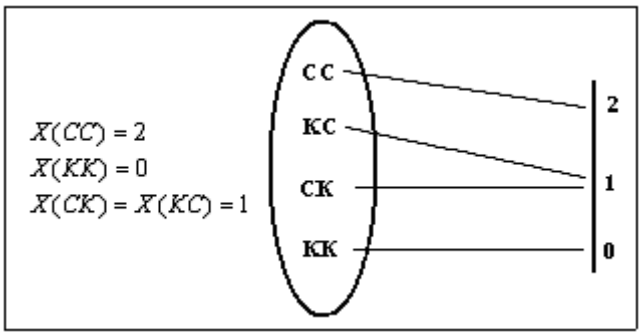

Definição: uma v.a X é dita discreta quando o conjunto dos valores possíveis de X é finito ou infinito enumerável.

$\Omega_X=\{x_1, x_2, \ldots, x_n\}$ ou $\Omega_X=\{x_1, x_2, \ldots\}$.

3.2- Função massa de probabilidade (fmp)

Definição: a função massa de probabilidade (f.m.p) de uma v.a. discreta é:

$$f:\Omega_X \rightarrow [0,1] \quad ; \quad x \rightarrow f(x)=P(X=x)$$

Nota: X representa a variável aleatória e x um número.

Condições para ser uma f.m.p:

(1ª) $0 \leq f(x) \leq 1$, para todo $\forall x \in \Omega_X$

(2ª) $\sum_{x \in \Omega_X} f(x)=1$

(3ª) $f(x)=0$ se $x \notin \Omega_X$

Observações:

(1ª) Soma à esquerda: $P(X \leq x)=\sum_{\{y \leq x\}} f(y)$.

Caso $x \notin \Omega_X$, $P(X \leq x)=P(X<x)=\sum_{y<x} f(y)$

(2ª) Soma à direita: $P(X \geq x)=\sum_{y \geq x} f(y)$.

Caso $x \notin \Omega_X$, $P(X \geq x)=P(X>x)=\sum_{y>x} f(y)$

(3ª) Soma entre dois pontos: $P(a \leq X \leq b)=\sum_{a \leq y \leq b} f(y)=f(a)+...+f(b)$.

Caso $a,b \notin \Omega_X$, $P(a \leq X \leq b)=\sum_{a<y<b} f(y)$.

Exemplo 3.2: Uma moeda é tal que a probabilidade da face cara é três vezes a da coroa. Seja X o número de faces cara em 3 lançamentos dessa moeda. Obtenha a fmp de X.

Solução: $\Omega=\{KKK, CKK, KCK, KKC, KCC, CKC, CCK, CCC\}$

$\Omega_X=\{0;1;2;3\}$

Defina $p=P(C)$ e $q=P(K)$.

$$p+q=1$$
$$3q+q=1$$
$$4q=1$$
$$q=\frac{1}{4};p=\frac{3}{4}$$

$$f(0)=P(X=0)=P(KKK)=\frac{1}{4}\times\frac{1}{4}\times\frac{1}{4}=\frac{1}{64}$$

$$f(1)=P(X=1)=P[(CKK)\cup(KCK)\cup(KKC)]=P(CKK)+P(KCK)+P(KKC)=$$
$$=\frac{3}{64}+\frac{3}{64}+\frac{3}{64}=\frac{9}{64}$$

$$f(2)=P(X=2)=P[(CCK)\cup(KCC)\cup(CKC)]=P(CCK)+P(KCC)+P(CKC)=$$
$$=\frac{9}{64}+\frac{9}{64}+\frac{9}{64}=\frac{27}{64}$$

$$f(3)=P(X=3)=P(CCC)=\frac{3}{4}\times\frac{3}{4}\times\frac{3}{4}=\frac{27}{64}$$

x	0	1	2	3	Total
$f(x)$	1/64	9/64	27/64	27/64	1

Representação gráfica da f.m.p do Exemplo 3.2:

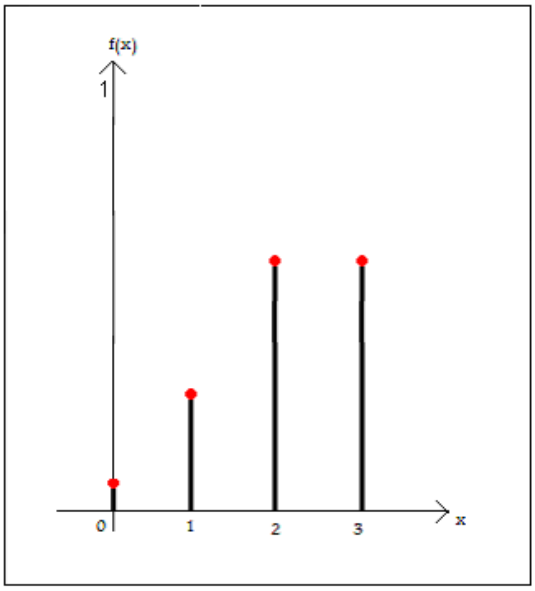

Exemplo 3.3: seja X v.a. discreta com a seguinte f.m.p:

x	-3	-1	0	1	2	3	5	8	Total
$f(x)$	0,1	0,2	0,15	0,2	0,1	0,15	0,05	0,05	1

Obtenha:

(a) probabilidade de X ser negativa (b) probabilidade de X ser par

(c) $P(X=-3|X\leq 0)$ (d) $P(X\geq 3|X>0)$

Solução:

(a) $f(-3)+f(-1)=0{,}3$ (b) $f(0)+f(2)+f(8)=0{,}3$

(c) $$\frac{P[(X=-3)\cap(X\leq 0)]}{P(X\leq 0)}=\frac{P(X=-3)}{P(X\leq 0)}=\frac{f(-3)}{f(-3)+f(-1)+f(0)}=\frac{0{,}1}{0{,}45}=\frac{2}{9}$$

(d) $$\frac{f(3)+f(5)+f(8)}{f(1)+f(2)+f(3)+f(5)+f(8)}=\frac{0{,}25}{0{,}55}=\frac{5}{11}$$

Exemplo 3.4: nas funções massas abaixo obtenha o valor de C

(a) $$f(x)=\begin{cases} C\times 2^x;\, x\in\{1,2,\ldots,N\} \\ 0;\, \text{caso contrário}\end{cases}$$

(b) $$f(x)=\begin{cases} C\times\left(\frac{1}{2}\right)^x;\, x\in\{1,2,\ldots\} \\ 0;\, \text{caso contrário}\end{cases}$$

Solução:

(a) Usando a soma dos termos de uma PG finita,

$$C=\frac{1}{\sum_{x=1}^{N}2^x}=\frac{1}{\frac{2(2^N-1)}{2-1}}=\frac{1}{2(2^N-1)}$$

(b) Usando a soma dos termos de uma PG infinita,

$$C\left(\frac{\frac{1}{2}}{1-\frac{1}{2}}\right)=1\Rightarrow C=1$$

3.3 - Esperança de uma variável aleatória discreta

A esperança matemática da v.a. X é definida como:

$$E(X)=\sum_{x\in\Omega_X} x\times f(x) \quad .$$

notações: $E(X), \mu, EX$

Observações:

(1ª) A esperança matemática é a média da população, enquanto $\bar{X}$ é a média da amostra, ou seja, uma estimativa de E(X).

(2ª) Interpretamos a esperança matemática como sendo o centro de gravidade (equilíbrio) de uma fmp, e é empregada com a finalidade de representatividade dos valores de Ω_X .

Exemplo 3.5: calcule o rendimento esperado das seguintes aplicações financeiras

(a) LTN pré-fixada 12% ao ano

(b) NTN pós-fixada tal que 14% ao ano com probabilidade 0,60 ou 6% ao ano com probabilidade 0,40

Solução: sendo C o capital aplicado

(a) rendimento esperado: $C\times 1{,}12\times 1$

(b) rendimento esperado: $C\times 1{,}14\times 0{,}60+C\times 1{,}06\times 0{,}40=C\times 1{,}108$

Exemplo 3.6: Uma fábrica opera com 3 marcas de máquinas: A, B, C. O gerente deseja saber qual marca tem menor custo médio de manutenção.

	Marca A		Marca B		Marca C	
Tipo de defeito	Custo do Conserto(X)	Probab. de Falha	Custo do Conserto(Y)	Probab. de falha	Custo do Conserto(Z)	Probab. de falha
Mecânico	33	0,50	32	0,48	34	0,45
Elétrico	34	0,20	36	0,21	35	0,27
Hidráulico	50	0,30	47	0,31	51	0,28

$$EX=33\times 0{,}50+34\times 0{,}20+50\times 0{,}30=38{,}3 \quad ; \quad EY=37{,}49 \quad ; \quad EZ=39{,}03$$

A marca B tem menor custo médio, logo deve ser a preferida.

Exemplo 3.7: um florista vende flores de uma certa espécie. Observando por 60 dias, ele obteve a seguinte tabela de demanda dessa flor:

Vendas diárias	Frequência	Probabilidade estimada
0	6	6/60
1	5	5/60
2	17	17/60
3	24	24/60
4	8	8/60

O custo, para cada flor, é de 0,50 unidades monetárias e o preço de venda é 0,80. Qual o lucro médio se ele mantiver um estoque diário de 4 flores?

Solução: X é o número de vendas diárias, que segue a distribuição de probabilidade da tabela.

$$L = 0{,}80 \times X - 4 \times 0{,}50 = 0{,}80 \times X - 2$$

$$E(L) = (0{,}80 \times 0 - 2) \times \frac{6}{60} + (0{,}80 \times 1 - 2) \times \frac{5}{60} + (0{,}80 \times 2 - 2) \times \frac{17}{60} +$$
$$+ (0{,}80 \times 3 - 2) \times \frac{24}{60} + (0{,}80 \times 4 - 2) \times \frac{8}{60} = -0{,}09$$

Com estoque de 4 flores ele terá prejuízo. Melhor manter um estoque diário de 3 flores.

Propriedades da Esperança:

(1ª) $E(c) = c$, se c for uma constante

(2ª) $E(cX) = cE(X)$, se c for uma constante

(3ª) $E(aX + b) = aE(X) + b$, $a, b \in R$ constantes

(4ª) $E(X \pm Y) = E(X) \pm E(Y)$

3.4 - Mediana e moda para variáveis aleatórias discretas

Definição: a moda de uma v.a. discreta é o valor $x \in \Omega_X$ tal que

$f(x) > f(y)$, para todo $y \in \Omega_X ; y \neq x$.

notação: Mo

Nota: pode haver mais de uma moda. Se todas $f(x)$ são iguais, diremos que não existe moda.

Definição: a mediana de uma v.a. discreta é um valor $x \in R$ tal que

$P(X \leq x) \geq \frac{1}{2}$ e $P(X \geq x) \geq \frac{1}{2}$.

notação: Md

Exemplo 3.8: seja X uma v.a. com f.m.p dada por

x	1	2	$\sum$
$f(x)$	1/8	7/8	1

$P(X \leq 2) = \frac{1}{8} + \frac{7}{8} = 1$ e $P(X \geq 2) = \frac{7}{8}$

Md = 2 é única.

Moda =2 ; $E(X) = \frac{15}{8}$

Exemplo 3.9: lançar 3 vezes uma moeda equilibrada.

x	0	1	2	3	$\sum$
$f(x)$	1/8	3/8	3/8	1/8	1

Neste exemplo, a mediana pode ser qualquer valor no intervalo [1; 2]. Se adotarmos $\text{Md} = \frac{1+2}{2} = 1{,}5$ estaremos utilizando o ponto médio do intervalo [1; 2], além do fato de que Md =E(X). Também, tem-se que $\text{Mo}^{(1)} = 1$ e $\text{Mo}^{(2)} = 2$.

Observação: em uma v.a. cuja f.m.p é simétrica e unimodal, então $E(X) = \text{Md} = \text{Mo}$

3.5- Variância e desvio padrão de uma variável aleatória discreta

Definição: Seja X v.a discreta com f.m.p f e espaço amostral $\Omega_X = \{x_1, x_2, \ldots\ldots\}$. Definimos a variância de X por

$$Var(X) = \sum_{x \in \Omega_X} (x - EX)^2 \times f(x)$$

Definição: o desvio padrão é definido como $DP(X) = \sqrt{Var(X)}$

Notações: $V(X), Var(X), \sigma_X^2, DP(X), \sigma_X$

Observações:

(1ª) uma fórmula alternativa para a variância é $Var(X)=\left(\sum_{x\in\Omega_X} x^2\times f(x)\right)-(EX)^2$

(2ª) $Var(X)\geq 0$

(3ª) a variância tem como unidade de medida o quadrado da unidade de medida

(4ª) o desvio padrão tem mesma unidade de medida que a v.a. X, e mede o grau de dispersão dos valores de Ω_X em torno de EX

(5ª) podemos também utilizar o coeficiente de variação de X, definido como $CV=\frac{DP}{|EX|}\times 100\%$. O CV é interpretado como o grau de variabilidade relativa em torno da esperança, ou seja, CV é uma medida relativa, enquanto DP é absoluta.

Exemplo 3.10: com relação ao Exemplo 3.2,

$$E(X)=\frac{144}{64}=2{,}25 \quad , \quad Var(X)=\frac{360}{64}-\left(\frac{144}{64}\right)^2=0{,}5625$$

$$DP(X)=0{,}75 \quad \text{e} \quad CV=33{,}3333\% \quad .$$

Propriedades da variância

(1ª) $Var(c)=0$, c constante;

(2ª) $Var(cX)=c^2 Var(X)$;

(3ª) $Var(aX+b)=a^2 Var(X)$, $a,b\in R$.

(4ª) $Z=\frac{X-\mu}{\sigma}$, $E(Z)=0$, $Var(Z)=1$

3.6 - Modelos probabilísticos discretos

3.6.1 - Modelo Uniforme Discreto

fmp: $f(x)=\frac{1}{N}$ $x\in\{1,2.\ldots.,N\}$.

Notação: $Unif(N)$

Gráfico da fmp de uma distribuição uniforme discreta

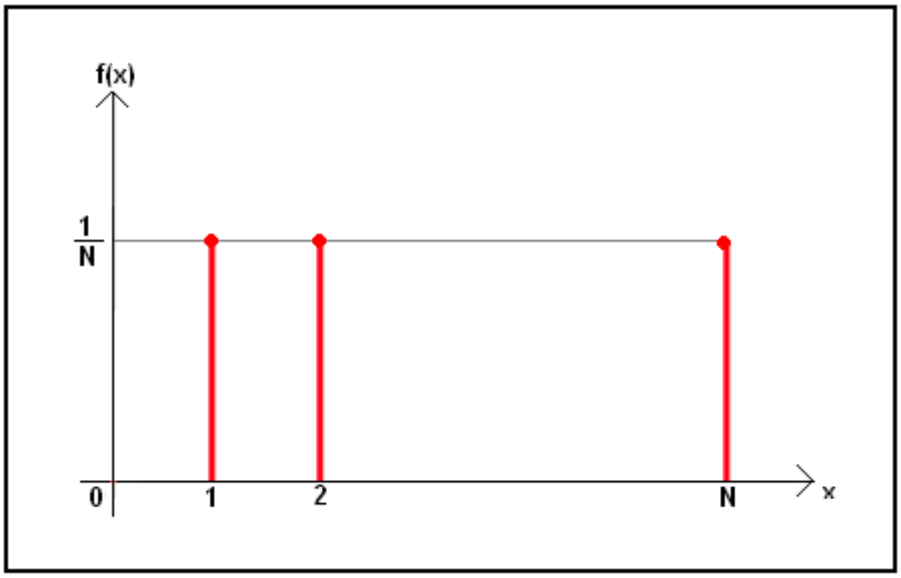

Esperança e variância de uma Uniforme discreta

$$EX=\frac{1+N}{2} \quad ; \quad Var(X)=\frac{(N^2-1)}{12} \quad .$$

Exemplo 3.11: X= "no. de pontos marcados na face superior de um dado".

x	1	2	3	4	5	6	$\sum$
$f(x)$	1/6	1/6	1/6	1/6	1/6	1/6	1

$$E(X)=\frac{6+1}{2}=3{,}5$$

Exemplo 3.12: a amostra a seguir é o resultado de 24 lançamentos de um dado equilibrado

Face	1	2	3	4	5	6	Total
Nº ocorrências	4	4	5	4	3	4	24

$$\bar{X}=\frac{1\times 4+2\times 4+3\times 5+4\times 4+5\times 3+6\times 4}{24}=\frac{82}{24}=3{,}416666$$

Em n lançamentos de um dado a soma das faces divida por n é aproximadamente 3,5.

3.6.2 - Modelo Binomial

Seja um experimento aleatório com dois resultados possíveis, isto é, $\Omega=\{\omega_1,\omega_2\}$, com $P(\omega_1)=p$ e $P(\omega_2)=1-p=q$. A variável aleatória X , tal que $X(\omega_1)=1$ (ocorreu um sucesso) e $X(\omega_2)=0$ (ocorreu um fracasso) é dita modelo de Bernoulli. O que é um "sucesso" ou um "fracasso" é subjetivo.

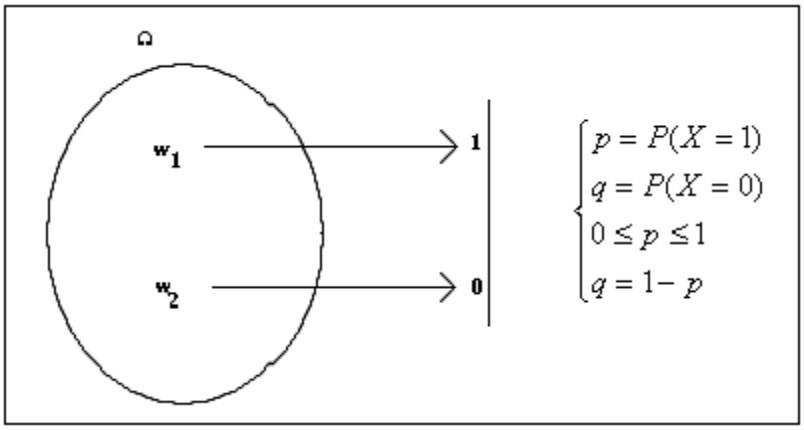

Exemplo 3.13: lançamento de uma moeda equilibrada

$$X=\begin{cases} 1, & \text{se é cara} \\ 0, & \text{se é coroa} \end{cases}$$

$p=P(X=1)=0{,}5$, $q=P(X=0)=0{,}5$

Exemplo 3.14:

$$X=\begin{cases} 1, & \text{se é RH+} \\ 0, & \text{se é RH-} \end{cases}$$

Sabe-se, da Biologia, que $p=P(X=1)=0{,}85$ e $q=P(X=0)=0{,}15$.

Sendo $X_1, X_2, \ldots, X_n$ v.a's. independentes e identicamente distribuídas segundo uma Bernoulli de parâmetro p , então $X=\sum_{i=1}^{n} X_i$ é dita binomial de parâmetros n e p .

Notação: $Binomial(n, p)$

Observações:

(1ª) O modelo tem como suposição a independência entre as repetições do experimento ou população infinita.

(2ª) A v.a. X é interpretada como o número de sucessos em n repetições independentes do experimento. O valor n é também visto como o tamanho da amostra e p a proporção de sucessos na população.

fmp: $f(x,n,p)=C_n^x p^x q^{n-x}$, $q=1-p$ $x\in\{0,1,2\ldots,n\}$

Observação: Uma vez que n e p estão fixados, podemos escrever sucintamente apenas $f(x)$ em vez de $f(x,n,p)$.

Esperança e Variância de uma v.a. Binomial: $EX = np$; $Var(X) = npq$

Tabela da Binomial

n	x	p 0,25
1	0 1	
2	0 1 2	$f(1;2;0,25)$

Exemplo 3.15: considere uma prova com 10 questões, cada uma com 4 alternativas. Suponha que o aluno escolha as respostas ao acaso. Qual é a probabilidade de:

(a) Acertar todas (b) Errar todas (c) Acertar no máximo 1
(d) Acertar no mínimo 2 (e) Qual o número esperado de acertos?

Solução: vamos denotar X como o número de acertos .

X é binomial com n=10 e p=0,25

Uma vez que n e p estão fixados, podemos escrever sucintamente apenas $f(x)$ em vez de $f(x,n,p)$.

(a) $P(X=10)=f(10)=C_{10}^{10}\times 0{,}25^{10}\times 0{,}75^{0}=0{,}25^{10}=9{,}5367\times 10^{-7}$

(b) $P(X=0)=f(0)=C_{10}^{0}\times 0{,}25^{0}\times 0{,}75^{10}=0{,}75^{10}=0{,}0563$

(c) $P(X\leq 1)=f(0)+f(1)=0{,}0563+0{,}1877=0{,}2440$

(d) $P(X\geq 2)=1-P(X<2)=1-P(X\leq 1)=1-f(0)-f(1)=1-0{,}2440=0{,}7560$

(e) $E(X)=10\times 0{,}25=2{,}5\simeq 3$

Exemplo 3.16: no exemplo anterior, se a prova tivesse 40 questões, qual o número esperado de acertos?

Solução: $E(X)=40\times 0{,}25=10$, $Var(X)=40\times 0{,}25\times 0{,}75=7{,}5$

$CV=27{,}3861\%$

3.6.3 - Modelo Hipergeométrico

Nota: a denominação do modelo tem relação com a série hipergeométrica.

Experimento aleatório: Seja uma população de tamanho N com r elementos possuindo uma característica em comum. O experimento consiste em extrair uma amostra, sem reposição, e observar se a unidade amostral possui a característica. Se a unidade amostral tiver a característica, diremos que ocorreu um "sucesso". A v.a. X = "número de sucessos (itens com a característica de interesse) na amostra" é tal que $\Omega_X=\{0,1,\ldots,\min(n,r)\}$.

f.m.p: $f(x,N,n,r)=P(X=x)=\dfrac{C_r^x \times C_{N-r}^{n-x}}{C_N^n}$, $x\in\{0,1,\ldots,\min(n,r)\}$.

$1\leq r\leq N$; $1\leq n\leq N$

Notação: $H(N,n,r)$

Esperança e variância de uma Hipergeométrica:

$E(X)=np$, $Var(X)=npq\left(\dfrac{N-n}{N-1}\right)$, $p=\dfrac{r}{N}$; $q=1-p$

Observação: para $N\rightarrow\infty$ e mantendo $p=\dfrac{r}{N}$ constante, a fmp de uma hipergeométrica converge para a binomial . Logo, para uma população suficientemente grande, os processos com e sem reposição ficam muito próximos.

Exemplo 3.17: parafusos são vendidos em embalagens de 20 unidades. Um inspetor de qualidade examina uma embalagem, selecionando ao acaso e sem reposição 5 unidades. Sabendo-se que há 4 defeituosos na embalagem, qual a probabilidade de que nesta amostra ele encontre:

(a) Nenhum item defeituoso?

(b) Um item defeituoso?

(c) No mínimo dois com defeitos?

Solução: X é "número de parafusos defeituosos na amostra"

$\Omega_X=\{0,1,2,3,4\}$ $N=20$ $n=5$ $r=4$

(a) $P(X=0)=f(0)=\dfrac{C_4^0\times C_{16}^5}{C_{20}^5}=0,2817$

(b) $P(X=1)=f(1)=\dfrac{C_4^1\times C_{16}^4}{C_{20}^5}=0,4696$

(c) $P(X\geq 2)=1-P(X<2)=1-P(X\leq 1)=1-f(0)-f(1)=1-0,2817-0,4696=0,2487$

3.7 - Variáveis aleatórias com espaço amostral infinito enumerável

3.7.1 - Modelo de Poisson

Relembrando, o conjunto dos naturais é infinito enumerável. O modelo de Poisson tem como espaço amostral o conjunto dos naturais (incluindo o zero). Agora, a definição clássica para espaços finitos, leva-nos a um paradoxo, ou seja,

$$f(x)=P(X=x)=\frac{1}{\text{número de pontos de } \Omega}=\frac{1}{\infty}=0.$$

O paradoxo é que todo ponto de Ω terá probabilidade zero, e assim $\sum_x f(x)=0$, contrariando a definição de função massa de probabilidade! Se o evento A for conjunto infinito enumerável,

$$P(A)=\frac{\text{número de pontos do evento A}}{\text{número de pontos de } \Omega}=\frac{\infty}{\infty},$$ que é uma indeterminação.

No caso de espaço amostral infinito enumerável a concepção clássica de probabilidade não pode ser admitida.

Distribuição de Poisson

A distribuição de Poisson é o modelo probabilístico que descreve um experimento aleatório, cuja variável aleatória X é o número de sucessos em um intervalo de comprimento t .

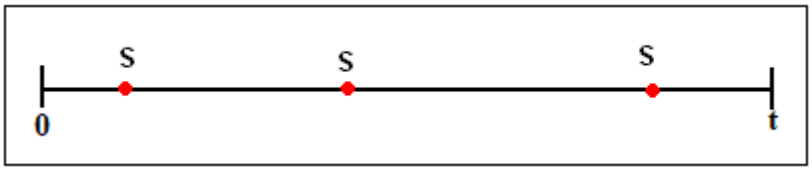

Exemplo 3.18: aplicações do modelo de Poisson:

(1º) no. de chamadas telefônicas recebidas por uma operadora durante um período de tempo.

(2º) no. de falhas de um computador durante 1 dia.

(3º) no. de veículos que chegam em um pedágio durante 1 hora.

(4º) no. de falhas em 1 metro de tecido de algodão.

fmp: $f(x,\lambda,t)=\frac{e^{-\lambda t}(\lambda t)^x}{x!}$, $x\in\{0,1,2,\ldots\ldots\}$

sendo $e=2,718281828$, $t>0$ e $\lambda>0$ o número médio de "sucessos" no intervalo de comprimento 1.

Notação: Poisson (λ, t)

Gráfico da fmp de uma Poisson

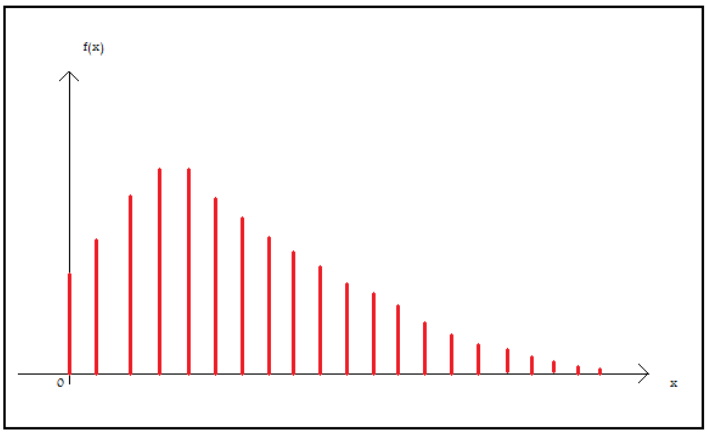

Observações:

(1ª) Num espaço amostral infinito enumerável as probabilidades dos pontos tem que somar 1, isto é, $\sum_x f(x)=1$. Para que a soma de infinitos termos resulte 1 é preciso que as massas $f(x)$ decaiam para zero de maneira muito veloz, caso contrário o valor da soma será ∞. De fato, com a função massa de probabilidade da Poisson, $\sum_{x=0}^{\infty} f(x)=\sum_{x=0}^{\infty} \frac{1}{x!} \times (\lambda)^x \times \exp(-\lambda)=1$. Por um Teorema do Cálculo, se uma série é convergente, então $\lim_{x \to \infty} f(x)=0$. Isto explica porque a distribuição de Poisson tem uma queda muito rápida para zero quando $x \to \infty$.

(2ª) Se λ for inteiro haverá duas modas: $Mo^{(1)}=\lambda-1$ e $Mo^{(2)}=\lambda$. Para $x>\lambda$, $f(x)$ será monótona decrescente, e o decaimento é de forma exponencial. Se λ for fracionário haverá uma única moda $Mo=[\lambda]$, sendo $[\ ]$ a função maior inteiro. Para $x>[\lambda]$, $f(x)$ será monótona decrescente, e o decaimento é de forma exponencial.

Tabela da Poisson

x	λt 1,6
4	$f(4;1,6)$

Esperança e variância de uma Poisson: $EX=\lambda t$; $Var(X)=\lambda t$.

Exemplo 3.19: em um pedágio de uma autoestrada chegam em média 3 veículos por minuto. Qual a probabilidade de que em:

(a) 1 minuto não chegue nenhum veículo?

(b) 2 minutos cheguem 7 veículos?

(c) 1 minuto cheguem no mínimo 3 veículos?

(d) Qual o menor k tal que $P(X \leq k) \geq 0,95$ **?** Assuma t =1 .

Solução: X é o número de veículos em um intervalo de t minutos"

(a) $\lambda t = 3 \times 1 = 3$; $P(X=0) = \dfrac{e^{-3} \times 3^0}{0!} = e^{-3} = 0{,}04978$

(b) $\lambda t = 3 \times 2 = 6$; $P(X=7) = \dfrac{e^{-6} \times 6^7}{7!} = 0{,}1377$

(c) $\lambda t = 3 \times 1 = 3$; $P(X \geq 3) = 1 - P(X < 3) = 1 - P(X \leq 2) = 1 - f(0) - f(1) - f(2)$
$= 1 - 0,04978 - 0,1494 - 0,2240 = 1 - 0,4232 = 0,5768$

(d) $P(X \leq K) \geq 0,95$, ou seja, $e^{-3} \sum_{x=0}^{K} \dfrac{3^x}{x!} \geq 0,95$ .Não há uma solução explícita para a incógnita *K*, pois ela está relacionada com o número de parcelas da soma. A solução é obtida através do método recursivo, como consta na tabela. Assim, *K=6*, pois não conseguimos que a soma seja exatamente 0,95, uma vez que *K* deve ser inteiro positivo.

K	$P(X \leq K)$
0	0,04978
1	0,1991
2	0,4232
3	0,6472
4	0,8152
5	0,9161
6	0,9664

4ª Parte -Variáveis Aleatórias Contínuas

4.1 - Variáveis contínuas

De uma maneira geral, medidas de grandezas físicas, como coordenadas espaciais, peso, tempo, temperatura e voltagem, são descritas mais adequadamente como variáveis aleatórias contínuas.

O espaço amostral de variáveis aleatórias contínuas é não enumerável, como por exemplo, a reta real, ou subintervalos da reta. Se usarmos a definição de probabilidade clássica em espaços não enumeráveis haverá um paradoxo. Suponha A um subintervalo do espaço amostral R. Assim,

$$P(A)=\frac{\text{número de pontos de } A}{\text{número de pontos de } \Omega}=\frac{\infty}{\infty}$$

que é uma indeterminação.

Para calcular a probabilidade de um evento teremos que recorrer à integração. Há casos em que poderemos utilizar fórmulas conhecidas, como área de retângulo, triângulo, círculo.

A integral de Riemann é definida como $\int_a^b f(x)\,dx=\lim_{n\to\infty}\sum_{i=1}^{\infty} f(c_i)\Delta x_i$ sendo $a<x_1<x_2<\cdots<x_{n-1}<x_n<b$; $c_i\in[x_i;x_{i+1}]$ e $\Delta x_i=x_{i+1}-x_i$. Se o limite da soma existir, isto é, for finito, diremos que a função é integrável.

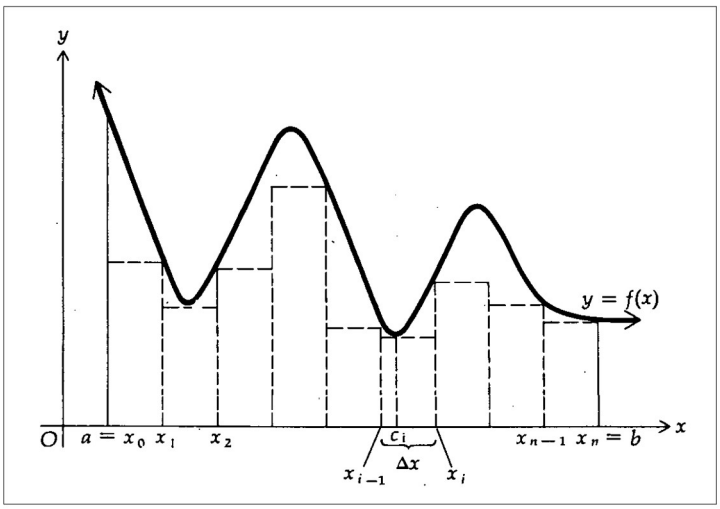

4.2 - Função densidade de probabilidade (fdp)

Definição: Diz-se que X é variável aleatória contínua se existir uma função f, denominada de função densidade de probabilidade (f.d.p), tal que:

(1º) $f(x)\geq 0$, $x\in R$

(2º) $\int_{-\infty}^{+\infty} f(x)\,dx=1$

(3º) $P(a \leq X \leq b) = \int_a^b f(x)\,dx\,; -\infty < a < b < +\infty$

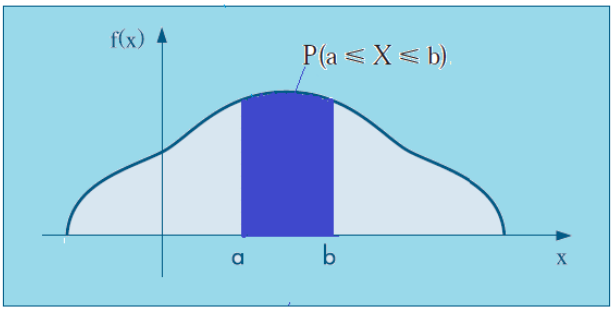

Observações:

(1ª) A denominação de densidade é devida à Mecânica. Suponha que há uma massa total (em certa unidade) distribuída sobre o intervalo [a, b]. Então, $f(x)$ representa a densidade de massa no ponto x, e $\int_c^d f(x)\,dx$ a massa contida no intervalo [c, d], com [c, d] ⊂ [a, b].

(2ª) $f(x)$ não é probabilidade.

(3ª) Uma vez que $P(X=x) = \int_x^x f(y)\,dy = 0$, então no caso contínuo

$P(X=a) = P(X=b) = 0$, e portanto,

$$P(a \leq X \leq b) = P(a < X \leq b) = P(a < X < b) = P(a \leq X < b)$$

(4ª) área à esquerda (ou área inferior): $p = P(X \leq a) = P(X < a)$

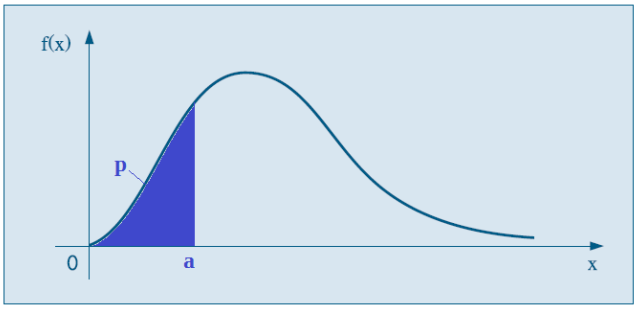

(5ª) área à direita (ou área superior) : $p = P(X \geq b) = P(X > b)$

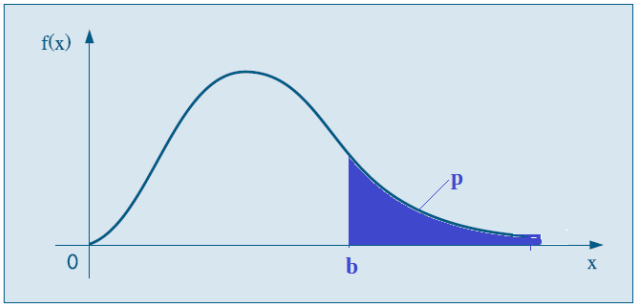

(6ª) área bilateral: $p = P(X \le a \text{ ou } X \ge b) = P(X \le a) + P(X \ge b) = p + q$

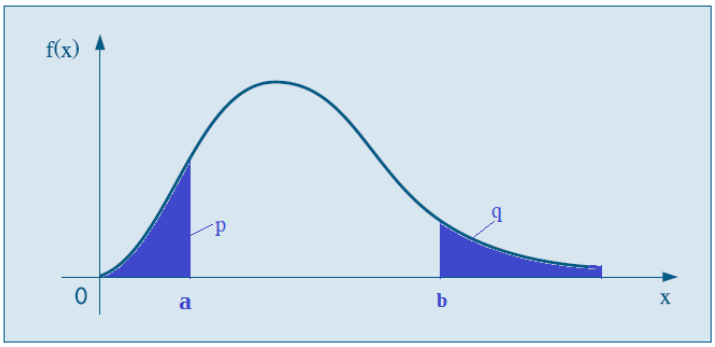

(7) área central entre dois pontos: $p = P(a \le X \le b)$

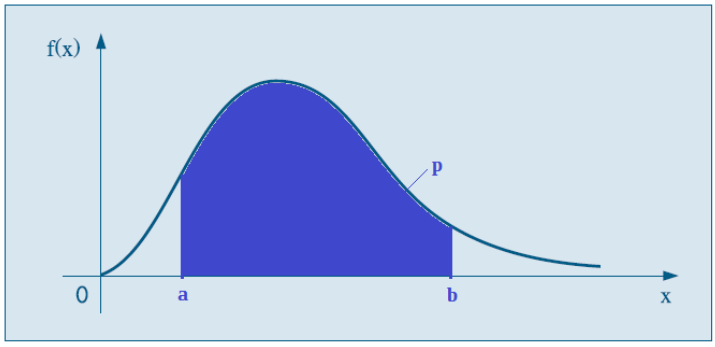

Exemplo 4.1: A demanda diária de arroz em um supermercado, em centenas de quilos, é uma v.a. X com fdp dada por:

$$f(x) = \begin{cases} 0; x < 0 \\ \frac{2}{3}x; 0 \le x \le 1 \\ 1 - \frac{x}{3}; 1 < x \le 3 \\ 0; x > 3 \end{cases}$$

(a) Faça o gráfico da densidade

(b) Verifique que f é densidade

(c) Qual a probabilidade, em um dia escolhido ao acaso, de se vender menos do que 150 kg?

(d) Qual a quantidade de arroz que deve ser deixada à disposição do público diariamente para que não falte arroz em 95% dos dias?

Solução:

(a)

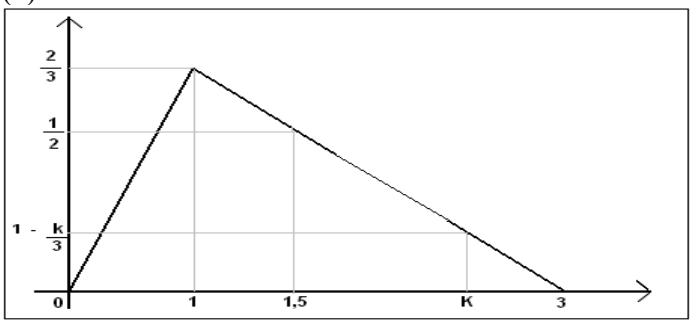

(b) área do triângulo = $\dfrac{3\times\frac{2}{3}}{2}=1$

(c) $P(X\leq 1{,}5)=1-\dfrac{1{,}5\times 0{,}5}{2}=1-\dfrac{3}{8}=\dfrac{5}{8}=0{,}625$

(d) Temos que encontrar K tal que $P(X\leq K)=0{,}95$. De maneira equivalente, $P(X\geq K)=0{,}05$, que é uma área superior.

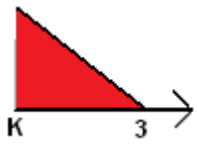

$$\frac{(3-K)\times\left(1-\frac{k}{3}\right)}{2}=0{,}05$$

$$(3-K)^2=\frac{30}{100}$$

$$3-K=\sqrt{0{,}30}\Rightarrow K=2{,}452277$$

4.3 - Função de Distribuição Acumulada de uma v.a. contínua

$F:R\rightarrow[0,1]$ $\qquad F(x)=\int_{-\infty}^{x} f(y)\,dy=P(X\leq x)$, onde f é f.d.p

Área correspondente a F(x)

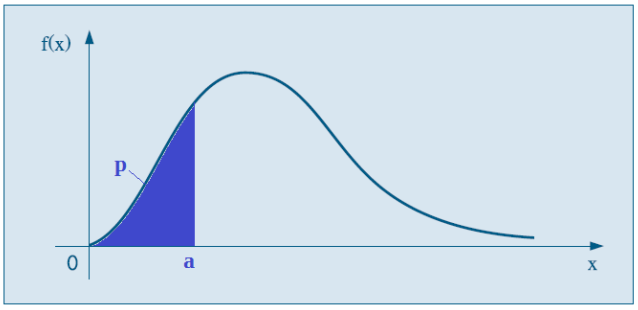

Observações

(1ª) Lembrando o Teorema Fundamental do Cálculo para integrais,

$$F(b)-F(a)=\int_a^b f(x)dx$$, ou seja, F é dita a "primitiva" de f

(2ª) É importante a distinção entre F e f. A letra maiúscula fica reservada à função acumulada.

(3ª) No caso contínuo a F.d.a. será útil para calcular probabilidades.

Propriedades:

(1ª) $0 \leq F(x) \leq 1$

(2ª) $\lim_{x \to -\infty} F(x)=0$ e $\lim_{x \to +\infty} F(x)=1$

(3ª) F é contínua e não decrescente em R

(4ª) $f(x)=\frac{d}{dx}F(x)$ se F for derivável em x
$=0$ se F não for derivável em x

(5ª) $P(a \leq X \leq b)=P(a<X \leq b)=P(a \leq X<b)=P(a<X<b)=F(b)-F(a)$, pois
$P(X=a)=P(X=b)=0$

$P(X \geq a)=P(X>a)=1-F(a)$.

Exemplo 4.2: seja a fdp a seguir

$$f(x)=\begin{cases} 0\,;x<1 \\ Kx\,;1 \leq x<2 \\ Kx^2;2 \leq x<3 \\ K(16-x^2);3 \leq x<4 \\ 0\,;x \geq 4 \end{cases}$$

(a) Faça o gráfico da densidade

(b) Encontre o valor da constante K

(b) Obtenha a Fda e faça o gráfico

(d) Usando a Fda obtenha $P(X \leq 1{,}5)$, $P(X>3{,}2)$ e $P(2{,}7 \leq X \leq 3{,}8)$

Solução:

(a)

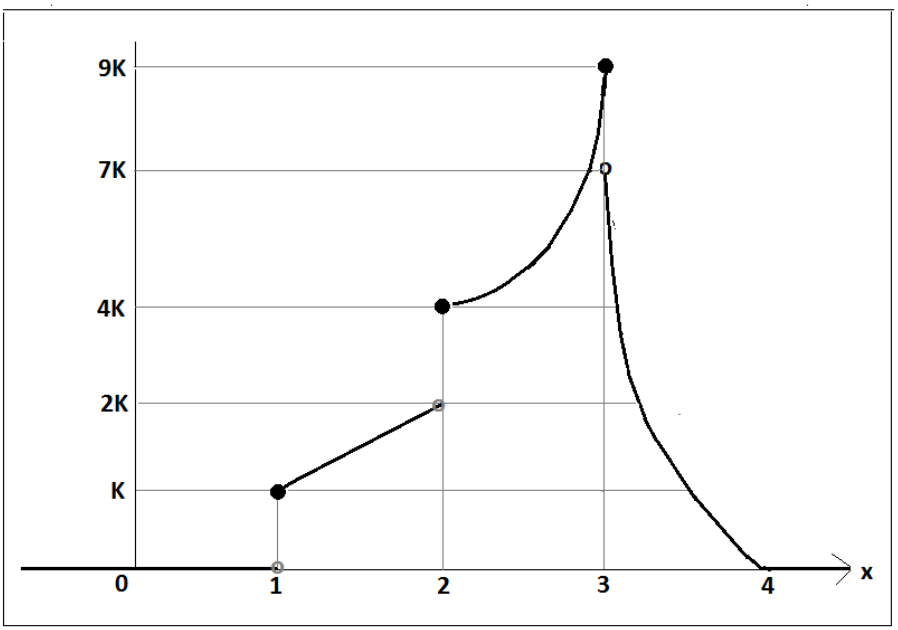

(b)

$$K\left[\int_1^2 x\,dx+\int_2^3 x^2\,dx+\int_3^4 (16-x^2)\,dx\right]=1$$

$$K=\frac{6}{69}$$

a (c)

$x<1$: $$F(x)=\int_{-\infty}^{x} f(y)\,dy=\int_{-\infty}^{x} 0\,dy=0$$

$1\le x<2$: $$F(x)=\int_{-\infty}^{x} f(y)\,dy=\int_{-\infty}^{1} 0\,dy+K\int_1^x y\,dy=\frac{3x^2-3}{69}$$

$2\le x<3$: $$F(x)=\int_{-\infty}^{x} f(y)\,dy=\int_{-\infty}^{1} 0\,dy+K\int_1^2 y\,dy+K\int_2^x y^2\,dy=\frac{2x^3-7}{69}$$

$3\le x<4$:

$$F(x)=\int_{-\infty}^{x} f(y)\,dy=\int_{-\infty}^{1} 0\,dy+K\int_1^2 y\,dy+K\int_2^3 y^2\,dy+K\int_3^x (16-y^2)\,dy=\frac{-2x^3+96x-187}{69}$$

$x\ge 4$: $$F(x)=\int_{-\infty}^{x} f(y)\,dy=\int_{-\infty}^{1} 0\,dy+K\int_1^2 y\,dy+K\int_2^3 y^2\,dy+K\int_3^4 (16-y^2)\,dy+\int_x^{\infty} 0\,dy=1$$

$$F(x)=\begin{cases} 0\,;x<1 \\ \dfrac{3x^2-3}{69}\,;1\le x<2 \\ \dfrac{2x^3-7}{69}\,;2\le x<3 \\ \dfrac{-2x^3+96x-187}{69}\,;3\le x<4 \\ 1\,;x\ge 4 \end{cases}$$

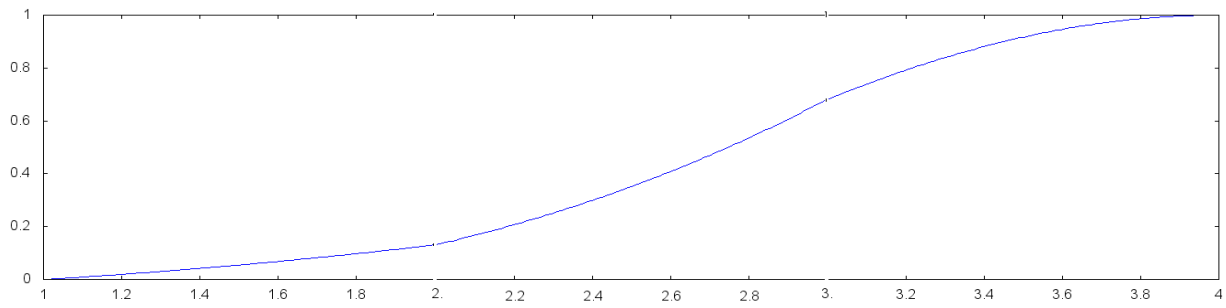

(d) $P(X\le 1{,}5)=F(1{,}5)=0{,}0543$

$P(X>3{,}2)=1-F(3{,}2)=1-0{,}7922=0{,}2078$

$P(2{,}7\le X\le 3{,}8)=F(3{,}8)-F(2{,}7)=0{,}5172$

4.4 - Esperança e variância de variáveis aleatórias contínuas

Esperança: $EX=\int_{-\infty}^{+\infty} xf(x)dx$

condição de existência: $E|X|=\int_{-\infty}^{+\infty} |x|f(x)dx<\infty$

Variância: $Var(X)=\int_{-\infty}^{+\infty} (x-EX)^2 f(x)dx=E(X^2)-(EX)^2$, onde $E(X^2)=\int_{-\infty}^{+\infty} x^2 f(x)dx$

condição de existência: $E|X|^2<\infty$

Importante: mesmas propriedades da esperança e variância são válidas para o caso contínuo.

Exemplo 4.3: o diâmetro X de um cabo elétrico é uma v.a contínua com fdp dada a seguir:

$$f(x)=\begin{cases} 0\,;x<0 \\ Kx(2-x);0\leq x<1 \\ 0\,;x\geq 1 \end{cases}$$

(a) Faça o gráfico da densidade

(b) Determine K

(c) Calcule E(X), Var(X) e DP(X)

Solução:
(a)

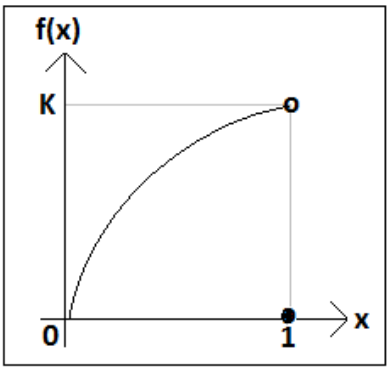

(b) $K\int_0^1 x(2-x)\,dx=1\Rightarrow K=1{,}5$

(c)

$$E(X)=\int_0^1 x\times 1{,}5\times x(2-x)\,dx=0{,}625$$

$$E(X^2)=\int_0^1 x^2\times 1{,}5\times x(2-x)\,dx=0{,}45$$

$$Var(X)=0{,}45-(0{,}625)^2=0{,}0594$$

4.5 - Mediana e Moda de variáveis aleatórias contínuas

Definição: a mediana é o valor x tal que $F(x)=\int_{-\infty}^{x} f(y)\,\mathrm{dy}=\frac{1}{2}$.

Notação: Md

Definição: a moda é o valor x tal que $f(x)>f(y)$, para $\forall\, y\in R$. Pode haver mais de uma moda. Quando não houver máximo, então diremos que a moda não existe.

Notação: Mo

Exemplo 4.4: seja a v.a. com função densidade dada por:

$$f(x)=\begin{cases} 0\,;x<0 \\ \frac{3}{4}x^2(2-x);0\leq x\leq 2 \\ 0\,;x>2 \end{cases}$$

(a) Faça o gráfico da densidade

(b) Obtenha $E(X)$; Moda e Mediana:
Solução:

(a)

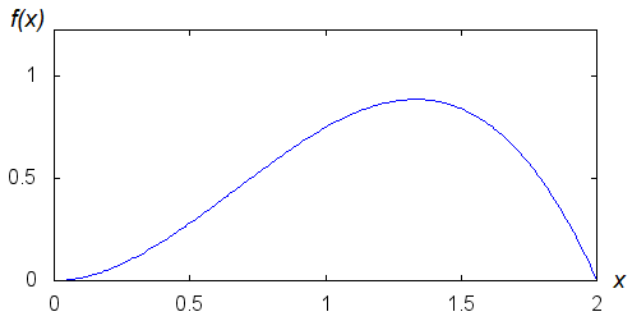

(b) Pelo gráfico, a priori podemos observar que $E(X)<\text{Md}<\text{Mo}$. Para obter a moda, devemos resolver a equação $\frac{\text{df}}{\text{dx}}=0$, ou seja, $\frac{3}{4}(4x-3x^2)=0$, cuja solução é $x=\frac{4}{3}$. Assim, $Moda=\frac{4}{3}$.

$$E(X)=\frac{3}{4}\int_0^2 x^3(2-x)\,\text{dx}=1{,}2.$$

Obtendo a mediana:

$$P(X\leq m)=0{,}5$$

$$\frac{3}{4}\int_0^m (2x^2-x^3)\,\text{dx}=0{,}5\Leftrightarrow 3m^4-8m^3+8=0$$

A equação $3m^4-8m^3+8=0$ tem quatro raízes, onde duas são complexas e duas são reais. Das raízes reais, somente uma delas está no intervalo [0; 2]. Utilizando o computador serão fornecidas as raízes: 1,2285448 ; -052842+0,768608i ; -052842-0,768608i; 2,494964. Portanto, $\text{Md}=1{,}2285448$.

Observação: para obter a esperança, mediana e moda pode ser utilizado um software numérico, por exemplo o MatLab, ou o site SymboLab, que poderá ser utilizado sem instalar nenhum software.

Medidas de tendência central em densidades simétricas

Em densidades simétricas e unimodais $E(X)=Md=Mo$.

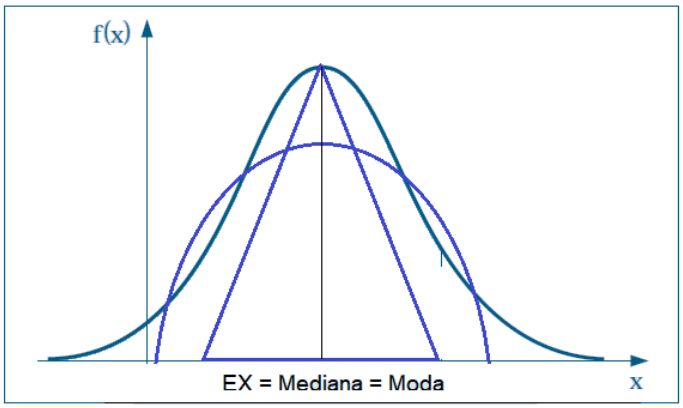

4.6 - Modelos probabilísticos contínuos

4.6.1 - Modelo Uniforme contínuo

Notação: $U[a,b]$

Função densidade de probabilidade:

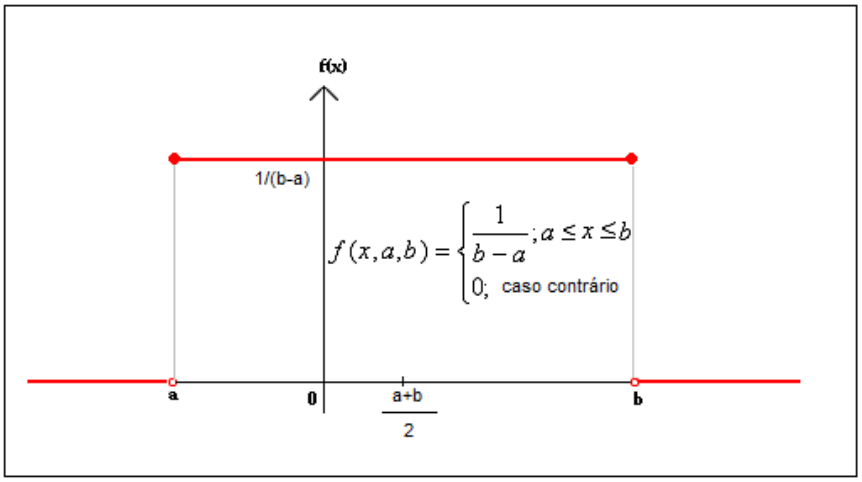

Função de distribuição acumulada

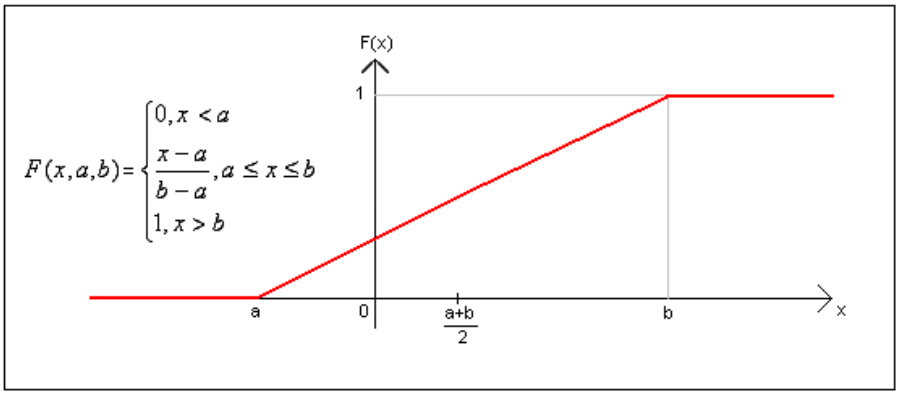

Esperança e variância: $EX=\frac{a+b}{2}$; $Var(X)=\frac{(b-a)^2}{12}$

Exemplo 4.5: Os geradores de números pseudoaleatórios, de calculadoras e computadores, têm distribuição uniforme contínua em [0,1). Por exemplo, no **EXCEL** o comando é : ALEATORIO( ). Por exemplo, foram gerados 18 números:

0,156829637	0,846649578	0,469263346	0,577564193	0,664633565	0,462117229
0,973857121	0,964847015	0,968308066	0,981239892	0,322957938	0,118940193
0,937166033	0,135396175	0,840436215	0,023279616	0,431708782	0,587640809

A média desses valores gerados é 0,495327.

Exemplo 4.6: considere um relógio circular de ponteiros. O relógio pode parar, por falta de bateria, em qualquer quadrante. Defina X o ângulo formado pelo ponteiro maior quando o relógio parar. Determinar:

(a) fdp (b) fda (c) probabilidade do ponteiro parar entre -90 e 0 graus

Solução:

(a) $f(x)=\begin{cases} 0; x<-360 \\ \frac{1}{360}; -360\le x\le 0 \\ 0; x>0 \end{cases}$ (b) $F(x)=\begin{cases} 0; x<-360 \\ \frac{x+360}{360}; -360\le x\le 0 \\ 1; x>1 \end{cases}$

(c) $P(-90\le X\le 0)=F(0)-F(-90)=\frac{360}{360}-\frac{-90+360}{360}=\frac{1}{4}$

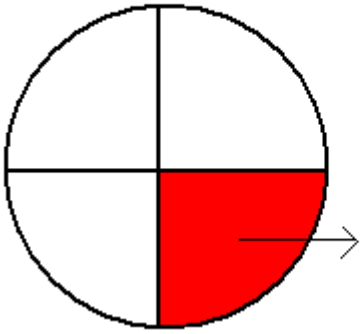

4.6.2 - Modelo Exponencial

Este modelo possui aplicações em diversas áreas: Biologia, Engenharia, Computação. Na Teoria da Confiabilidade está associada à probabilidade de falha de componentes em um sistema.

Notação: $Expon(\lambda)$

Função densidade de probabilidade: $f(x,\lambda)=\begin{cases} 0; x\le 0 \\ \lambda\times\exp(-\lambda\times x); x>0 \end{cases}$, $\lambda>0$

Gráfico da densidade exponencial

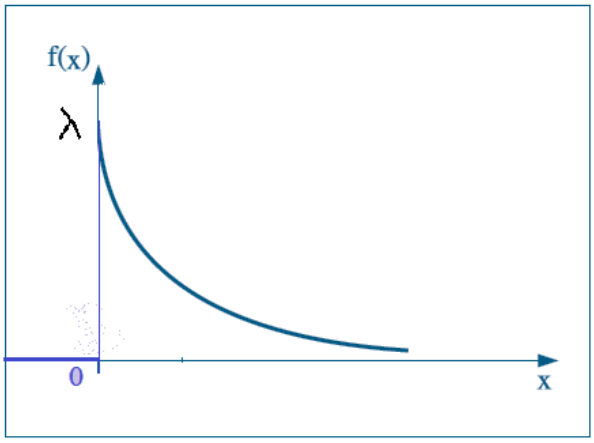

Observações:

(1ª) A notação $\exp(x)$ equivale a e^x

(2ª) O parâmetro λ é a taxa (intensidade) de sucessos (ou fracassos)

(3ª) Existe relação entre a distribuição exponencial e a Poisson. A exponencial é o tempo de espera até que ocorra um sucesso (ou fracasso) na distribuição de Poisson.

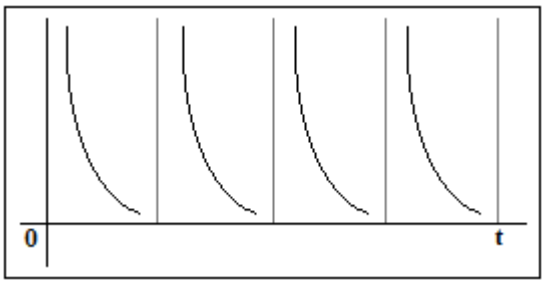

Função de distribuição acumulada: $F(x)=\begin{cases} 0; x\leq 0 \\ 1-\exp(-\lambda\times x); x>0 \end{cases}$

Gráfico da função acumulada da exponencial

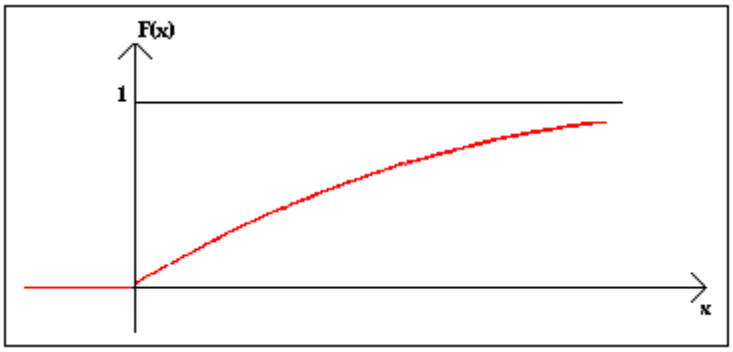

Esperança e variância da exponencial: $EX=\frac{1}{\lambda}$, $Var(X)=\frac{1}{\lambda^2}$

Observação: quanto menor a taxa de falhas, maior será o tempo médio de duração do componente (veja figura abaixo).

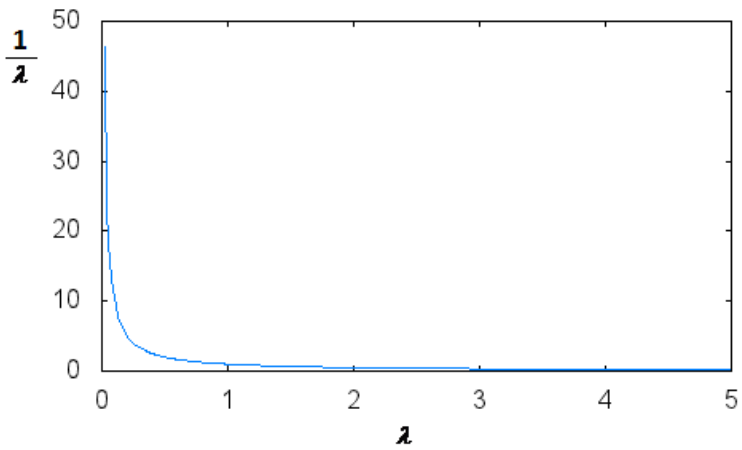

Exemplo 4.7: a duração média de uma lâmpada led 6W é 25000 horas (2,89 anos). Suponha que para uma certa marca, a duração segue distribuição exponencial de média 25000 h, e que o custo de produção seja 12,00.

(a) Qual a probabilidade da lâmpada durar mais que a média?

(b) Com um preço de venda de 15,00, se a fábrica garantir duração mínima de 6000 h, qual o lucro esperado por lâmpada?

(c) Para ter um lucro médio mínimo de 2,00, com garantia de 6000 h, qual deve ser o preço de venda mínimo?

(d) Se o fabricante adotar a garantia prevista no CDC, que é de 90 dias (2160 h), com preço de venda 15,00, qual o lucro esperado?

Solução: seja T o tempo de duração lâmpada.

(a) $\lambda = \frac{1}{\mu} = \frac{1}{25000}$

$$P(T > E(T)) = P(T > 25000) = 1 - F(25000) = 1 - \left(1 - \exp\left\{-\frac{25000}{25000}\right\}\right) = \exp\{-1\} = 0{,}3679$$

(b) $L = \begin{cases} -12\,; T < 6000 \\ 3\,; T \geq 6000 \end{cases}$

$$E(L) = -12 \times P(T < 6000) + 3 \times P(T \geq 6000) = -12 \times F(6000) + 3 \times (1 - F(6000)) =$$
$$= -15 \times F(6000) + 3 = 15 \times \exp\left\{-\frac{6}{25}\right\} - 12 = 0{,}20$$

(c) vamos denotar por V o preço de venda. Assim, $E(L) = V \times \exp\left\{-\frac{6}{25}\right\} - 12 \geq 2{,}00$

Resolvendo a inequação, $V \geq 17{,}80$.

(d) $E(L) = 15 \times \exp\left\{-\frac{2160}{25000}\right\} - 12 = 1{,}76$

4.6.3 - A distribuição Normal (Gaussiana)

A distribuição Normal é de grande importância em Probabilidade e em Inferência Estatística. A distribuição normal foi introduzida pela primeira vez por Abraham de Moivre em um artigo no ano 1733. O nome "distribuição normal", foi criado por Charles S. Peirce, Francis Galton e Wilhelm Lexis, em 1875.

Exemplo 4.8 (algumas aplicações da normal):

(1º) distribuição das alturas de pessoas

(2º) distribuição dos valores de depósitos bancários

(3º) distribuição do quociente intelectual (QI)

(4º) distribuição da produção de cereais

Função densidade: a fdp tem forma de "sino" e tem dois parâmetros: $\mu \in R$ e $\sigma > 0$.

$$f(x,\mu,\sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \times \exp\left\{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right\}, \qquad -\infty < x < +\infty$$

Notação: $N(\mu,\sigma)$

Gráfico da densidade normal

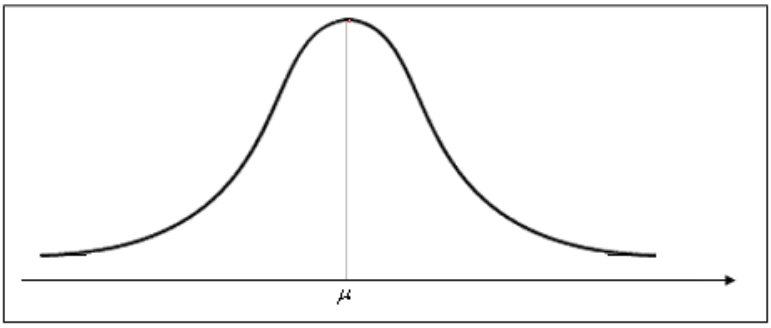

Propriedades da distribuição normal:

(1ª) $f(x) > 0$, $\lim_{x \to -\infty} f(x) = 0$ e $\lim_{x \to +\infty} f(x) = 0$

(2ª) A área sob a densidade f é igual a 1.

(3ª) $EX = Md = Mo = \mu$ (que é o ponto de máximo) , ou seja, a densidade é simétrica em torno da média.

(4ª) $Var(X)=\sigma^2$; $DP(X)=\sigma$. Quanto maior for σ mais achatada (baixa) será a fdp

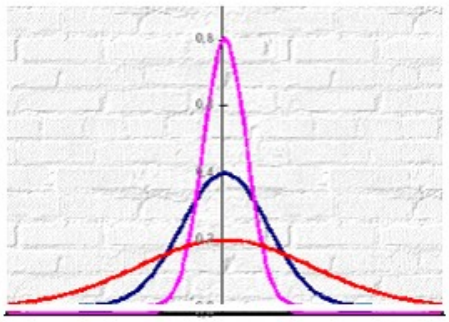

Distribuições normais: N(0; 1/2), N(0; 1) e N(0; 2)

(5ª)

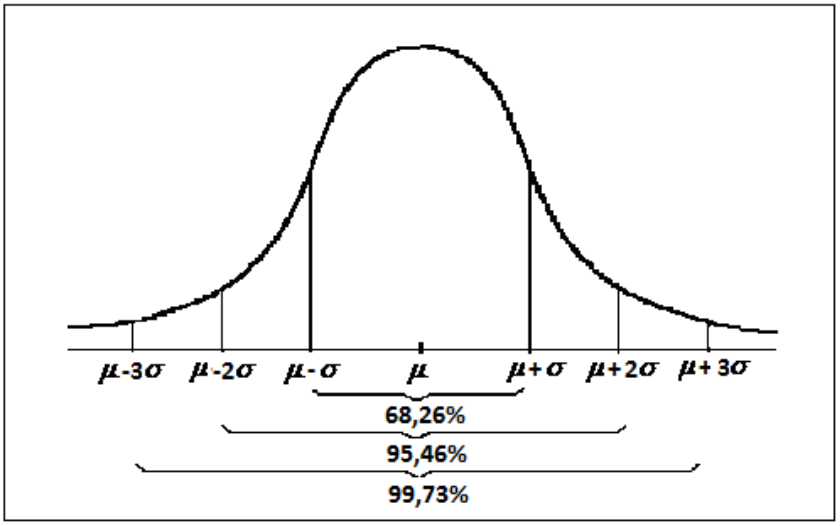

$P(X<\mu-4\times\sigma)\simeq 0$; $P(X>\mu+4\times\sigma)\simeq 0$, logo, $P(\mu-4\times\sigma\leq X\leq\mu+4\times\sigma)\simeq 1$

(6ª) Se X é $N(\mu,\sigma)$ então $Z=\dfrac{X-\mu}{\sigma}$ é $N(0,1)$. A transformação Z é dita padronização da v.a. normal.

Tabulação da distribuição Normal padrão

No caso da distribuição normal a integral $\Phi(z)=\int_{-\infty}^{z}\frac{1}{\sqrt{2\pi}}e^{-u^2/2}du$ existe e fica entre (0, 1). O problema é que não conhecemos a forma funcional de Φ. O Teorema Fundamental do Cálculo garante que Φ existe e é única, mas não diz como obtê-la. Até os dias atuais não se sabe a forma funcional, por isso tem-se que recorrer à integração numérica.

A integral $\Phi(z)=\int_{-\infty}^{z}\frac{1}{\sqrt{2\pi}}\times e^{-u^2/2}du$ é aproximada por integração numérica, gerando uma tabela. Atualmente calculadoras já tem incorporadas funções que fazem o cálculo aproximado para esta integral.

Seja $\mathbf{Z}$ $N(0;1)$. A função de distribuição acumulada de Z é denotada por $\Phi(z)=P(Z\leq z)=\int_{-\infty}^{z}\frac{1}{\sqrt{2\pi}}\exp\left\{\frac{x^2}{2}\right\}dx$, a qual corresponde à área na figura abaixo:

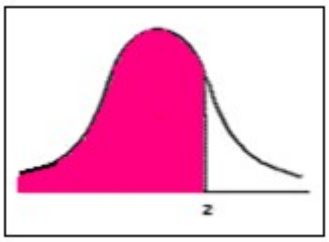

Gráfico aproximado da função $\Phi(z)$ **:**

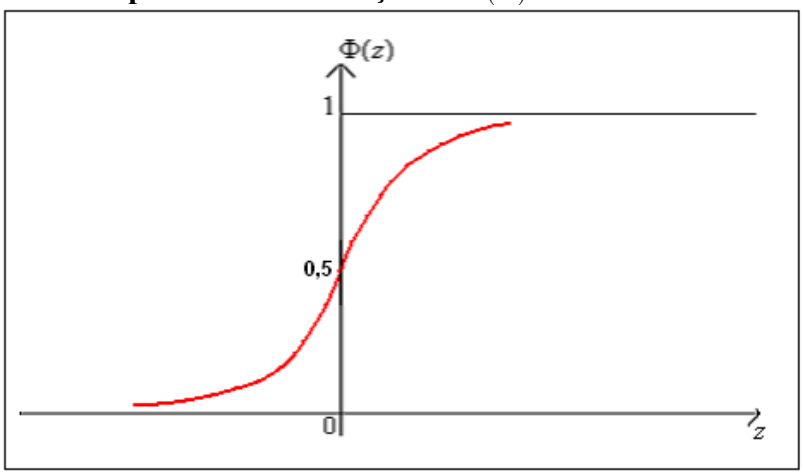

Propriedades de Φ

(1ª) $\lim_{z\to-\infty}\Phi(z)=0$, $\lim_{z\to+\infty}\Phi(z)=1$

(2ª) $\Phi(0)=0{,}5$

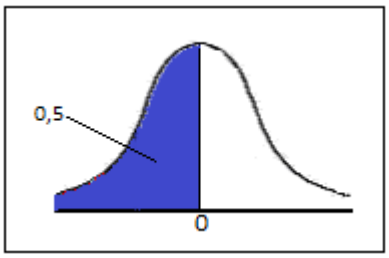

(3ª) $P(a\leq Z\leq b)=\Phi(b)-\Phi(a)$

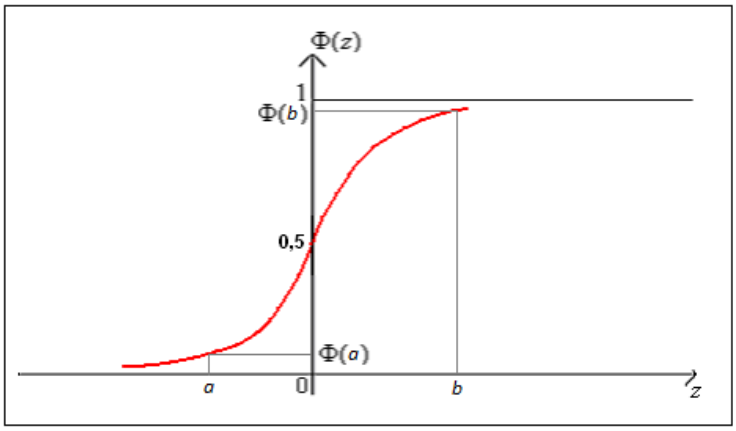

(4ª) $P(Z \geq b) = 1 - \Phi(b)$

(5ª) $\Phi(z) = 1 - \Phi(-z)$, devido a simetria da densidade

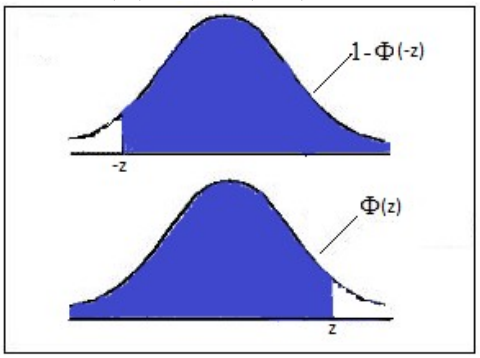

(6ª) Se X é $N(\mu;\sigma)$ é preciso padronizá-la , para poder usar a tabela da normal padrão.

$$P(a \leq X \leq b) = P\left(\frac{a-\mu}{\sigma} \leq \frac{X-\mu}{\sigma} \leq \frac{b-\mu}{\sigma}\right) = P\left(\frac{a-\mu}{\sigma} \leq Z \leq \frac{b-\mu}{\sigma}\right) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$$

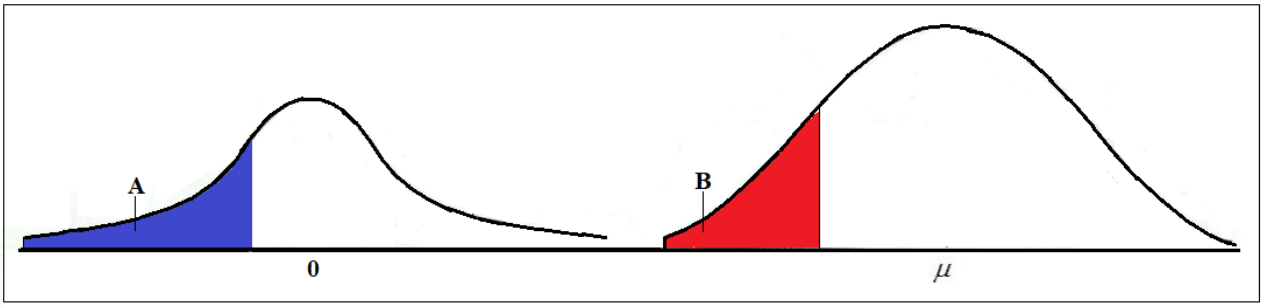

Nota: Na figura acima, as áreas A e B têm formas diferentes, mas mesmo valor.

Tabela de Φ **:** fornece $P(Z \leq z)$, $z \in [-3,79;3,79]$, que é a área hachurada na figura abaixo. No exemplo, $P(Z \leq 1,27) = 0,8980$.

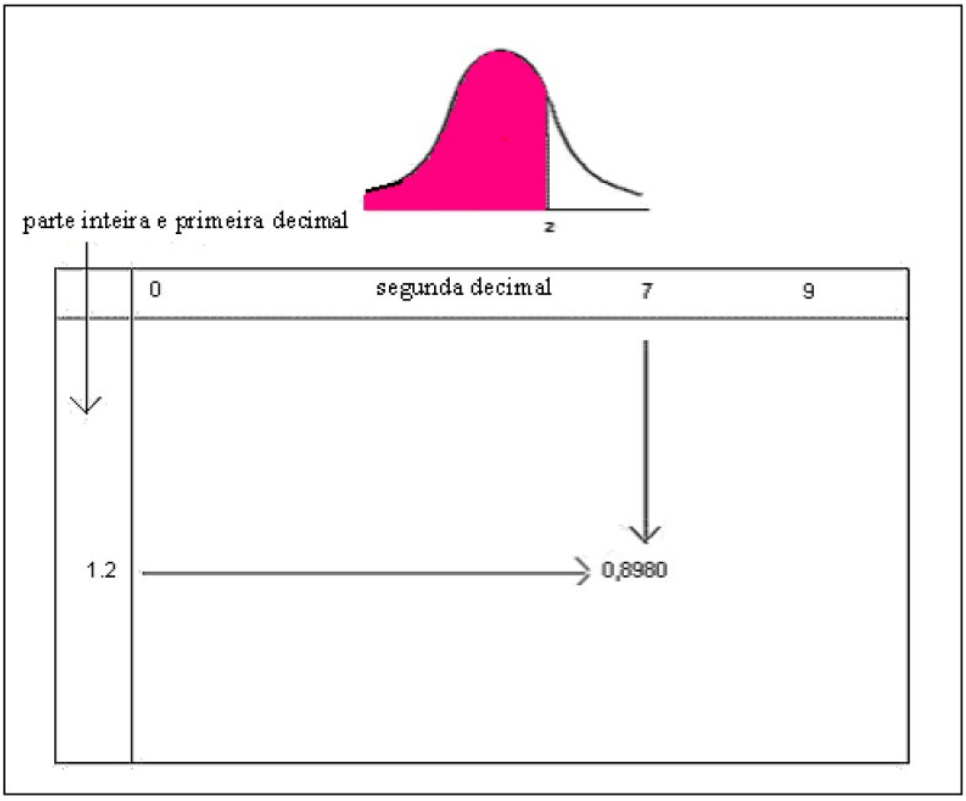

A tabela da Função Distribuição acumulada da normal pode ser utilizada de duas maneiras. Na ilustração abaixo, à esquerda, quando temos a coordenada e queremos obter a área inferior, ou seja, $\alpha = P(Z \leq z) = \Phi(z)$. Na ilustração à direita, quando temos a área inferior e precisamos saber qual a coordenada, ou seja, $z = \Phi^{-1}(\alpha)$.

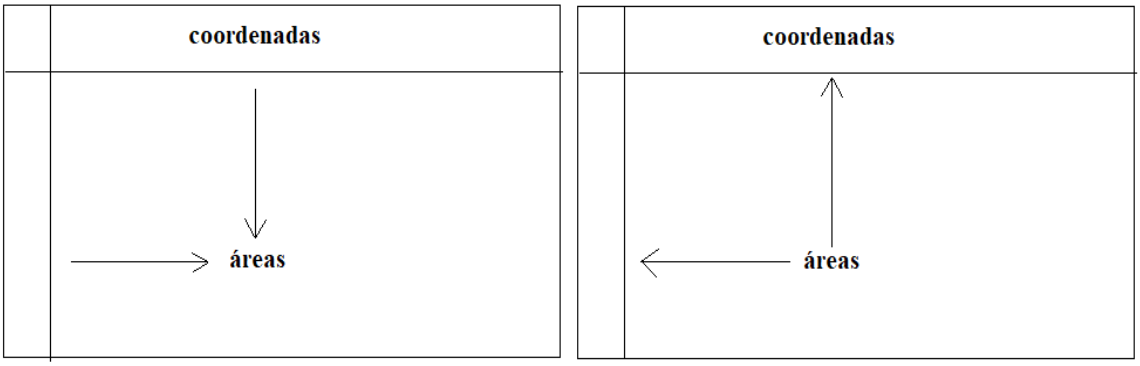

Uma vez que a tabela da função de distribuição acumulada tem dois dígitos após a vírgula, não haverá toda área (probabilidade) que desejamos. Por exemplo, não encontraremos a área 0,95.

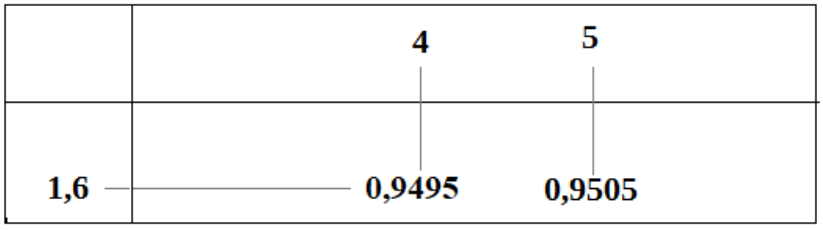

Neste caso é feita uma interpolação linear (em uma curva que não é linear!) na função acumulada. Esta é a maneira empírica de resolver o problema, e que autores adotam. Sendo assim, $z=\frac{1,64+1,65}{2}=1,645$ será uma aproximação da coordenada tal que a área inferior é 0,95. Se você utilizar um software vai encontrar 1,64485363.

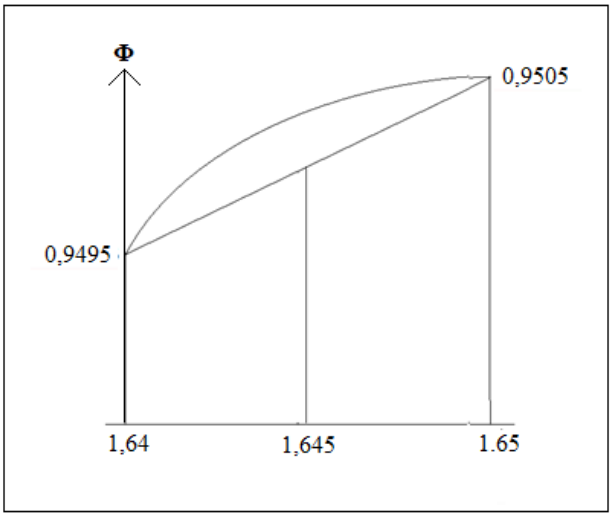

Exemplo 4.9: Seja Z $N(0;1)$. Obtenha:

(a) $P(Z\leq 1)$ (b) $P(Z\leq 1,57)$ (c) $P(-1,96\leq Z\leq 1,96)$ (d) $P(Z\geq 1,64)$

(e) $P(|Z|\leq 1,33)$ (f) $P(|Z|>1,50)$ (g) $P(Z\leq -4)$

Solução:

(a) $P(Z\leq 1)=\Phi(1,00)=0,8413$

	0
1,0	0,8413

(b)$P(Z\leq 1,57)=\Phi(1,57)=0,9418$

	7
1,5	0,9418

(c) $P(-1,96\leq Z\leq 1,96)=\Phi(1,96)-\Phi(-1,96)=0,9750-0,025=0,95$

(d) $P(Z\geq 1,64)=1-\Phi(1,64)=1-0,9495=0,0505$

(e) Aqui usamos a propriedade $|x|\leq a\Leftrightarrow -a\leq x\leq a$

$$P(|Z|\leq 1,33)=P(-1,33\leq Z\leq 1,33)=P(Z<1,33)-P(Z<-1,33)=\Phi(1,33)-\Phi(-1,33)=$$
$$=0,9082-0,0918=0,8164$$

Outra maneira, pela simetria da densidade,
$P(|Z|\leq 1{,}33)=1-2\times\Phi(-1{,}33)=1-2\times 0{,}0918=0{,}8164$

(f) Aqui usamos a propriedade $|x|\geq a \Leftrightarrow x\leq -a$ ou $x\geq a$

$$P(|Z|>1{,}50)=P(Z<-1{,}50 \text{ ou } Z>1{,}50)=P(Z\leq -1{,}50)+P(Z\geq 1{,}50)=$$
$$=\Phi(-1{,}50)+(1-\Phi(1{,}50))=0{,}1336$$

Outra maneira, pela simetria da densidade, $P(|Z|>1{,}50)=2\times\Phi(-1{,}50)=0{,}1336$

(g) $P(Z\leq -4)=\Phi(-4)=0$ e $P(Z\geq 4)=1-\Phi(4)=1-1=0$. Mas, pelo computador $P(Z\leq -4)=0{,}000031671242$, ou seja, na tabela a área foi arredondada para zero.

Exemplo 4.10: As notas da disciplina de Direito Tributário de uma determinada faculdade tem distribuição segundo uma normal de média 6,4 e desvio padrão 0,8. Os conceitos são atribuídos de acordo com a seguinte graduação:

Notas	Conceito
$0\leq X<5$	D
$5\leq X<7{,}5$	C
$7{,}5\leq X<9$	B
$9\leq X\leq 10$	A

Em uma classe de 80 alunos, qual o número esperado de conceitos A, B, C e D?

Solução:

$$P(0\leq X<5)=P\left(\frac{0-6{,}4}{0{,}8}\leq\frac{X-6{,}4}{0{,}8}<\frac{5-6{,}4}{0{,}8}\right)=P(-8\leq Z<-1{,}75)=$$
$$=\Phi(-1{,}75)-\Phi(-8)=0{,}0401-0=0{,}0401$$

$$P(5\leq X<7{,}5)=\Phi(1{,}38)-\Phi(-1{,}75)=0{,}9162-0{,}0401=0{,}8761$$
$$P(7{,}5\leq X<9)=\Phi(3{,}25)-\Phi(1{,}38)=0{,}9994-0{,}9162=0{,}0832$$
$$P(9\leq X\leq 10)=\Phi(4{,}5)-\Phi(3{,}25)=1-0{,}9994=0{,}0006$$

Notas	Probabilidade	Probabilidade $\times N$
$0\leq X<5$	0,0401	3
$5\leq X<7{,}5$	0,8761	70
$7{,}5\leq X<9$	0,0832	7
$9\leq X\leq 10$	0,0006	0

Tabela da Normal Padrão Inversa: Φ^{-1} **:** fornece as coordenadas tais que $z=\Phi^{-1}(\alpha)$, ou seja:

$P(Z\geq z^{(u)})=\alpha$ (áreas unilaterais superiores)

$P(|Z|\geq z^{(b)})=\alpha$ (áreas bilaterais)

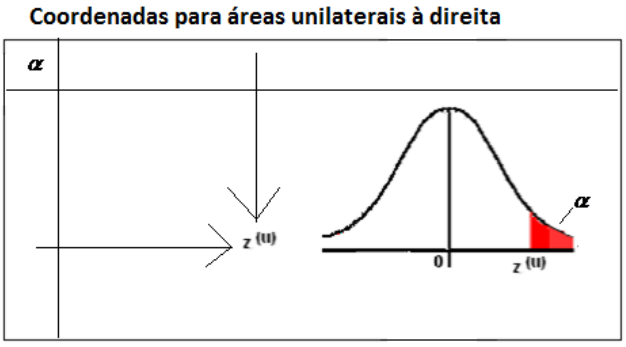

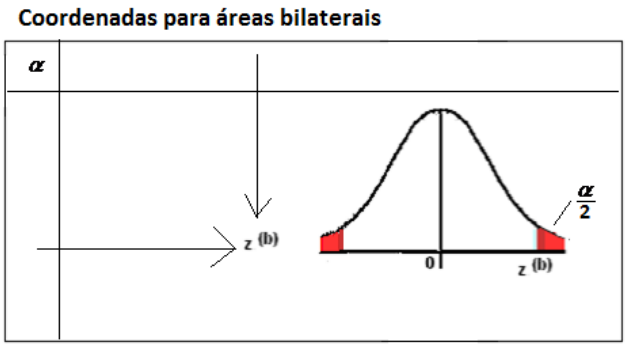

A tabela tem duas utilidades. Na ilustração abaixo, à esquerda, quando temos a área e queremos obter a coordenada. $z=\Phi^{-1}(\alpha)$. Para esta tabela há dois tipos de áreas, a bilateral e unilateral à direita. Também pode-se utilizar de outra maneira, como a figura à direita, quando temos a coordenada e queremos a área.

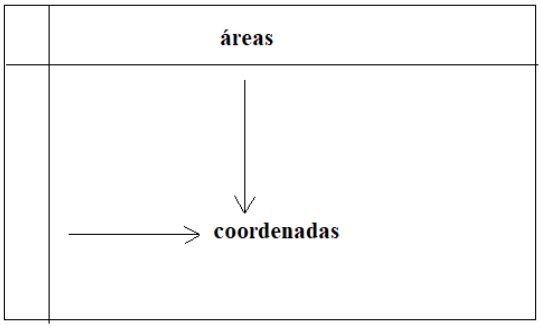

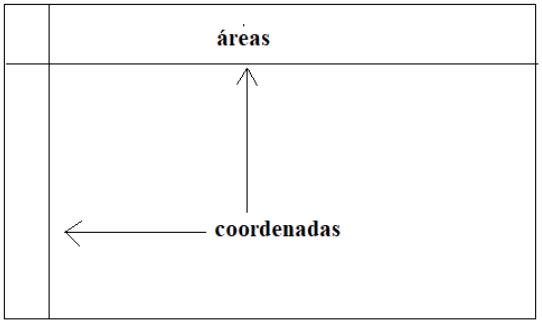

Exemplo 4.11: Para uma normal padrão, obtenha z tal que :

(a) $P(Z\leq z)=0,9750$ (b) $P(Z\leq z)=0,95$ (c) $P(Z\leq -z)=0,01$

(d) $P(-z\leq Z\leq z)=0,95$

Solução:

(a) Na tabela da normal inversa, com a área unilateral de 0,025, $z=1,96$ como mostra a figura.

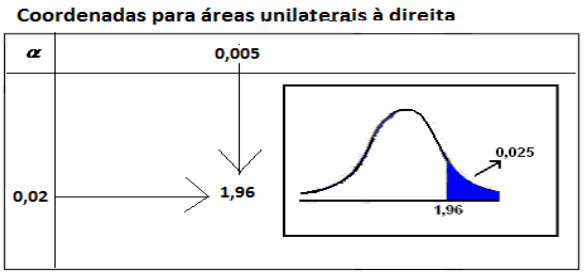

(b)

Coordenadas para áreas unilaterais à direita

α	0,000
0,05	1,6449

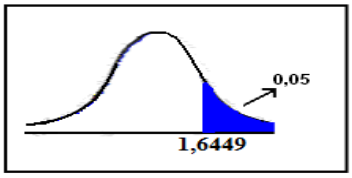

O valor da coordenada é z=1,6449

(c) Neste caso, a área deseja é a cauda inferior. Pela tabela da normal inversa, obtemos z = 2,3263, e portanto - z = -2,3263.

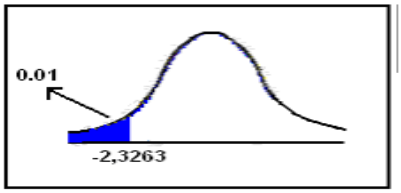

(d) Pela tabela da normal inversa com área bilateral de 0,05 , z=1,96.

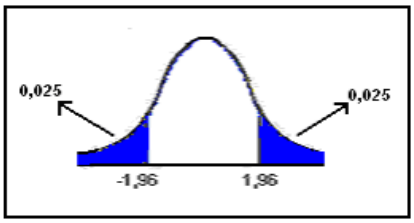

Exemplo 4.12: uma variável X tem distribuição normal com desvio padrão $\sigma=5$ e tal que 1,5% dos valores estão abaixo de 35.

(a) Qual a média μ ?

(b) Se forem obtidos 20 valores, independentemente um do outro, qual a probabilidade de que metade deles sejam menores que $0{,}9\times\mu$?

Solução:

(a) $P(X<35)=P\left(\frac{X-\mu}{5}<\frac{35-\mu}{5}\right)=P\left(Z<\frac{35-\mu}{5}\right)=0{,}015$, sendo $Z=\frac{X-\mu}{\sigma}$ normal padrão. Uma vez que dispomos da tabela inversa da normal padrão para áreas superiores, a coordenada tal que $P(Z>z)=0{,}015$ é z=2,1701. Logo, $P(Z<-2{,}1701)=0{,}015$. Agora temos que resolver a equação:

$$\frac{35-\mu}{5}=-2{,}1701\Rightarrow\mu=45{,}85$$

(b) Vamos denotar Y = nº de valores que são menores que $0{,}9\times\mu$. A variável Y é Binomial de parâmetros n=20 e $p=P(X<0{,}9\times\mu)=P(Z<-0{,}92)=\Phi(-0{,}92)=0{,}1788$. A probabilidade de 10 dos 20 valores serem menores que $0{,}9\times\mu$ é $P(Y=10)=C_{20}^{10}\times p^{10}\times(1-p)^{10}=0{,}00086$.

5ª Parte - Amostragem e estimação de parâmetros

5.1 – Definições

Tipos de amostragem probabilística:

*** Simples**
*** Sistemática**
*** Estratificada**
*** Por conglomerados**

Aqui nos concentraremos na amostragem aleatória simples (aas). Uma aas pode ser extraída de uma população de acordo com os critérios:

(a) com reposição **(b)** sem reposição.

Se a população for infinita então as retiradas com e sem reposição serão equivalentes, isto é, se a população for infinita (ou então muito grande), o fato de se recolocar o elemento retirado de volta na população não vai afetar em quase nada a probabilidade de extração do elemento seguinte. Se, no entanto, a população for finita (e pequena) será necessário fazer uma distinção entre os dois procedimentos, pois na extração com reposição as diversas retiradas serão independentes, mas no processo sem reposição haverá dependência entre as retiradas, isto é, o fato de não recolocar o elemento retirado afeta a probabilidade do elemento seguinte ser retirado. A amostragem sem reposição é mais eficiente que a amostragem com reposição e reduz a variabilidade, uma vez que não é possível retirar elementos extremos mais de uma vez.

(a) Com reposição

P(uma amostra de tamanho n)= $\dfrac{1}{N^n}$

(b) Sem reposição

P(uma amostra de tamanho n) = $\dfrac{1}{C_N^n}$, desconsiderando a ordenação na amostra

$\dfrac{1}{A_N^n}$, considerando a ordenação na amostra

Exemplo 5.1: suponha que em um município existam 60 escolas de ensino fundamental da rede municipal. Está-se interessado em avaliar o número de matrículas durante o ano. Para tal, optou-se por uma amostragem aleatória simples sem reposição de tamanho 15.

Solução:

População: escolas municipais de ensino fundamental

Unidade amostral: escolas municipais

Variável de interesse: número de matrículas

N=60; n=15

P(uma escola qualquer ser escolhida no 1º sorteio)= $\frac{1}{60}$

P(uma amostra qualquer)= $\frac{1}{C_{60}^{15}}$

Parâmetros e Estatísticas

Definição 5.1: denomina-se amostra aleatória a $n-upla$ $(X_1, X_2, \ldots, X_n)$ de v.a´s com mesma distribuição de probabilidade.

Exemplo 5.2: $(X_1, X_2, \ldots, X_n)$com distribuição binomial de parâmetros m e p .

Definição 5.2: um parâmetro é uma medida usada para descrever uma característica da população.

Exemplo 5.3: $\theta = 0{,}85$ é a proporção de pessoas com fator RH+

Exemplo 5.4: a função produção é definida como $Y = \alpha \times Q^{\beta}$, sendo Y o valor do produto, Q a quantidade produzida e $\alpha ; \beta$ parâmetros.

Definição 5.3: uma estatística (ou estimador) é uma característica da amostra, isto é, uma estatística é uma função de $(X_1, X_2, \ldots, X_n)$.

Notação: $T = f(X_1, X_2, \ldots . X_n)$

Exemplo 5.5: $P = \frac{\sum_{i=1}^{n} X_i}{n}$, onde $X_i =$ 1, se for RH+

$X_i =$ 0, se for RH-

Nota: uma vez que a estatística é função de v'a.s, então também será aleatória.

Definição 5.4: uma estimativa é um valor particular assumido pelo estimador $t = f(x_1, x_2, \ldots . x_n)$

Observação: por convenção representamos a amostra observada (e as estimativas) por letras minúsculas.

Exemplo 5.6: numa amostra de 30 pessoas, 25 tem RH+. Assim, $p=\frac{25}{30}=0,83$.

Notações usuais:

Medidas	Parâmetro	Estimador	Estimativa
Média	μ	$\bar{X}=\frac{\sum_{i=1}^{k} f_i X_i}{n}$	$\bar{x}=\frac{\sum_{i=1}^{k} f_i x_i}{n}$
Variância	σ^2	$S^2=\frac{\left[\sum_{i=1}^{k} f_i X_i^2\right]-n\left(\bar{X}\right)^2}{n-1}$	$s^2=\frac{\left[\sum_{i=1}^{k} f_i x_i^2\right]-n\left(\bar{x}\right)^2}{n-1}$
Desvio padrão	σ	S	s
Amplitude	η	H	h
Proporção	θ	P	p
Correlação	ρ	R	r

5.2 - Propriedades dos Estimadores:

(1ª) Um estimador é dito não tendencioso ou não enviesado, se $E(T)=\Psi$, onde Ψ é um parâmetro populacional

Exemplo 5.7: "a média de todas médias amostrais possíveis é igual à média populacional", ou seja, $E(\bar{X})=\mu$.

Exemplo 5.8: $E(S^2)=\sigma^2$, mas $E(V^2)\neq\sigma^2$, onde $V^2=\left[\frac{\sum_{i=1}^{k} f_i X_i^2}{n}\right]-\left(\bar{X}\right)^2$.

(2ª) Uma sequência $\{T_n\}_{n\geq 1}$ de estimadores de Ψ é dita consistente se:

$\lim_{n\to\infty} E(T_n)=\Psi$ e $\lim_{n\to\infty} Var(T_n)=0$

Exemplo 5.9: como $E(\bar{X})=\mu$ e $\lim_{n\to\infty}\mathrm{Var}\left(\bar{X}\right)=\lim_{n\to\infty}\frac{\sigma^2}{n}=0$, então $\bar{X}$ é consistente.

(3ª) Se T e H são dois estimadores não tendenciosos de Ψ e $Var(T)<Var(H)$ então dizemos que T é mais eficiente que H.

Exemplificação de quatro estimadores onde foram feitas 18 observações

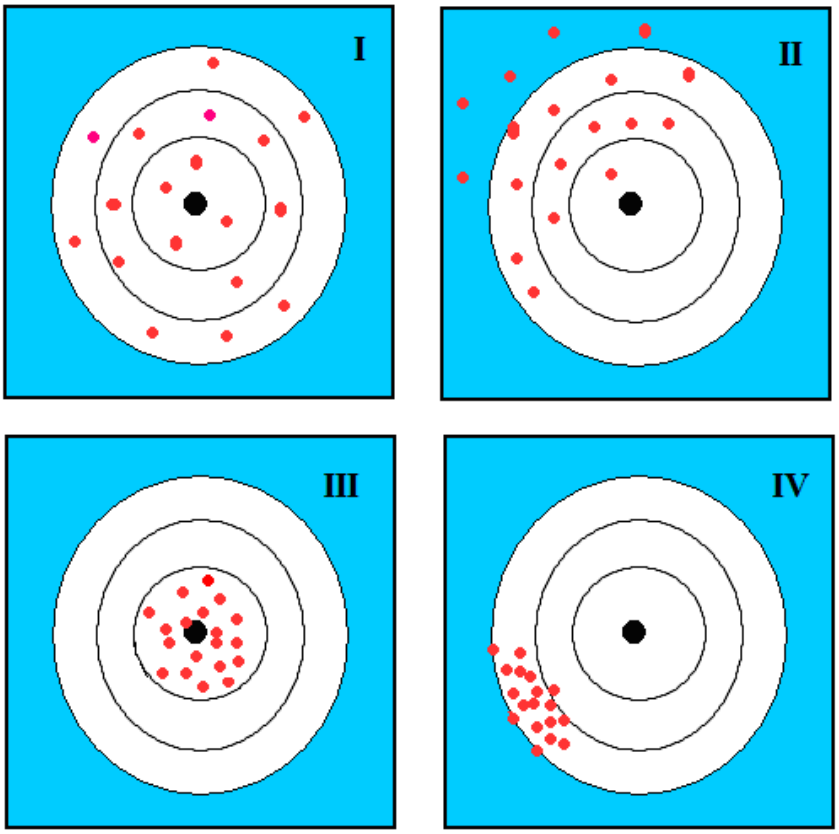

Essa figura é comum encontrar em textos de Inferência Estatística. O objetivo é fazer uma analogia com um arco e flecha e um estimador. A escolha de um arco seria aquele sem nenhum viés e com reduzida variação. A escolha natural seria a III.

Teorema 5.1: Seja X v.a com esperança μ e variância σ^2, e $X_1, X_2, \ldots . X_n$ uma amostra. Então, para $\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n}$, tem-se :

(i) $E(\bar{X}) = \mu$

(ii) $Var(\bar{X}) = \frac{\sigma^2}{n}$ se for ***com reposição*** e $Var(\bar{X}) = \frac{\sigma^2}{n} \times \left(\frac{N-n}{N-1}\right)$ para o caso ***sem reposição***.

(iii) $\bar{X}$ é o estimador de variância mínima dentre os estimadores lineares não-tendenciosos.

Observação: o quociente $\left(\frac{N-n}{N-1}\right)$ é dito fator de correção para população finita. Note que para N suficientemente grande, $Var(\bar{X})$ é próxima de $\frac{\sigma^2}{n}$.

Corolário 5.1: para $P=\frac{\sum_{i=1}^{n} X_i}{n}$, tem-se que $E(P)=\theta$,

$Var(P)=\frac{\theta\times(1-\theta)}{n}$, se for ***com reposição***

$Var(P)=\frac{\theta\times(1-\theta)}{n}\times\left(\frac{N-n}{N-1}\right)$, se for ***sem reposição***.

5.3 - Distribuições amostrais:

O conjunto de todas amostras de mesmo tamanho formam uma população, que tem uma distribuição de probabilidade referente à estatística T , a qual recebe o nome de distribuição amostral da estatística T .

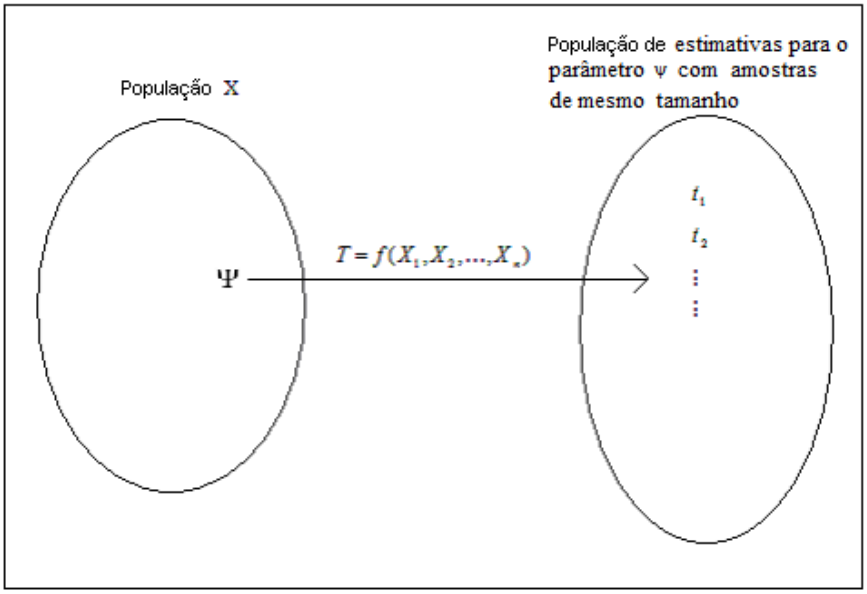

Teorema 5.2: para uma amostra aleatória $(X_1, X_2, \ldots, X_n)$ de uma distribuição normal de parâmetros μ e σ , a estatística $\bar{X}$ tem distribuição normal de média μ e desvio padrão $\frac{\sigma}{\sqrt{n}}$.

Exemplo 5.10: Uma população tem distribuição normal de média 800 e desvio padrão 60. Calcule a probabilidade de uma amostra aleatória apresentar média amostral entre 781,4 e 818,6 quando: (a) $n=9$ (b) $n=25$

Solução: Pelo Teorema 5.2, $Z=\dfrac{\bar{X}-E\left(\bar{X}\right)}{\sqrt{Var\left(\bar{X}\right)}}=\left(\dfrac{\bar{X}-\mu}{\sigma}\right)\times\sqrt{n}$ tem distribuição normal padrão.

(a)

$$P(781{,}4\leq\bar{X}\leq818{,}6)=P\left(\left(\frac{781{,}4-800}{60}\right)\times\sqrt{9}\leq Z\leq\left(\frac{818{,}6-800}{60}\right)\times\sqrt{9}\right)=$$
$$=\Phi(0{,}93)-\Phi(-0{,}93)=0{,}8238-0{,}1762=0{,}6476$$

(b) $P\left(781{,}4\leq\bar{X}\leq818{,}6\right)=\Phi(1{,}55)-\Phi(-1{,}55)=0{,}9394-0{,}0606=0{,}8788$

5.4 - Métodos de Estimação de parâmetros

Estimação por ponto: é a estimativa resultante da amostra.

Estimação por intervalo: a estimação por ponto não permite julgar a magnitude do erro que estamos cometendo. Daí surge a ideia de construir os intervalos de confiança, que são fundamentados na distribuição amostral do estimador.

$P(\Psi\in I.C.)=\gamma$

"I.C." é a abreviatura de Intervalo de confiança

γ é dito grau de confiança, que é a probabilidade do parâmetro pertencer ao intervalo

$\alpha=1-\gamma$ é a probabilidade de não pertencer ao intervalo

Construção de intervalos de confiança: o teorema a seguir é o alicerce dos Intervalos de Confiança.

Teorema 5.3 (Teorema Central do Limite): Para uma amostra aleatória $(X_1,\ldots,X_n)$ e um estimador $T_n=f(X_1,\ldots,X_n)$ de *máxima verossimilhança* do parâmetro Ψ, tal que $E(T_n)=\Psi$, tem-se:

$$Z_n=\frac{T_n-E(T_n)}{\sqrt{Var(T_n)}}\overset{n\to\infty}{\to}N(0,1)$$

Por exemplo, $T_n=\bar{X}_n$, $Z_n=\left(\dfrac{\bar{X}_n-\mu}{\sigma}\right)\sqrt{n}\approx N(0,1)$.

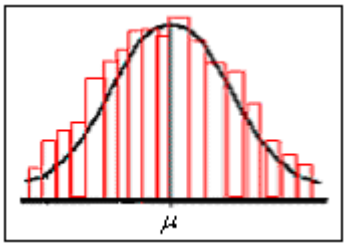

5.4.1 - IC para a média populacional μ quando o desvio padrão populacional σ é conhecido

Observação: se o desvio padrão da população for conhecido, então será dito explicitamente, ou será utilizada a notação σ .

Pelo Teorema 5.3, $P\left(-z_{tab}^{(b)} \leq \frac{\bar{X}-E\left(\bar{X}\right)}{\sqrt{Var\left(\bar{X}\right)}} \leq z_{tab}^{(b)}\right) \approx 1-\alpha$, onde z_{tab}^{b} é tal que $P\left(|Z|>z_{tab}^{b}\right)=\alpha$, Z normal padrão.

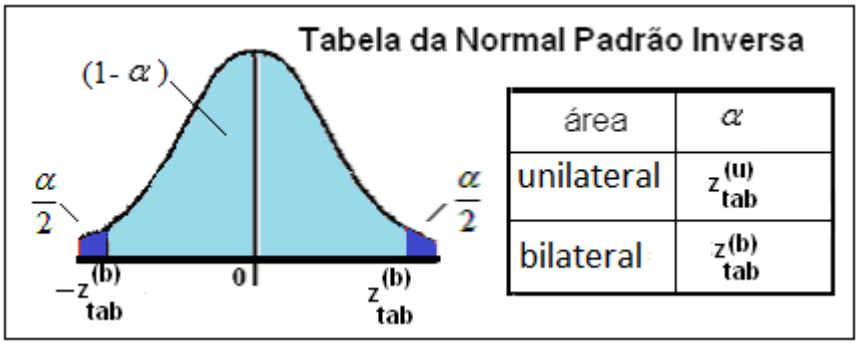

Mas $E(\bar{X})=\mu$ e $\sqrt{Var(\bar{X})}=\frac{\sigma}{\sqrt{n}}$. portanto,

$$-z_{tab}^{b} \leq \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{tab}^{b}$$

$$\bar{X}-z_{tab}^{b}\times\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}+z_{tab}^{b}\times\frac{\sigma}{\sqrt{n}}$$

Assim, o intervalo de confiança para μ , de grau $\gamma=(1-\alpha)\times 100\%$, é dado por $\left[\bar{X}-\varepsilon\,;\bar{X}+\varepsilon\right]$, onde $\varepsilon=z_{tab}^{(b)}\frac{\sigma}{\sqrt{n}}$ é dito erro de estimação (ou erro amostral).

Observações:

(1ª) É importante fazer distinção entre o desvio padrão populacional e o amostral. Para a população, a notação é σ e para a amostra é s.

(2ª) Note que o erro de estimação é a semiamplitude do I.C, e a média amostral estará no centro.

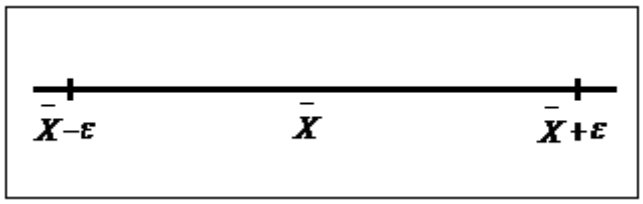

(3ª) Os extremos do IC são aleatórios. Quando for obtida a amostra, a média amostral será um número, e assim os extremos do intervalo estarão bem definidos. O IC será então chamado de uma estimativa por intervalo para o parâmetro.

(4ª) Interpretação do Intervalo de Confiança: aproximadamente $(1-\alpha)\times 100\%$ dos intervalos originados de amostras de mesmo tamanho contenham o parâmetro μ

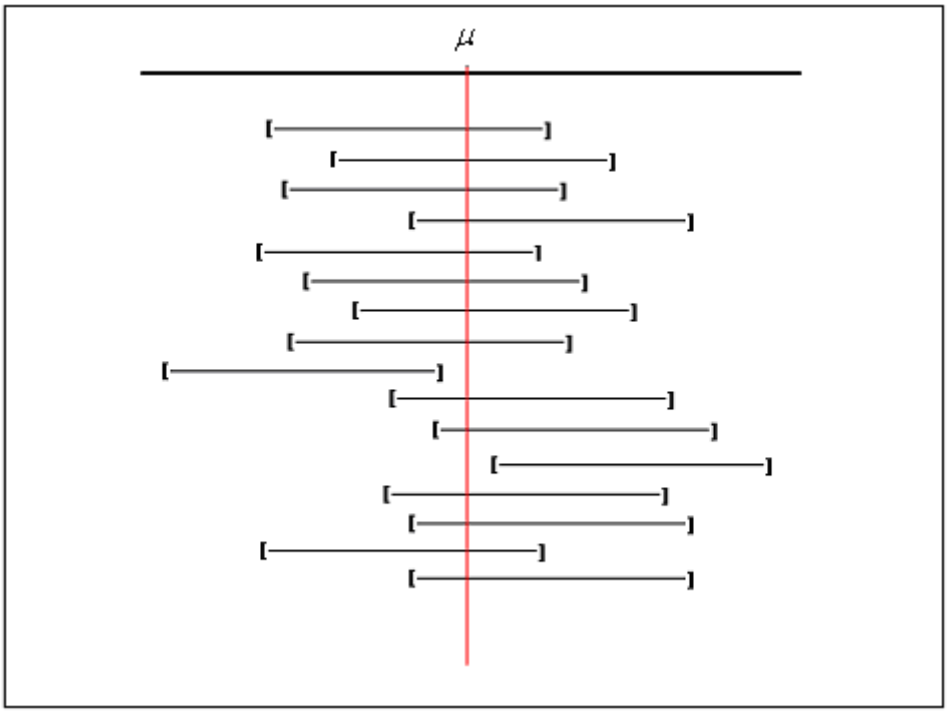

(5ª) Não se utiliza grau de confiança igual a 1, pois neste caso o intervalo fica a própria reta real! De fato, para que $P\left(-z_{tab}^{b} \leq Z \leq z_{tab}^{b}\right)=1$, então é preciso que $z_{tab}^{b}=+\infty$, e portanto, $IC=(-\infty,+\infty)$.

(6ª) Um grau de confiança igual a 0 resulta em um intervalo degenerado (que é a própria estimativa por ponto!). De fato, para que $P\left(-z_{tab}^{b} \leq Z \leq z_{tab}^{b}\right)=0$, então é preciso que $z_{tab}^{b}=0$, e portanto, $IC=[\bar{X},\bar{X}]$, ou seja, um intervalo degenerado.

(7ª) Não existe um valor ideal para o grau de confiança. Nunca se deve utilizar os extremos 0 e 1. Os valores mais usuais são 0,99; 0,95 e 0,90, mas não há uma justificativa formal para usá-los, são apenas valores de referência mais encontrados em artigos e livros. Fisher utilizava 0,95 e talvez por isto ficou um valor "consagrado".

(8ª) O desvio padrão σ influencia diretamente na amplitude do I.C., ou seja, se σ for grande, então o I.C. será amplo. O grau de confiança também é responsável pela amplitude do I.C. Mantendo γ fixado, se n aumentar então a amplitude do I.C. irá diminuir, ou seja, ficará mais preciso.

Exemplo 5.11: foram medidos os diâmetros de eixos de 100 caminhões. Sabe-se que σ =0,04 cm. A amostra de 100 eixos resultou em $\bar{x}$ =19,92 cm . Construa intervalos de confiança para a média populacional com:

(a) $1-\alpha$ =0,90 (b) $1-\alpha$ =0,95 (c) $1-\alpha$ =0,99

solução:

(a) $$\left[19,92-1,6449\times\frac{0,04}{\sqrt{100}};19,92+1,6449\times\frac{0,04}{\sqrt{100}}\right]=[19,9134;19,9266]$$

(b) $$\left[19,92-1,96\times\frac{0,04}{\sqrt{100}};19,92+1,96\times\frac{0,04}{\sqrt{100}}\right]=[19,9121;19,9278]$$

(c) $$\left[19,92-2,5758\times\frac{0,04}{\sqrt{100}};19,92+2,5758\times\frac{0,04}{\sqrt{100}}\right]=[19,9097;19,9303]$$

5.4.2 - IC para a média populacional μ quando o desvio padrão populacional σ é desconhecido

Observação: se o desvio padrão da população for conhecido então será dito explicitamente ou será utilizada a notação σ .

A distribuição t-student:

Foi introduzida por William Gosset, que utilizou o pseudônimo "um estudante". Essa distribuição aparece quando substituímos o desvio padrão σ pelo respectivo estimador S . A densidade t-student é similar à normal padrão, isto é, e simétrica em torno de zero e tem a forma de um sino, sendo mais baixa (achatada) que a normal padrão. Além disso, a t-student converge à normal padrão.

Notação: $t(v)$, onde $v>0$ é o parâmetro da distribuição.

Comparação entre a normal padrão e a t-student

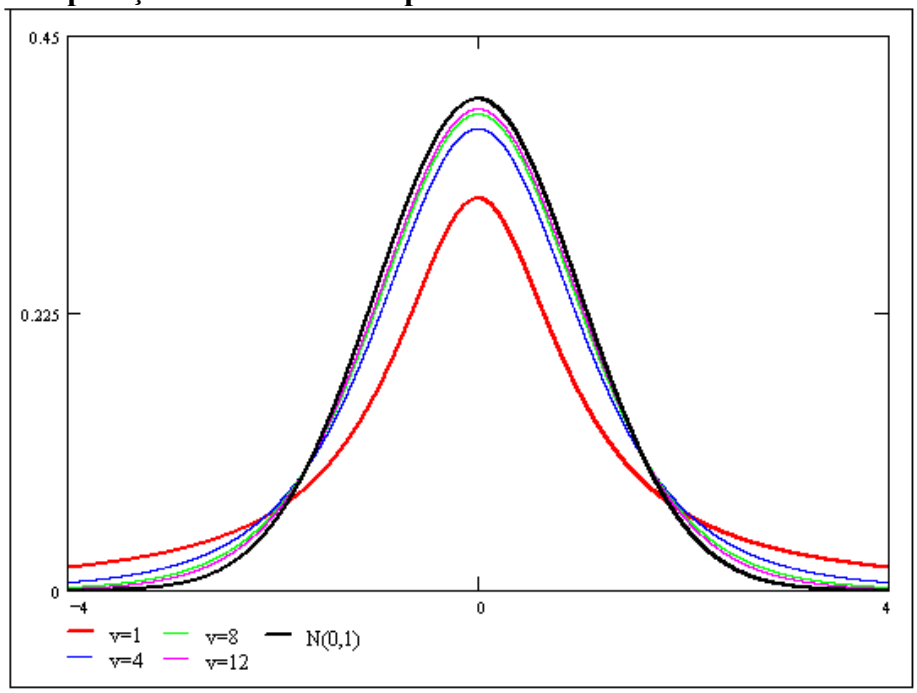

Em inferência estatística o parâmetro $v = n - 1$ e tem a denominação de "graus de liberdade". O conceito de graus de liberdade (GL) é o número de valores que poderemos atribuir de maneira arbitrária. Por exemplo, sabe-se a média de três números é 5. Então, uma vez determinados dois números, o terceiro ficará determinado.

$$\frac{x_1+x_2+x_3}{3}=5 \Rightarrow x_1+x_2+x_3=3\times 5=15$$

Suponha $x_1=4; x_2=5$, então $x_3=6$, ou seja, GL= 3-1=2.

A tabela da t-student é tal que se você entrar com GL e a área, você obterá a coordenada. Para GL maior que 120, utiliza-se a normal padrão.

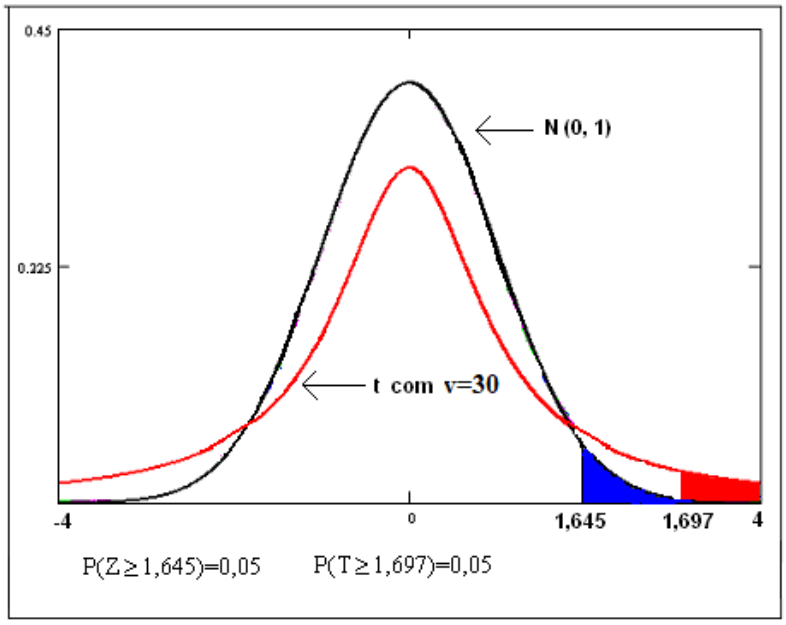

Modelo de Tabela t-student

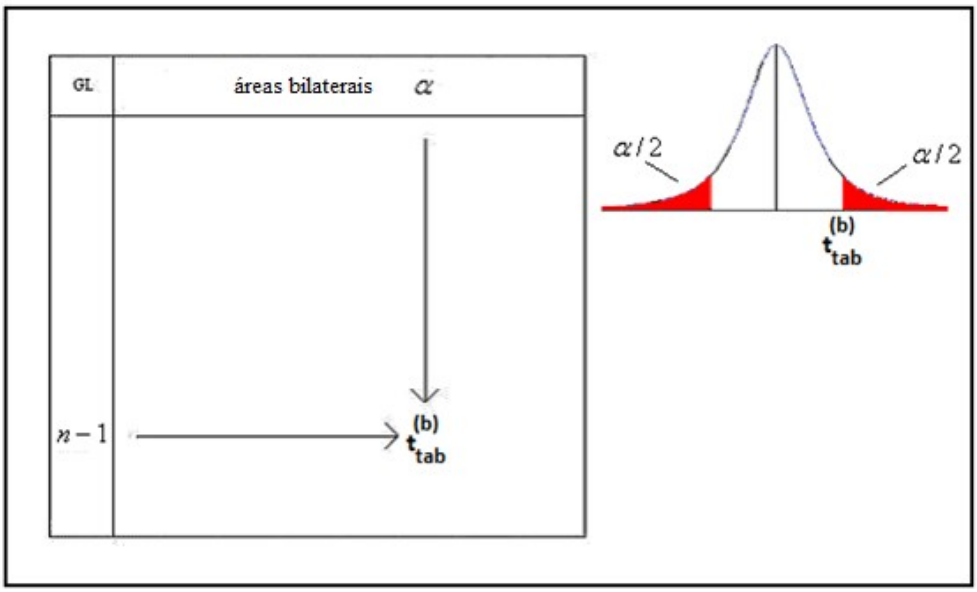

Intervalo de confiança: $[\bar{X}-\varepsilon;\bar{X}+\varepsilon]$ **,** $\varepsilon=t_{\text{tab}}^{b}\times\frac{S}{\sqrt{n}}$, onde $t_{\text{tab}}^{(b)}$ é t al que $P(|T|\geq t_{tab}^{(b)})=\alpha$, T é $t(n-1)$

Exemplo 5.12: foram observadas a duração do tonner de doze fotocopiadoras, cuja unidade de medida é em milhares de cópias. As medidas descritivas foram $\bar{x}=15$ e $s=2$. Faça IC de 0,95 para a média da população.

Solução: IC = $\left[15-2{,}201\times\frac{2}{\sqrt{12}};15+2{,}201\times\frac{2}{\sqrt{12}}\right]=[13{,}7293;16{,}2707]$

Observação: o desvio padrão amostral S influencia diretamente na amplitude do I.C. Se a variabilidade na amostra for alta, o I.C. será mais amplo. Aumentando-se a amostra, o I.C. deverá ficar mais preciso (com menor amplitude).

5.4.3 - IC para a proporção populacional θ

Intervalo de confiança: $[P-\varepsilon;P+\varepsilon]$; $\varepsilon=z_{\text{tab}}^{b}\times\sqrt{\frac{P(1-P)}{n}}$, onde P é a proporção amostral e $z_{tab}^{(b)}$ é tal que $P\left(|Z|>z_{tab}^{b}\right)=\alpha$, Z normal padrão.

Exemplo 5.13: suponha que foi feita uma pesquisa de mercado a respeito de um novo produto. Das 50 pessoas entrevistadas, 17 disseram que usariam o produto pelo menos para conhecê-lo melhor. Obtenha IC de 0,98 para a proporção de pessoas que usariam o produto.

Solução: $p=\frac{17}{50}=0,34$

$$\left[0,34-2,3263\times\sqrt{\frac{0,34\times 0,66}{50}};0,34+2,3263\times\sqrt{\frac{0,34\times 0,66}{50}}\right]=[0,1842;0,4958]$$

5.4.4 - IC para a variância populacional σ^2

A distribuição Qui-Quadrado: a distribuição origina-se da soma de quadrados de distribuições normais. A densidade dessa distribuição é assimétrica à direita. O nome "QUI" vem da letra grega χ .

Algumas distribuições Qui-Quadrado

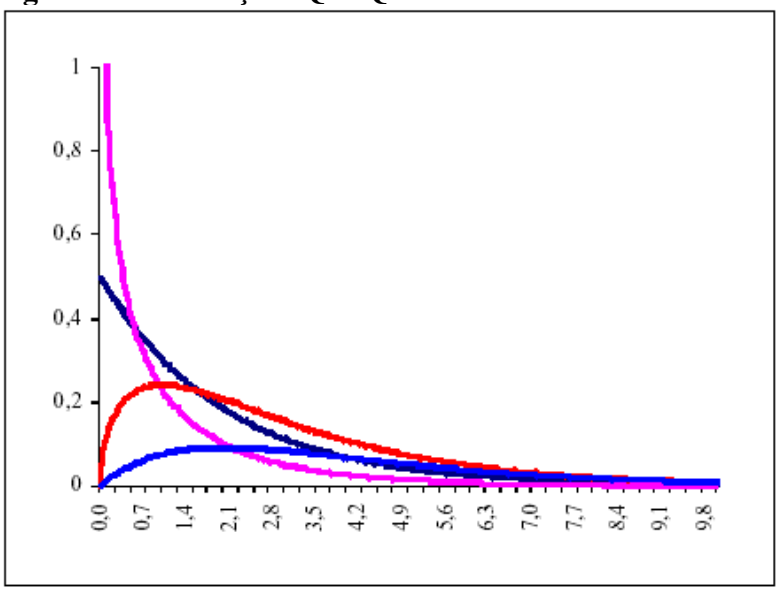

Notação: $Qui-Quadrado(v)$, onde $v>0$ é o parâmetro da distribuição.

Assim como na t-student, em inferência estatística esse parâmetro assume valores inteiros positivos, e denomina-se "graus de liberdade". A tabela da Qui-Quadrado é tal que se você entrar com GL=n-1 e a área, você obterá as coordenadas.

Modelo de Tabela Qui-Quadrado

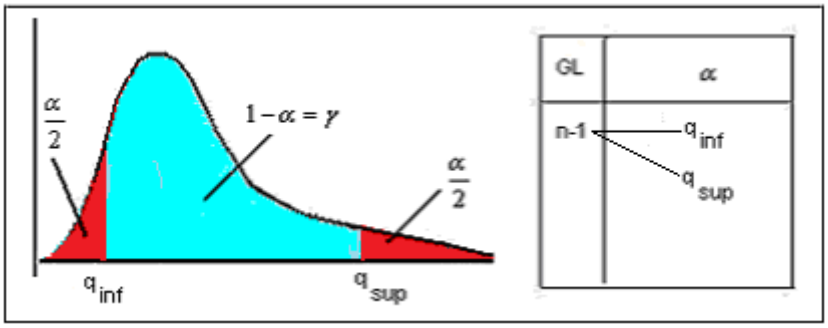

O intervalo de confiança para a variância é: $IC=\left[\frac{(n-1)S^2}{q_{\sup}},\frac{(n-1)S^2}{q_{\inf}}\right]$, onde

$P(q_{\inf}\leq X\leq q_{\sup})=1-\alpha$; X é $Qui-Quadrado(n-1)$

O intervalo de confiança para o desvio padrão é: $IC=\left[\sqrt{\frac{(n-1)S^2}{q_{\sup}}},\sqrt{\frac{(n-1)S^2}{q_{\inf}}}\right]$

Exemplo 5.14: O setor de qualidade de uma indústria deseja estimar a variação dos pesos de parafusos produzidos. Para uma amostra de 20 parafusos o desvio padrão foi 2 g. Obtenha intervalo de confiança de grau 0,95 para σ .

Solução: $IC=\left[\sqrt{\frac{(20-1)\times 2^2}{32{,}852}};\sqrt{\frac{(20-1)\times 2^2}{8{,}9065}}\right]=[1{,}5210;2{,}9211]$

5.5 - Dimensionamento de amostras

5.5.1 - Estimação da média

Vimos que para a média populacional, $I.C.=\left[\bar{X}-\varepsilon,\bar{X}+\varepsilon\right]$, onde $\varepsilon=z_{tab}^{b}\frac{\sigma}{\sqrt{n}}$ é o erro de estimação absoluto. Isolando n nesta última equação obtemos o tamanho da amostra:

população infinita: $n=\left(\frac{z_{tab}^{b}\times\sigma}{\varepsilon}\right)^2$, z_{tab}^{b} é tal que $P\left(|Z|>z_{tab}^{b}\right)=\alpha$, Z normal padrão.

população finita: $m=\frac{n\times N}{N+n}$

Observações:

(1ª) Se σ for desconhecido então a distribuição é a t-student, e portanto, $\varepsilon=t_{\text{tab}}^{\text{b}}\times\frac{S}{\sqrt{n}}$. Com esta equação não é possível obter uma forma algébrica para n , e nesta situação tem que se utilizar o método iterativo. Alternativa é utilizar uma aproximação, visto que a distribuição t-student converge para a normal padrão, e então, a expressão aproximada fica $n=\left(\frac{z_{tab}^{b}\times s}{\varepsilon}\right)^2$.

(2ª) O tamanho da amostra n e o erro de estimação ε tem relação inversa, como mostra a figura:

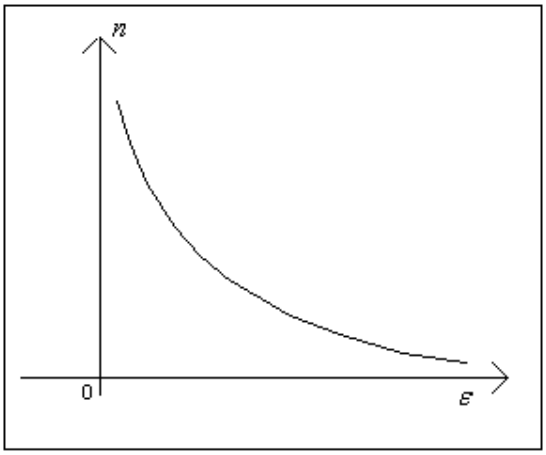

Exemplo 5.15: deseja-se estimar o salário médio de uma classe de trabalhadores. De uma amostra inicial de 20 trabalhadores obteve-se desvio padrão 150,00. Exige-se um erro absoluto máximo de 20,00 e um grau de confiança de 0,95. Qual deve ser o tamanho da amostra?

Solução: $n=\left(\frac{1,96\times 150}{20}\right)^2=216,09\simeq 216$

Supondo N=10000, $m=\frac{10000\times 216,09}{10000+216,09}=211,52\simeq 212$

5.5.2 - Estimação da proporção

ε_r é o erro de estimação relativo

população infinita: $n=\left(\frac{z_{tab}^b}{\varepsilon_r}\right)^2\times\theta\times(1-\theta)$

população finita: $m=\frac{n\times N}{N+n}$

Observações:

(1ª) o erro de estimação para a proporção está em termos relativos, visto que uma proporção é uma medida relativa (sem unidade de medida).

(2ª) Se θ for desconhecida, pode-se utilizar alguma estimativa de uma pesquisa anterior, ou realizar uma pesquisa inicial para estimar um valor para θ. Também se pode assumir o maior valor possível $\theta\times(1-\theta)=0,25$. Desta forma,

$$n=\left(\frac{z_{tab}^b}{\varepsilon_r}\right)^2\times 0,25$$

.

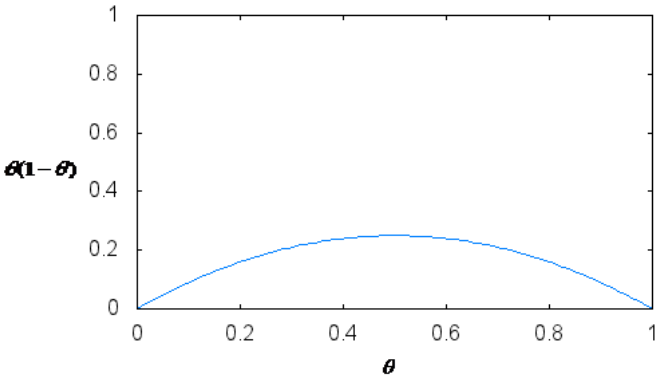

Exemplo 5.16: Antes de uma eleição um determinado partido está interessado em estimar a proporção de eleitores favoráveis ao seu candidato. Uma amostra preliminar de 50 pessoas foi selecionada de um bairro com N=4000 domicílios, constatando-se que 10 eram a favor. Qual deve ser o tamanho da amostra, com grau de confiança de 0,99 e erro de estimação máximo 0,05?

Solução: $p=\frac{10}{50}=0{,}2$; $z_{tab}^{b}=2{,}5758$

$$n=\left(\frac{2{,}5758}{0{,}05}\right)^2\times 0{,}2\times 0{,}80=424{,}36\approx 424 \quad ; \qquad m=\frac{4000\times 424{,}36}{4000+424{,}36}=383{,}66\simeq 384$$

Se usarmos $\theta(1-\theta)=0{,}5\times 0{,}5=0{,}25$,

$$n=\left(\frac{2{,}5758}{0{,}05}\right)^2\times 0{,}25=663{,}06\approx 663 \quad \text{e} \quad m\simeq 569$$

6ª Parte -Testes de Hipóteses

6.1 - Definições

Hipótese conceitual: é a hipótese formulada utilizando termos específicos da área em estudo.

Hipótese operacional: é a formulação matemática da hipótese conceitual

Exemplo 6.1: o biometano é menos poluente que combustíveis à base de petróleo

Como trabalhar matematicamente com essa hipótese? Compararemos as médias de emissões de partículas de óxido de enxofre por cm^3. Um grupo de veículos será abastecido com biometano e outro com gasolina. Vamos denotar por μ_b a média de emissão de partículas por cm^3 usando biometano, e por μ_g usando gasolina.

Hipóteses : $\mu_b = \mu_g$ contra $\mu_b < \mu_g$

Hipóteses estatísticas

Em inferência estatística uma hipótese é uma suposição formulada a respeito dos parâmetros de uma distribuição de probabilidade, de uma ou mais populações. Esta hipótese será testada com base em resultados amostrais, sendo aceita ou rejeitada. Ela somente será rejeitada se o resultado da amostra for improvável de ocorrer sob a suposição da hipótese ser verdadeira. Quando se "rejeita" ou "aceita" uma hipótese, não é uma conclusão definitiva e incontestável, visto que nas Ciências as Teorias sempre estarão sujeitas a reformulações.

Denominaremos por H_0 (hipótese nula) a hipótese a ser testada, e por H_1 (hipótese alternativa) a negação de H_0 . Através de um teste aceitaremos ou rejeitaremos H_0 . A nossa decisão terá uma probabilidade de erro. Essa probabilidade de erro é controlada (escolhida pelo pesquisador).

O quadro abaixo apresenta o que pode acontecer em um teste de hipóteses:

	REALIDADE	
DECISÃO	H_0 verdadeira	H_0 falsa
Aceitar H_0	Decisão Correta	Erro do tipo II
Rejeitar H_0	Erro do tipo I	Decisão Correta

Exemplo 6.2: suponha um julgamento num tribunal

	REALIDADE	
DECISÃO	inocente	Culpado
inocente	Decisão Correta	Erro do tipo II
Culpado	Erro do tipo I	Decisão Correta

As probabilidades desses erros são chamadas α e β respectivamente, ou seja:

$$\alpha = P(\text{erro tipo I}) = P(\text{rejeitar } H_0 \mid H_0 \text{ é verdadeira})$$
$$\gamma = P(\text{aceitar } H_0 \mid H_0 \text{ é verdadeira}), \text{ que é o grau de confiança}$$
$$\beta = P(\text{erro tipo II}) = P(\text{aceitar } H_0 \mid H_0 \text{ é falsa})$$
$$1-\beta = P(\text{rejeitar } H_0 \mid H_0 \text{ é falsa})$$

Nível de significância de um teste: é o valor de α no teste, ou seja, é a probabilidade de rejeitar H_0, supondo que é verdadeira. Os valores mais utilizados para α são: 0,01; 0,05 e 0,10.

Observações:

(1ª) No enfoque de Fisher, a preocupação é com os testes de significância, dando exclusiva atenção ao erro tipo I. Neste curso seguiremos o enfoque de Fisher, conhecido como ***Ensaios de Significância.***

(2ª) $1-\beta$ é dito o poder (potência) do teste de hipóteses. O poder estatísico foi desenvolvido por Newmann. Para detalhes, consulte Morettin & Bussab - Estatística Básica.

(3ª) Fisher, um dos precursores da Teoria Estatística, usou o valor de 0,05 para facilitar o ensino da Teoria, e por isso ficou como um valor "consagrado".

6.2 - Etapas de um teste de hipóteses

(1ª) Formular as hipóteses estatísticas: a hipótese nula a respeito de um parâmetro ψ deve conter a igualdade e a alternativa pode ser bilateral ou unilateral.

$H_0 : \psi = \psi_0$ $\quad$ $H_1 : \psi \neq \psi_0$ (bilateral)
$\psi < \psi_0$ (unilateral à esquerda)
$\psi > \psi_0$ (unilateral à direita).

(2ª) Fixar o nível de significância do teste.

(3ª) Calcular a estatística do teste, a qual será comparada com o valor tabelado através de uma regra de decisão.

(4ª) Tomada de decisão: rejeitar H_0 se a estatística do teste estiver na região crítica (região onde a hipótese nula é rejeitada), caso contrário não se rejeita H_0. A região crítica dependerá de α e do tipo de hipótese alternativa.

6.3 – Principais testes de hipóteses

6.3.1 - Teste de hipóteses para a média de uma população quando o desvio padrão σ for conhecido

Observação: é importante a distinção entre σ e S. Este teste é conhecido como "teste z para uma média", pois σ é por suposição conhecido, e assim a distribuição da estatística do teste é normal padrão.

$H_0: \mu = \mu_0$

estatística do teste: $z_c = \left(\dfrac{\bar{X} - \mu_0}{\sigma} \right) \sqrt{n}$

nota: para a estatística do teste usamos a notação z_c, sendo "c" a abreviatura de "calculado através da amostra".

H_1 bilateral ($H_1: \mu \neq \mu_0$): rejeita H_0 se $|z_c| > z^b_{tab}$, tal que $P\left(|Z| > z^b_{tab}\right) = \alpha$ Z normal padrão.

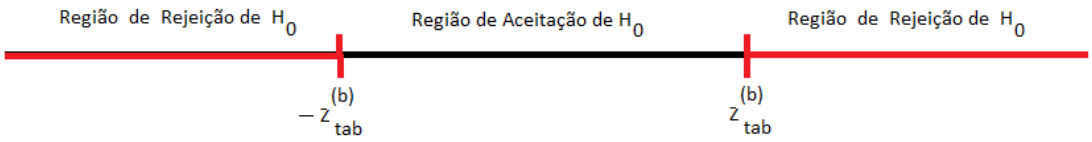

H_1 unilateral à direita ($H_1: \mu > \mu_0$): rejeita H_0 se $z_c > z^u_{tab}$, tal que $P\left(Z > z^u_{tab}\right) = \alpha$.

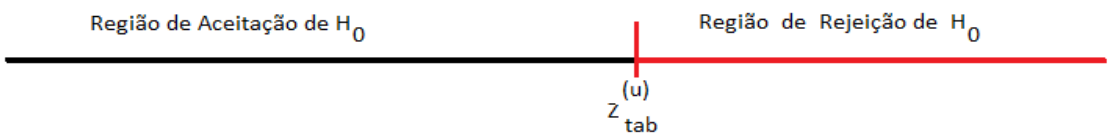

H_1 unilateral à esquerda ($H_1 : \mu < \mu_0$): rejeita H_0 se $z_c < -z^u_{tab}$ tal que $P\left(Z < -z^u_{tab}\right) = \alpha$.

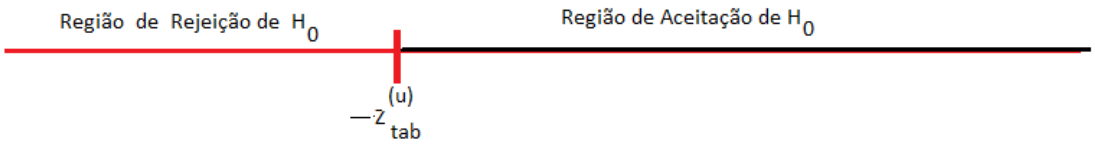

Tabela da Normal Padrão Inversa

área	α
unilareral	$z^{(u)}_{tab}$
bilateral	$z^{(b)}_{tab}$

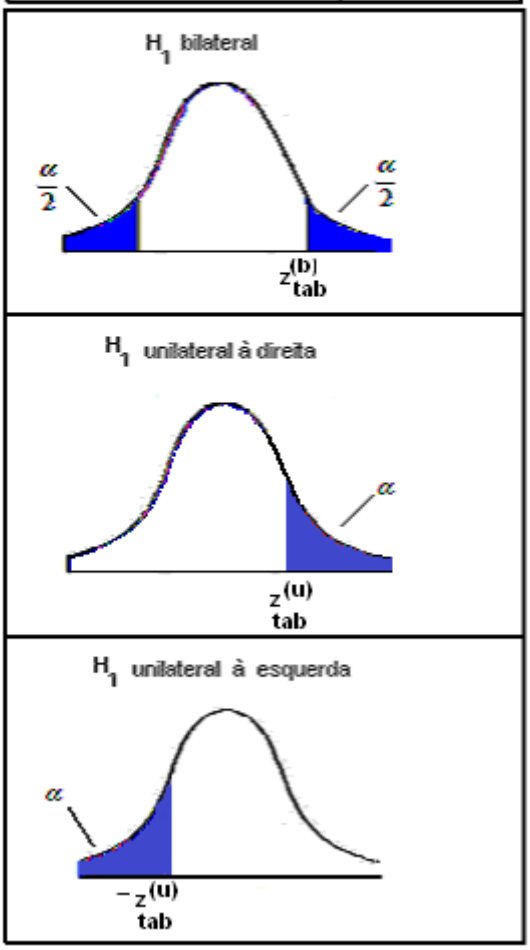

Observações:

(1ª)

valor pequeno de α equivale a um teste conservador (protege Ho)

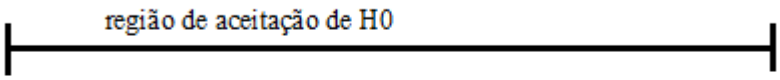

valor grande de α equivale a um teste rigoroso (vai contra Ho)

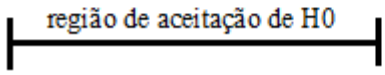

(2ª) se σ for grande, a estatística z_c não será sensível o bastante para detectar diferença significante entre $\bar{X}$ e μ_0 .

(3ª) aumentando a amostra, o teste ficará mais sensível para detectar diferenças significativas.

(4ª) O teste unilateral é mais rigoroso que o bilateral. Na figura abaixo, o valor tabelado do teste unilateral é menor que no bilateral. Se $z_{tab}^{(u)} < |z_c| < z_{tab}^{(b)}$, então o teste unilateral rejeitará a hipótese nula, mas o bilateral não.

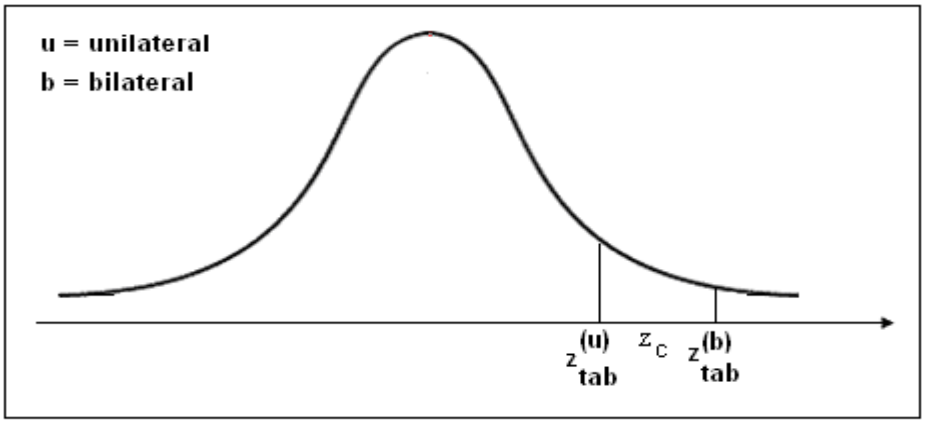

Exemplo 6.3: uma linha de produção fabrica parafusos cujo diâmetro (em mm) tem desvio padrão $\sigma = 2$. Tomou-se uma amostra de tamanho 20, cujas estatísticas foram $\bar{x} = 3,735$ e $s = 3,8756$. Com $\alpha = 0,05$, teste $H_0: \mu = 5$ contra:

(a) $H_1: \mu \neq 5$ (b) $H_1: \mu < 5$

(c) Em relação ao item (b), apresente um α que levaria à aceitação de H_0 .

Solução:

Estatística do teste: $z_c = \left(\frac{3,735-5}{2} \right) \sqrt{20} = -2,82$

(a) $z_{tab}^b = 1,96$. Como $|z_c| > z_{tab}^b$, rejeitamos H_0 .

(b) $-z_{tab}^u = -1,6449$. Como $z_c < -z_{tab}^u$, rejeitamos H_0 .

(c) Temos que encontrar um $-z_{tab}^u$ tal que $z_c > -z_{tab}^u$. Um possível valor é $-z_{tab}^u = -3$, o qual leva-nos à aceitação de H_0 . Mas, $\alpha = P(Z \leq -z_{tab}^u) = 0,00135$, que é considerado um teste conservador (protege a hipótese nula).

6.3.2 - Teste de hipóteses para a média de uma população quando o desvio padrão σ for desconhecido

Observação: este teste é conhecido como "teste t para uma média", pois σ é desconhecido, e assim a distribuição da estatística do teste é t- student com Gl= n-1.

$H_0 : \mu = \mu_0$

Estatística do teste: $t_c = \left(\frac{\bar{X} - \mu_0}{S} \right) \sqrt{n}$

H_1 bilateral $(\mu \neq \mu_0)$: rejeita H_0 se $|t_c| > t_{tab}^b$, $P(|T| > t_{tab}^b) = \alpha$, T é t student com n-1 graus de liberdade.

H_1 unilateral à direita $(\mu > \mu_0)$: rejeita H_0 se $t_c > t_{tab}^u$, $P(T > t_{tab}^u) = \alpha$

H_1 unilateral à esquerda $(\mu < \mu_0)$: rejeita se H_0 $t_c <$ - t_{tab}^u , $P(T < -t_{tab}^u) = \alpha$

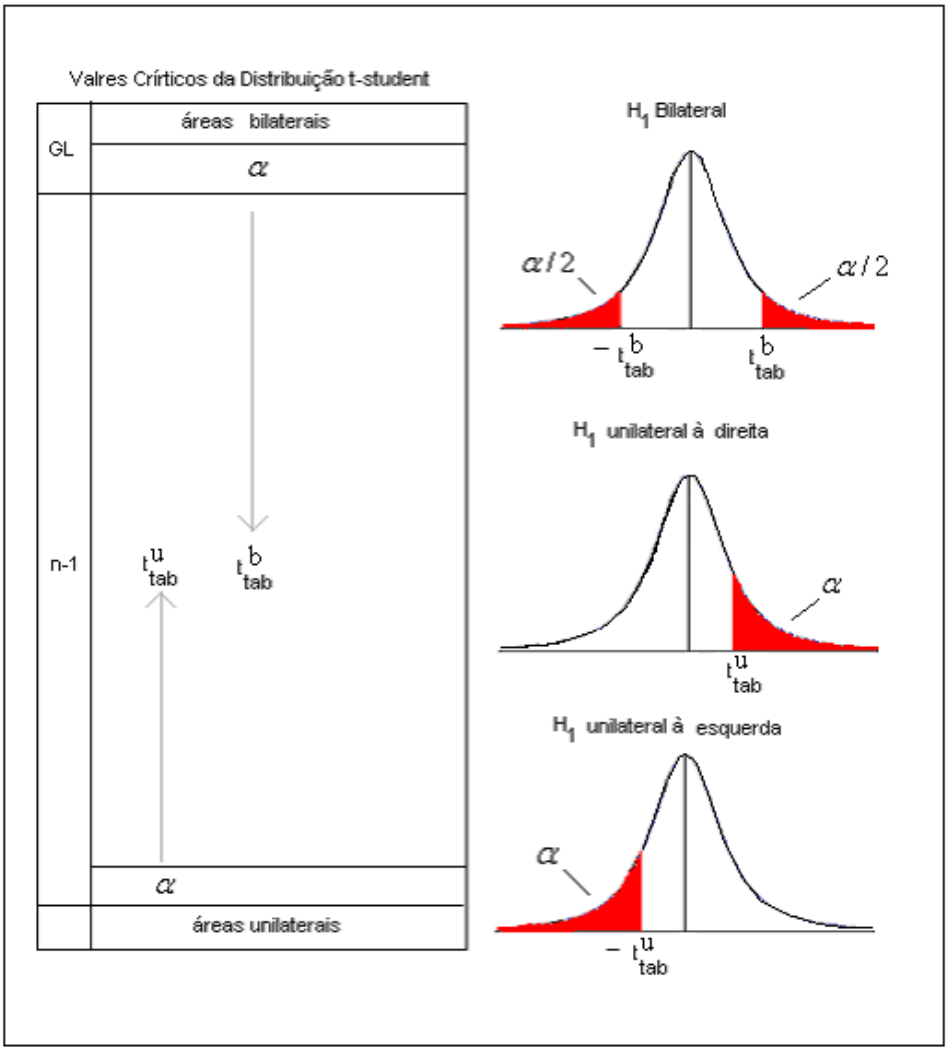

Exemplo 6.4: em relação ao Exemplo 6.3, vamos supor que σ era desconhecido. Use $\alpha = 0,05$.

Solução: $t_c = \left(\frac{3,735-5}{3,8756}\right) \times \sqrt{20} = -1,4597$

(a) $t^b_{tab} = 2,093$. Como $|t_c| < t^b_{tab}$, não rejeitamos H_0 .

(b) $t^u_{tab} = 1,7291$. Como $t_c > -t^u_{tab}$, não rejeitamos H_0 .

Nota: como $CV = \frac{3,8756}{3,735} \times 100\% = 103,76\%$ é elevado, o teste não foi sensível o bastante para detectar diferença significativa! No exemplo 6.3 o teste Z foi sensível o bastante para detectar a queda no diâmetro médio dos parafusos, pois a estatística do teste utilizou o parâmetro σ .

6.3.3 - Teste de hipóteses para a proporção de uma população

Observação: este teste é conhecido como "teste z para uma proporção", pois a distribuição da estatística do teste é assintoticamente normal padrão.

$H_0: \theta = \theta_0$

Estatística do teste: $z_c = \left(\frac{P - \theta_0}{\sqrt{\theta_0 (1 - \theta_0)}} \right) \sqrt{n}$, sendo P a proporção amostral.

H_1 bilateral($\theta \neq \theta_0$): rejeita H_0 se $|z_c|$ > z_{tab}^b , tal que $P\left(|Z| > z_{tab}^b\right) = \alpha$, Z normal padrão.

H_1 unilateral à direita ($\theta > \theta_0$): rejeita H_0 se z_c > z_{tab}^u , tal que $P\left(Z > z_{tab}^u\right) = \alpha$

H_1 unilateral à esquerda($\theta < \theta_0$): rejeita H_0 se z_c < $-z_{tab}^u$, $P\left(Z < -z_{tab}^u\right) = \alpha$

Exemplo 6.5: uma estação de TV afirma que 0,70 dos televisores estavam ligados no seu programa especial de sábado. Uma rede concorrente deseja contestar essa afirmação, e decide entrevistar 300 domicílios. Desses 300, 189 deram respostas afirmativas. Teste a hipóteses $H_0: \theta = 0{,}7$ e $H_1: \theta < 0{,}7$, com $\alpha = 0{,}01$.

Solução: $z_c = \left(\frac{0{,}63 - 0{,}7}{\sqrt{0{,}7 \times 0{,}3}} \right) \times \sqrt{300} = -2{,}65$, $z_{tab}^u = 2{,}3263$

Como $z_c < -z_{tab}^u$ então há evidências significativas para rejeitar H_0

6.3.4 - Teste de hipóteses para a igualdade de médias de duas populações com desvios padrões populacionais conhecidos

Observação: este teste é conhecido como "teste z para duas médias", pois os desvios padrões das populações são por suposição conhecidos, e assim a distribuição da estatística do teste é normal padrão.

$H_0: \mu_X = \mu_Y$

Estatística do teste: $z_c = \left(\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \right)$, n é o tamanho da amostra para X e m para Y.

H_1 bilateral($\mu_X \neq \mu_Y$): rejeita H_0 se $|z_c|$ > z_{tab}^b , tal que $P\left(|Z| > z_{tab}^b\right) = \alpha$, Z normal padrão.

H_1 unilateral à direita($\mu_X > \mu_Y$): rejeita H_0 se z_c > z_{tab}^u , tal que $P\left(Z > z_{tab}^u\right) = \alpha$

H_1 unilateral à esquerda($\mu_X < \mu_Y$): rejeita H_0 se z_c < - z_{tab} , tal que $P\left(Z < -z_{tab}^u\right) = \alpha$

Exemplo 6.6: deseja-se verificar se duas máquinas de empacotar café são homogêneas com relação ao peso interno. Sabe-se, pelos manuais das máquinas, que $\sigma_X = 24 ; \sigma_Y = 26\, g$. Foram obtidas amostras para cada máquina. Teste se a média da máquina X é significativamente maior que a de Y, utilizando $\alpha = 0,10$.

Estatísticas	X	Y
Média	500 g	497 g
Amostra	60	63

Solução: $H_0 : \mu_X = \mu_Y$ contra $H_1 : \mu_X > \mu_Y$

$$z_c = \left(\frac{500 - 497}{\sqrt{\frac{24^2}{60} + \frac{26^2}{63}}} \right) = 0,6654 \quad ; \quad z_{tab}^u = 1,2816$$

Como $z_c < z_{tab}^u$ então não se rejeita H_0 .

6.3.5 - Teste de hipóteses para a igualdade de médias de duas populações independentes com desvios padrões populacionais desconhecidos

Observação: este teste é conhecido como "teste t para duas médias", pois os desvios padrões das populações são desconhecidos, e assim a distribuição da estatística do teste é t student.

$H_0 : \mu_X = \mu_Y$

Estatística do teste: $t_c = \dfrac{\bar{X} - \bar{Y}}{\sqrt{S^2 \times \left(\frac{1}{n} + \frac{1}{m} \right)}}$, $S^2 = \dfrac{(n-1) S_X^2 + (m-1) S_Y^2}{n + m - 2}$

$S_X^2 ; S_Y^2$ são as variâncias amostrais

H_1 bilateral $(\mu_X \neq \mu_Y)$: rejeita H_0 se $|t_c| > t^b_{tab}$, $P(|T| > t^b_{tab}) = \alpha$, T é t student com $n + m - 2$ graus de liberdade.

H_1 unilateral à direita $(\mu_X > \mu_Y)$: rejeita H_0 se $t_c > t^u_{tab}$, $P(T > t^u_{tab}) = \alpha$

H_1 unilateral à esquerda $(\mu_X < \mu_Y)$: rejeita H_0 se $t_c < -t^u_{tab}$, $P(T < -t^u_{tab}) = \alpha$

Exemplo 6.7: Foi realizado um estudo comparativo do tempo médio de adaptação.

Estatísticas	Homens	Mulheres
Média	3,2 anos	3,4 anos
Desvio padrão	0,8	0,7
Amostra	14	16

Teste se há diferença significativa entre as médias, usando $\alpha = 0,05$.

Solução: $H_0: \mu_H = \mu_M$ contra $H_1: \mu_H \neq \mu_M$.

$$S^2 = \frac{(14-1) \times 0,8^2 + (16-1) \times 0,7^2}{14+16-2} = 0,5596$$

$$t_c = \frac{3,4 - 3,2}{\sqrt{0,5596 \times \left(\frac{1}{14} + \frac{1}{16}\right)}} = 0,7305$$

Para Gl=28, $t^b_{tab} = 2,0484$. Como $|t_c| < t^b_{tab}$ então não rejeitamos H_0 .

6.3.6 - Teste de hipóteses para a igualdade de duas proporções populacionais

Observação: este teste é conhecido como "teste z para duas proporções", pois a distribuição da estatística do teste é assintoticamente normal padrão.

$$H_0: \theta_X = \theta_Y$$

Estatística do teste: $z_c = \dfrac{P_X - P_Y}{\sqrt{P \times (1-P) \times \left(\frac{1}{n} + \frac{1}{m}\right)}}$,

P_X, P_Y são as proporções amostrais e $P = \dfrac{n \times P_X + m \times P_Y}{n+m}$

H_1 bilateral($\theta_X \neq \theta_Y$): rejeita H_0 se $|z_c|$ > z_{tab}^b , tal que $P\left(|Z| > z_{tab}^b\right) = \alpha$, Z normal padrão.

H_1 unilateral à direita($\theta_X > \theta_Y$): rejeita H_0 se z_c > z_{tab}^u , tal que $P\left(Z > z_{tab}^u\right) = \alpha$

H_1 unilateral à esquerda($\theta_X < \theta_Y$): rejeita H_0 se z_c < - z_{tab} , tal que $P\left(Z < -z_{tab}^u\right) = \alpha$

Exemplo 6.8: nas prévias de uma eleição, o candidato de um partido apresentou os seguintes resultados para pesquisas feitas em SP e RJ:

SP(X)	RJ (Y)
n= 500 n^0 favoráveis= 154	m=496 n^0 favoráveis= 140

Teste $H_0 : \theta_X = \theta_Y$ contra $H_1 : \theta_X > \theta_Y$

(a) Obtenha um α e o respectivo valor tabelado tal que leve à aceitação de H_0

(b) Obtenha um α e o respectivo valor tabelado tal que leve à rejeição de H_0

Solução: $p_X = 0,31$, $p_Y = 0,28$.

$$p = \frac{154+140}{500+496} = 0,29518 \quad , \quad z_c = \frac{\frac{154}{500} - \frac{140}{496}}{\sqrt{p \times (1-p)\left(\frac{1}{500} + \frac{1}{496}\right)}} = 0,890542$$

(a) $\alpha = 0,10$, $z_{tab}^u = 1,2816$ (b) $\alpha = 0,30$, $z_{tab}^u = 0,5244$

7ª Parte - Correlação e Regressão

7.1 – Correlação Linear

O diagrama de dispersão nos fornece uma ideia do tipo de relacionamento entre duas variáveis quantitativas X e Y. Uma forma de mensurar a relação entre duas variáveis quantitativas é através do coeficiente de correlação linear de Pearson.

Exemplo 7.1:

Carga aplicada em uma mola, em kg (X): 1 2 3 4 5 6 7 8 9 10

Alongamento da mola, em cm (Y): 0,5 1,0 2,0 2,5 4,0 5,0 5,3 6,2 6,8 7,2

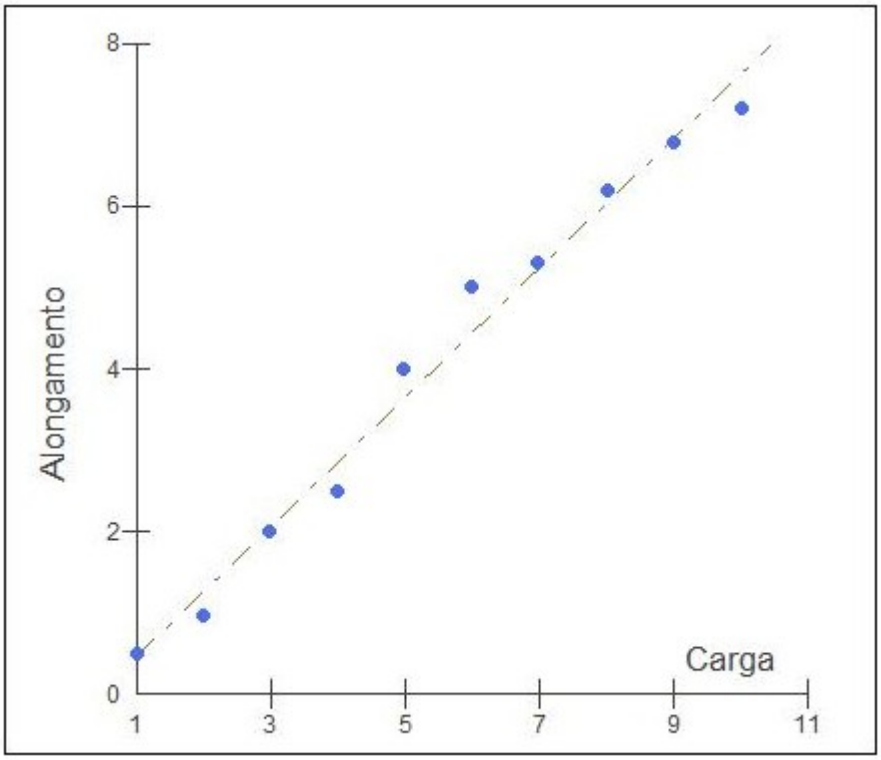

Definição: para uma amostra, o coeficiente de correlação linear de Pearson para duas variáveis é definido como:

$$R_{YX}=\frac{\sum_{i=1}^{n} X_i Y_i-\frac{\left(\sum_{i=1}^{n} X_i\right)\left(\sum_{i=1}^{n} Y_i\right)}{n}}{\sqrt{\left(\sum_{i=1}^{n} X_i^2-\frac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}\right)\left(\sum_{i=1}^{n} Y_i^2-\frac{\left(\sum_{i=1}^{n} Y_i\right)^2}{n}\right)}}$$

Exemplo 7.2: para o exemplo anterior,

Planilha do Excel

carga (X)	alongamento (Y)	X^2	Y^2	X*Y
1	0,5	1	0,25	0,5
2	1	4	1	2
3	2	9	4	6
4	2,5	16	6,25	10
5	4	25	16	20
6	5	36	25	30
7	5,3	49	28,09	37,1
8	6,2	64	38,44	49,6
9	6,8	81	46,24	61,2
10	7,2	100	51,84	72
Soma=55	Soma=40,5	Soma=385	Soma=217,11	Soma=288,4

$$R_{YX}=\frac{288{,}4-\frac{55\times 40.5}{10}}{\sqrt{\left(385-\frac{(55)^2}{10}\right)\left(217{,}11-\frac{(40{,}5)^2}{10}\right)}}=0{,}9920$$

O Excel também tem o comando que calcula diretamente a correlação linear: Correl( )

Resultados:

(1º) A correlação de Pearson independe da unidade de medida.

(2º) $R_{XY}=R_{YX}$

(3º) $R_{XY}=\cos(\Psi)$, onde Ψ é o ângulo entre os vetores X e Y

(4º) $-1\leq R\leq 1$, pois $-1\leq\cos(\psi)\leq 1$

(5º) se Y e X tiverem uma relação linear perfeita diretamente proporcional
($Y=a+bX\,;b>0$) então $R_{XY}=1$

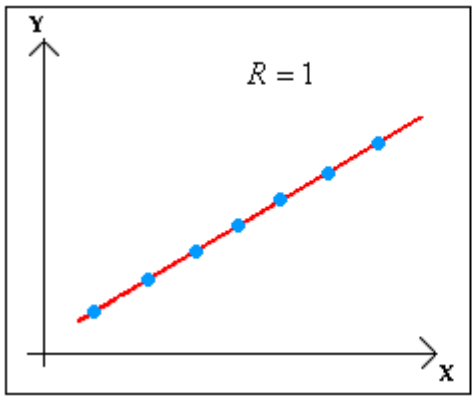

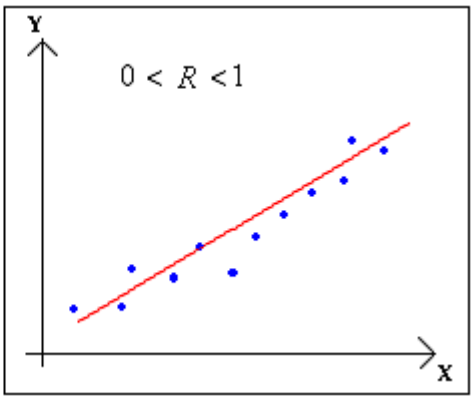

(6º) se Y e X tiverem uma relação linear perfeita inversamente proporcional ($Y=a+bX\,;b<0$) então $R_{XY}=-1$

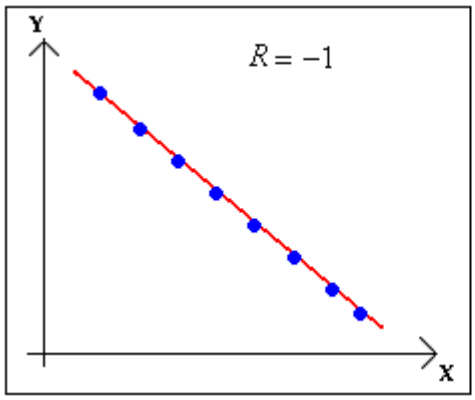

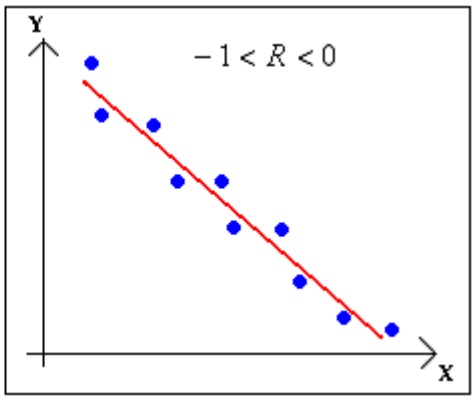

(7º) se Y e X forem independentes então $R=0$. Contudo, a recíproca não vale, $R_{xy}=0$ não implica Y e X independentes. Na figura, há uma relação perfeita $Y=X^2$, contudo, $R_{xy}=0$.

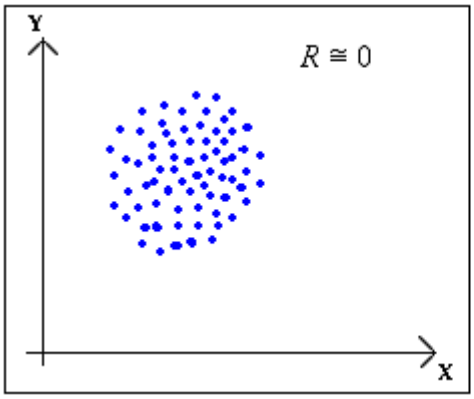

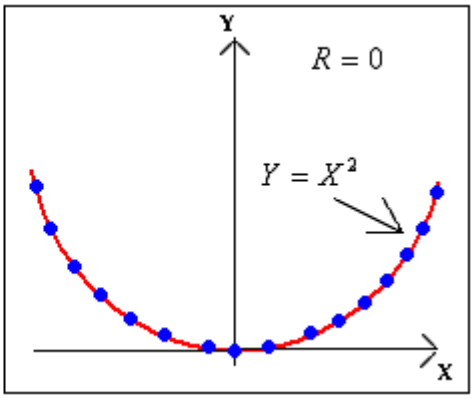

(8⁰)

$\lvert R_{XY}\rvert$	Interpretação da correlação
0 a 0,40	Fraca
0,40 a 0,70	Regular
0,70 a 0,80	Boa
0,80 a 0,99	Ótima
1	Perfeita

Teste de hipóteses para o coeficiente de correlação

$H_0 \;:\; \rho=0$ contra $H_1 \;:\; \rho\neq 0$

Estatística do teste : $t_c=R\times\sqrt{\dfrac{n-2}{1-R^2}}$

Regra de decisão: rejeita-se H_0 se $|t_c|>t_{tab}^{(b)}$, onde $P(|T|>t_{tab}^{(b)})=\alpha$, T com distribuição $t(n-2)$.

Exemplo 7.3: para o exemplo anterior, $t_c = 0{,}9220 \times \sqrt{\frac{10-2}{1-0{,}9220^2}} = 22{,}2263$

Para $\alpha = 0{,}05$ .GL=8, $t^b_{tab} = 2{,}3060$ .Logo, $|t_c| > t^b_{tab}$,levando à rejeição de H_0 .

7.2 - O modelo linear simples

O modelo linear simples é definido como $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, i=1,.....,n., onde:

β_0, β_1 são os parâmetros do modelo que deverão ser estimados;
X é a variável preditora;
Y é a variável resposta (dependente).
ε é o erro aleatório

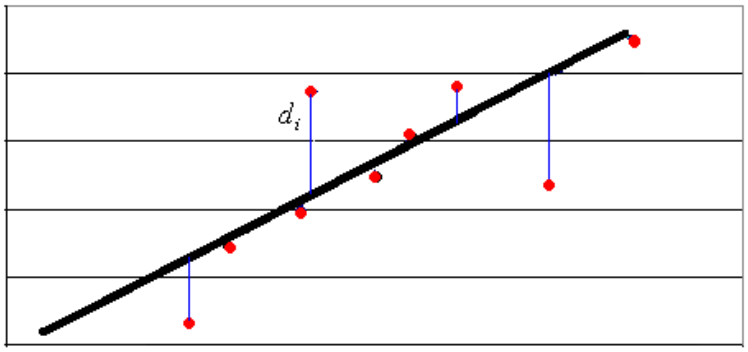

O método que usaremos para estimar os parâmetros do modelo é o dos Mínimos Quadrados (Gauss). Neste método, minimiza-se a soma dos quadrados das distâncias d_i (ver figura). Os estimadores de β_0 e β_1 são, respectivamente:

$$b_1 = \frac{\sum_{i=1}^{n} X_i Y_i - \frac{\left(\sum_{i=1}^{n} X_i\right)\left(\sum_{i=1}^{n} Y_i\right)}{n}}{\sum_{i=1}^{n} X_i^2 - \frac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}} \quad ; \qquad b_0 = \bar{Y} - b_1 \bar{X} \quad .$$

Observações:

(1ª) da relação $b_1 = R_{YX} \times \sqrt{\dfrac{\sum_{i=1}^{n} Y_i^2 - \dfrac{\left(\sum_{i=1}^{n} Y_i\right)^2}{n}}{\sum_{i=1}^{n} X_i^2 - \dfrac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}}}$ segue que b_1 , R_{YX} têm mesmo sinal

(2ª) A notação para o modelo ajustado é $\hat{Y} = b_0 + b_1 \times X$.

(3ª) No EXCEL o comando para ajustar a inclinação da reta é inclinação() e para o intercepto é intercepção()

O Coeficiente de determinação

R_{YX}^2 é dito coeficiente de determinação da regressão Y sobre X. É interpretado como o percentual da variância geral devido à regressão linear.

Exemplo 7.5: para o exemplo 7.1,

$$b_1 = \frac{288{,}4 - \dfrac{55 \times 40{,}5}{10}}{385 - \dfrac{55^2}{10}} = 0{,}7958$$

$$b_0 = 4{,}05 - 0{,}7958 \times 5{,}5 = -0{,}3267$$

O coeficiente de determinação é $R_{YX}^2 = 0{,}9841$, ou seja, 98,41% da variação de Y é devida ao preditor. O modelo ajustado ficou $\hat{y} = -0{,}326667 + 0{,}795758 \times X$. Para x=7,5 kg, o valor estimado para y será 5,6415 cm.

7.4 – Alguns Modelos não lineares

Exponencial: $Y = \alpha \times \exp\{\beta X\}$, $\alpha, \beta, X \in R$

Para ajustar este modelo por mínimos quadrados é necessário fazer a transformação

$\ln(Y) = \ln(\alpha) + \beta X$, e então ajustar a reta $Z = \delta + \beta X$, sendo $Z = \ln(Y)$ e $\delta = \ln(\alpha)$. Após o ajuste da reta, os parâmetros do modelo exponencial serão $\alpha = \exp(\delta)$ e β .

Logarítmico: $Y=\alpha+\beta\times\ln(x)$, $\alpha,\beta\in R$ $x>0$

Hiperbólico: $Y=\dfrac{x}{\alpha\times x-\beta}$, $\alpha\neq 0,\beta\in R,x\neq\dfrac{\beta}{\alpha}$

Logístico: $Y=\dfrac{\exp\{\alpha\times x+\beta\}}{1+\exp\{\alpha\times x+\beta\}}$, $x\in R$

Inverso: $Y=\dfrac{\alpha}{\beta X}$; $X,\alpha,\beta\neq 0$

Potência: $Y=\alpha X^{\beta}$; $\alpha,\beta\neq 0$

Exemplo 7.6: Série Censo Demográfico - IBGE

Ano	T = Ano – 1872	População	Variação %
1872	0	9930478	----------
1890	18	14333915	44,3426489641284
1900	28	17438434	21,6585559492993
1920	48	30635605	75,6786475207579
1940	68	41236315	34,602580885868
1950	78	51944397	25,9676016152268
1960	88	70191370	35,1278945446224
1970	98	93139037	32,6930034276294
1980	108	119002706	27,7688816988735
1991	119	146825475	23,3799465030652
2000	128	169799170	15,6469406960883
2010	138	190732695	12,3284024297645
2023	151	203062512	6,46444858339572

Ajuste pela função potência: $Y=17316\times t^{1,8806}$
Projeção para 2030 com o modelo potência: 236 179 443

Ajuste pela função logística: $Y=\dfrac{2,6687\times 10^{8}}{1+57,226\times\exp\{-0,03537\,t\}}$
Projeção para 2030 com o modelo logístico: 219 814 322

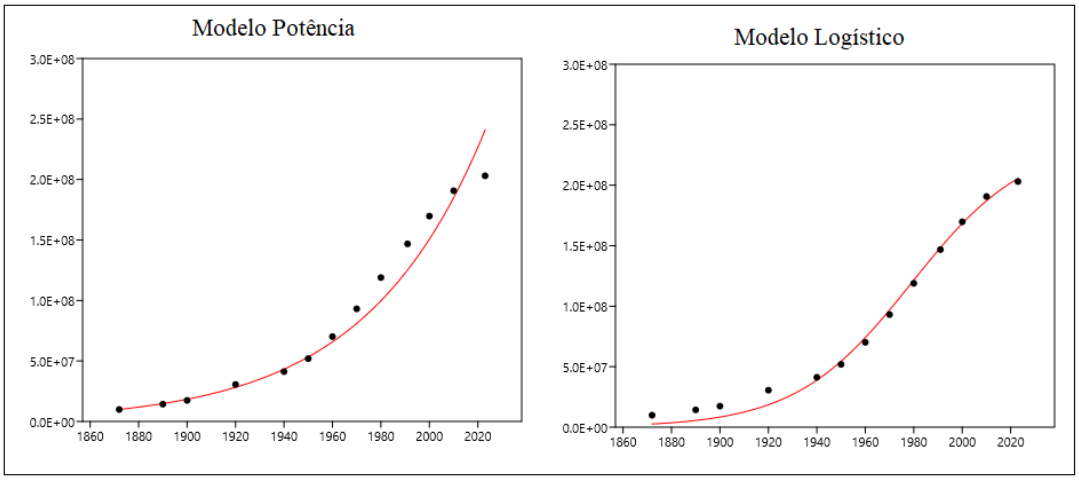

O modelo logístico tem um melhor ajuste. Analisando o gráfico , a partir de 2020 a população começa a apresentar um decréscimo na taxa de crescimento.

7.4 - Regressão linear múltipla

O modelo de regressão múltipla é a extensão do modelo simples, ou seja, poderá haver dois ou mais preditores. O enfoque matricial é o utilizado por softwares estatísticos. Neste texto nos concentraremos para o caso com dois preditores:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 Z_i + \varepsilon_i ; \quad i \in \{1,2,\ldots,n\}$$

$\beta_0, \beta_1, \beta_2$	são os parâmetros do modelo que deverão ser estimados;
$X ; Z$	são os preditores
Y	é a variável resposta (dependente).
ε	é o erro aleatório

Na forma matricial,

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \qquad M = \begin{bmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{bmatrix} \qquad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} \qquad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} ,$$

sendo M chamda de matriz do delineamento. Assim, $Y = M \otimes \beta + \varepsilon$, onde $\otimes$ denota multiplicação matricial. As estimativas de mínimos quadrados são obtidas por $b = \left(M^{\mathrm{T}} \otimes M \right)^{-1} \otimes M^{\mathrm{T}} \otimes Y$, sendo M^{T} a transposta de M .

Exemplo 7.6: Tempo para que uma reação química ocorra sob condições de temperatura e pressão.

X = Temperatura (Celsius) , Z=Pressão (Atm) , Y= Tempo (segundos)

X	20	30	30	40	60	80
Z	1,5	1,5	1,2	1,0	1,0	0,8
Y	9,4	8,2	9,7	9,5	6,9	6,5

$$M = \begin{bmatrix} 1 & 20 & 1{,}5 \\ 1 & 30 & 1{,}5 \\ 1 & 30 & 1{,}2 \\ 1 & 40 & 1{,}0 \\ 1 & 60 & 1{,}0 \\ 1 & 80 & 0{,}8 \end{bmatrix} \qquad Y = \begin{bmatrix} 9{,}4 \\ 8{,}2 \\ 9{,}7 \\ 9{,}5 \\ 6{,}9 \\ 6{,}5 \end{bmatrix}$$

Parâmetros estimados: $b_0 = 18{,}4281 ; b_1 = -0{,}1062 ; b_2 = -4{,}6808$

Modelo ajustado: $\widehat{Y}_i = 18{,}4281 - 0{,}1062\, X - 4{,}6808\, Z$

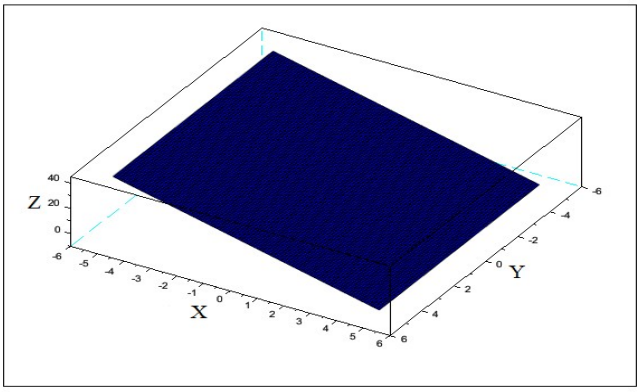

Exemplo 7.7: ajuste um modelo linear para Resistência em função de Força, Potência, Temperatura e Tempo.

Força(gm)	Potência(mw)	Temperatura(c)	Tempo(ms)	Resistência(ms)
30.	60.	175.	15.	26.2
40.	60.	175.	15.	26.3
30.	90.	175.	15.	39.8
40.	90.	175.	15.	39.7
30.	60.	225.	15.	38.6
40.	60.	225.	15.	35.5
30.	90.	225.	15.	48.8
40.	90.	225.	15.	37.8
30.	60.	175.	25.	26.6
40.	60.	175.	25.	23.4
30.	90.	175.	25.	38.6
40.	90.	175.	25.	52.1
30.	60.	225.	25.	39.5
40.	60.	225.	25.	32.3
30.	90.	225.	25.	43.
40.	90.	225.	25.	56.
25.	75.	200.	20.	35.2
45.	75.	200.	20.	46.9
35.	45.	200.	20.	22.7
35.	105.	200.	20.	58.7
35.	75.	150.	20.	34.5
35.	75.	250.	20.	44.
35.	75.	200.	10.	35.7
35.	75.	200.	30.	41.8
35.	75.	200.	20.	36.5
35.	75.	200.	20.	37.6
35.	75.	200.	20.	40.3
35.	75.	200.	20.	46.
35.	75.	200.	20.	27.8
35.	75.	200.	20.	40.3

$$Resistência = -37{,}48 + 0{,}21 \times Força + 0{,}50 \times Potência + 0{,}13 \times Temperatura + 0{,}26 \times Tempo$$